Elasticidad Precio-Demanda en el Servicio de Delivery de Comidas: Evidencia desde Datos Transaccionales

Jharol André Vilca Ramos
Estudiante de Ingeniería Industrial y Ciencia de Datos

Resumen

Este estudio examina la relación entre el precio final de compra (`checkout_price`) y la demanda en una plataforma de entrega de comidas, utilizando **datos observacionales agregados de demanda a nivel semana–centro–comida** (456 548 observaciones) del conjunto de datos público *Food Demand Forecasting* (Kaggle/Genpact). Se estimaron múltiples especificaciones complementarias: (1) OLS log-log con controles (elasticidad promedio $= -0,759$, IC 95 % agrupado por entidad $[-0,843, -0,675]$); (2) Panel con efectos fijos de dos vías (entidad y tiempo, elasticidad within $= -1,5985$, EE clusterizado por entidad $= 0,0239$); (3) Variables instrumentales 2SLS con instrumentos tipo Hausman-Nevo y los mismos controles (elasticidad $= -0,8414$, EE agrupado por centro $= 0,050$, IC 95 % $[-0,940, -0,743]$); el test de sobreidentificación de Hansen J rechaza con ponderación robusta a heterocedasticidad ($\chi^2 = 33,3$) pero no con ponderación agrupada por centro ($\chi^2 = 0,92$, $p = 0,34$), y el supuesto de exclusión no es contrastable, por lo que el resultado IV se presenta como análisis de sensibilidad, no como estimación causal definitiva. Los tests de especificación (RESET $F = 153,07$, $p \approx 3{,}5 \times 10^{-67}$; contraste F anidado RCS $F = 3\,607,28$, 2 gl., $p \approx 0$) rechazan la restricción de elasticidad constante, y la regresión cuantil revela heterogeneidad sistemática ($\tau = 0,1$: $-0,67$ a $\tau = 0,9$: $-1,01$). La conclusión principal es que la elasticidad precio-demanda **no es un parámetro escalar constante**: su magnitud depende del nivel de precio, la categoría de comida, el momento temporal y la fuente de variación explotada. El estudio incorpora además un flujo reproducible de procesamiento y una capa de inteligencia de negocios para la explotación de los resultados.

Palabras Claves: elasticidad-precio de la demanda, entrega de comidas, econometría aplicada, regresión log-log, datos observacionales agregados, datos de panel, variables instrumentales, 2SLS, efectos fijos, reproducibilidad, Python, SQLite, inteligencia de negocios

Introducción

El crecimiento sostenido de las plataformas de entrega de comidas ha transformado los hábitos de consumo alimentario urbano en la última década. Según estimaciones de mercado, el sector de entrega de comidas a domicilio ha experimentado tasas de crecimiento anual compuesto superiores al 10 % en múltiples economías, impulsado por la penetración de teléfonos inteligentes, la urbanización y, más recientemente, por cambios de comportamiento tras la pandemia de COVID-19 (Statista, 2024). En este contexto, comprender cómo responde la demanda ante cambios de precio no es solo un ejercicio académico: es una entrada crítica para la sostenibilidad económica de las plataformas, el diseño de estrategias comerciales (promociones, fijación dinámica de precios, suscripciones) y la evaluación de políticas públicas relacionadas con el acceso a la alimentación y la

regulación de mercados digitales.

La elasticidad precio de la demanda —definida como el cambio porcentual en la cantidad demandada ante un cambio porcentual en el precio— es el parámetro central para cuantificar esta sensibilidad. Sin embargo, la evidencia empírica disponible para el segmento específico de entrega de comidas sigue siendo limitada. La mayoría de los estudios existentes se centran en comida fuera del hogar (*food away from home*, FAFH) en sentido amplio (Andreyeva et al., 2010; Damayanti et al., 2023) o en transporte por aplicación (Christensen & Osman, 2021), pero escasean las estimaciones basadas en datos observacionales agregados derivados de registros transaccionales de plataformas de entrega de comidas. Li y Wang (2025) **señala la escasez de evidencia empírica previa** en *Management Science*, consistente con esta brecha, al no reportar coeficiente propio de elasticidad en plataformas de entrega de comidas con datos de transacciones observadas.

Este estudio cubre esa brecha examinando la relación entre precio final de compra (`checkout_price`) y demanda en un contexto real de entrega de comidas, utilizando un conjunto de **datos observacionales agregados de demanda a nivel semana–centro–comida** (456 548 observaciones) provenientes de la competencia pública *Food Demand Forecasting* de Genpact/Analytics Vidhya, alojada en Kaggle (Genpact / Analytics Vidhya, 2019). Se estimaron múltiples especificaciones: un modelo log-log con controles produce una elasticidad promedio de $-0,759$ (EE agrupado por entidad panel centro×comida: 0,043, IC 95 % $[-0,843, -0,675]$); el panel con efectos fijos de dos vías da $-1,5985$ (EE clusterizado por entidad 0,0239); y la estrategia IV 2SLS con instrumentos tipo Hausman-Nevo (especificación con controles) produce $-0,8414$ (EE agrupado por centro 0,050; IC 95 % $[-0,940, -0,743]$, que se solapa con el IC del OLS), aunque la exclusión de los instrumentos no es contrastable y el test de Hansen J solo rechaza bajo ponderación robusta a heterocedasticidad ($\chi^2 = 33,3$; con ponderación agrupada por centro, $\chi^2 = 0,92$, $p = 0,34$), lo que limita su interpretación causal. Crucialmente, los tests de especificación (RESET $F = 153,07$, $p \approx 3{,}5 \times 10^{-67}$; contraste F anidado RCS $F = 3\,607,28$, 2 gl., $p \approx 0$) rechazan la restricción de elasticidad constante, y la regresión cuantil muestra heterogeneidad sistemática ($-0,67$ a $-1,01$ según cuantil). La conclusión central es que la elasticidad **no es un parámetro escalar constante**: varía con el nivel de precio, la categoría, el momento y la fuente de identificación.

Objetivos y contribuciones

El objetivo general es estimar la elasticidad precio-demanda en un contexto real de entrega de comidas y contextualizar el hallazgo dentro de la evidencia empírica existente. Los objetivos específicos son:

1. Construir un flujo reproducible de limpieza y preparación de datos observacionales agregados, documentando decisiones críticas (p. ej., el hallazgo de que `base_price` no es un precio mínimo garantizado).

2. Estimar y comparar múltiples especificaciones de modelo de demanda (log-log base, log-log con controles, semi-log con controles) usando criterios cuantitativos (AIC, BIC, R^2 ajustado) y cualitativos (interpretabilidad, advertencias numéricas).

3. Validar formalmente los supuestos estadísticos del modelo seleccionado (heterocedasticidad con Breusch-Pagan y errores robustos HC3, multicolinealidad con VIF, normalidad con Jarque-Bera y Q-Q plot).

4. Ubicar el resultado propio dentro de una comparación estructurada con literatura verificada (meta-análisis FAFH, estudio indonesio con LA/AIDS, experimento de movilidad con Uber, evidencia emergente en entrega de comidas bajo demanda).

Las contribuciones del trabajo son: (a) una estimación de elasticidad ($-0,759$) basada en datos observacionales agregados derivados de registros transaccionales de *delivery* de comidas, poco común en la literatura; (b) un flujo reproducible y documentado que permite replicar y extender el análisis; (c) la verificación de que el comportamiento observado de `base_price` es consistente con

tratarlo como precio de referencia, no como piso garantizado, con 25,43 % de observaciones donde el precio final superó la referencia — hallazgo que, de ignorarse mediante una exclusión sistemática, podría introducir sesgo de selección; y (d) una comparación con literatura donde cada cita fue verificada contra la fuente primaria, descartando un documento generado por IA que contenía errores graves de atribución.

Descripción de los Datos

Fuente y estructura

El conjunto de datos proviene de la competencia *Food Demand Forecasting* de Genpact/Analytics Vidhya, disponible públicamente en Kaggle (Genpact / Analytics Vidhya, 2019). El conjunto de datos original está compuesto por tres tablas relacionales:

1. **train.csv**: Registros semanales de pedidos por combinación de centro de distribución (`center_id`) y tipo de comida (`meal_id`). Contiene 456 548 filas y las variables: `week` (semana 1–145), `center_id`, `meal_id`, `checkout_price` (precio final pagado por el cliente), `base_price` (precio de referencia/lista), `emailer_for_promotion` (binaria, promoción por correo), `homepage_featured` (binaria, destacada en página principal), `num_orders` (número de pedidos, variable objetivo).

2. **meal_info.csv**: Metadatos de las comidas. Contiene `meal_id`, `category` (categoría de comida) y `cuisine` (tipo de cocina: *indian*, *italian*, *thai*, *mexican*, *continental*, *chinese*).

3. **fulfilment_center_info.csv**: Metadatos de los centros. Contiene `center_id`, `center_type` (*TYPE_A*, *TYPE_B*, *TYPE_C*), `region_code` (código de región), `city_code` (código de ciudad), `op_area` (área operativa en km^2).

Período y cobertura

Los datos cubren 145 semanas de operación. Cada observación corresponde a una combinación única de `week` × `center_id` × `meal_id`, lo que permite modelar la demanda a nivel granular semanal por centro y producto. **El conjunto de datos no incluye fecha calendario exacta, solo el número de semana**, por lo que no es posible alinear las observaciones con festivos, eventos externos o un rango de años específico; cualquier referencia a un período calendario concreto en versiones previas de este documento fue un error y se ha corregido en esta versión.

Variables clave

Tras unir las tres tablas mediante `meal_id` y `center_id` (merge *left* que preserva las 456 548 filas originales de `train`), se obtiene un *DataFrame* final de 456 548 filas y 20 columnas, sin valores nulos en ninguna variable. Las variables principales para el análisis de elasticidad son:

- `checkout_price` (precio final de checkout): precio efectivamente cobrado al cliente esa semana, *incluyendo descuento, impuestos y cargos de entrega* (unidades monetarias del conjunto de datos original).
- `base_price` (precio base de referencia): precio de lista o de referencia, actualizado con menor frecuencia (unidades monetarias del conjunto de datos original).
- `num_orders`: cantidad de pedidos (variable dependiente, conteo semanal por centro-comida).
- `emailer_for_promotion`, `homepage_featured`: indicadores binarios de actividad promocional.
- `category`, `center_type`: variables categóricas para efectos fijos.

Tabla 1

Estadística descriptiva de las variables clave (antes de transformaciones).

	Precio final (`checkout_price`)	Precio base (`base_price`)	N. pedidos (`num_orders`)	Var. precio (`variacion_precio`)
Media	332,24	354,16	261,87	21,92
Desv. est.	152,94	160,72	395,92	48,50
Mínimo	2,97	55,35	13	−185, 30
P25	228,95	243,50	54	−1, 00
Mediana	296,82	310,46	136	1,00
P75	445,23	458,87	324	16,52
Máximo	866,27	866,27	24 299	561,60

Nota. $N = 456\,548$. `variacion_precio` = `base_price` − `checkout_price`. Valores positivos indican descuento; negativos, aumento sobre el precio de referencia. Fuente: elaboración propia.

La dispersión considerable de `num_orders` (desviación estándar 1,5 veces la media, máximo 24 299 vs. mediana 136) y su asimetría marcada a la derecha motivan la transformación logarítmica descrita en la sección Preparación y Limpieza de Datos. El precio final promedio (332,24 unidades monetarias del conjunto de datos) es inferior al precio base promedio (354,16 unidades monetarias del conjunto de datos), consistente con una prevalencia neta de descuentos, aunque –como se detalla en la siguiente sección– en 25,43 % de los casos el precio final superó a la referencia.

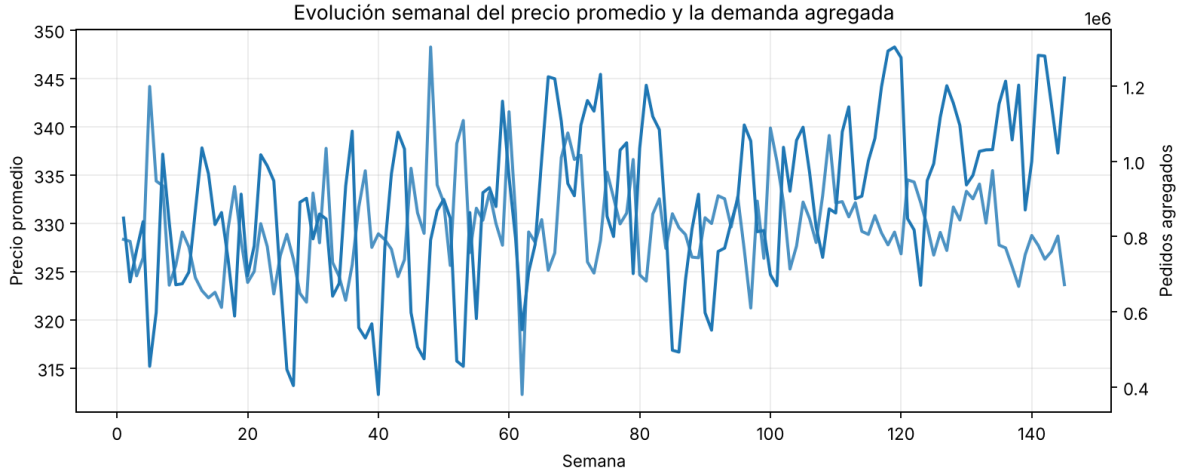


Figura 1

Evolución semanal del precio promedio de checkout y la demanda agregada (145 semanas). Muestra la dinámica temporal conjunta de precio y cantidad. Fuente: elaboración propia a partir de los datos de Kaggle/Genpact.

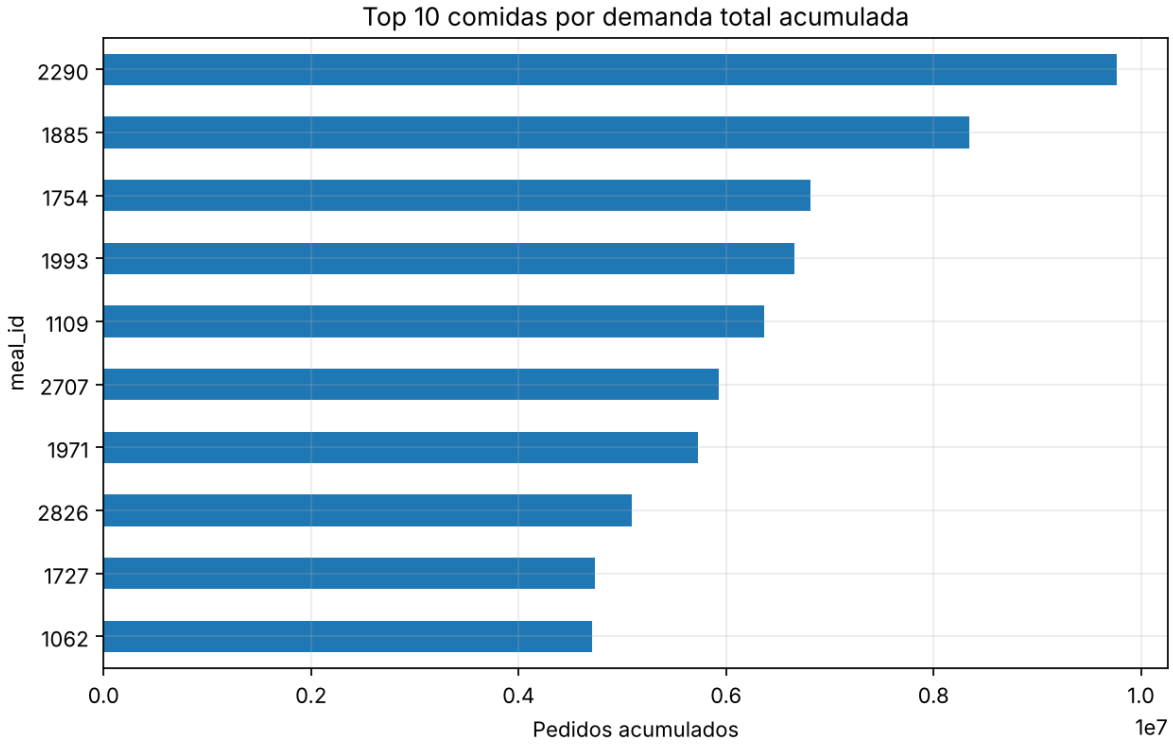


Figura 2

Top 10 comidas por demanda total acumulada (145 semanas). Muestra la concentración de la demanda en pocos productos estrella. Fuente: elaboración propia a partir de los datos de Kaggle/Genpact.

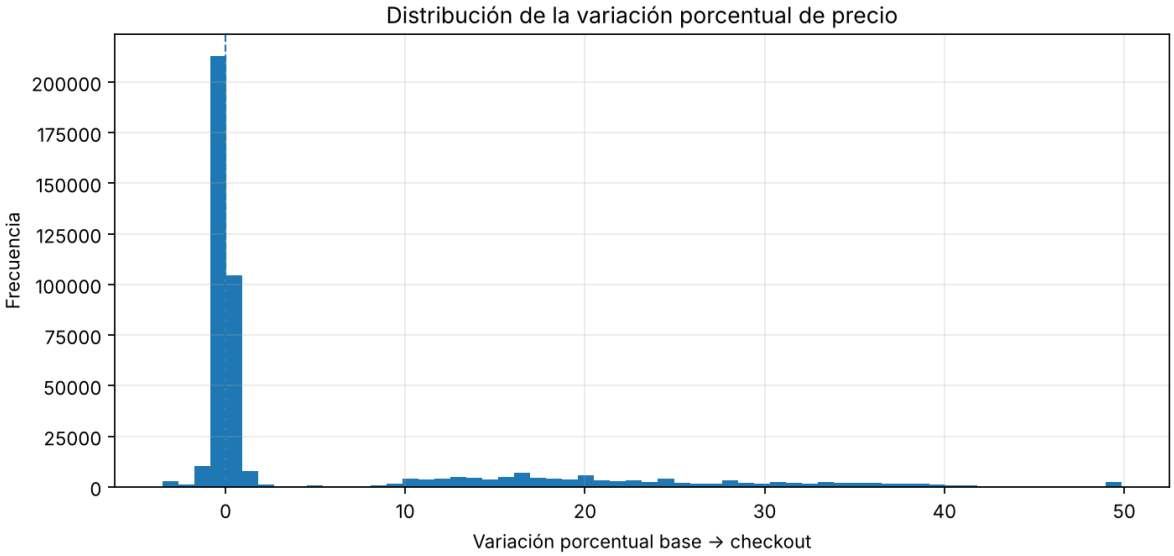


Figura 3

Distribución de la variación porcentual de precio (`base_price` → `checkout_price`). Positivo = descuento, Negativo = aumento. Media = 5,72 %, 25,43 % con aumento. Fuente: elaboración propia a partir de los datos de Kaggle/Genpact.

Preparación y Limpieza de Datos

El flujo reproducible de preparación sigue tres etapas secuenciales, implementadas en Python (`src/data_prep.py`) y diseñadas para ser totalmente reproducibles: (1) carga y unión de tablas, (2) construcción de variables derivadas de precio, (3) transformaciones logarítmicas para modelado. Cada etapa incluye aserciones de integridad.

Carga y unión de tablas

Las tres tablas se leen desde CSV y se unen mediante `meal_id` y `center_id` con *left join* usando `train` como tabla base:

```
train.merge(meal_info, on='meal_id', how='left') \
     .merge(centers, on='center_id', how='left')
```

Se verifica que el número de filas se mantenga idéntico al de `train` original (456 548), descartando duplicados en las tablas de referencia o pérdidas por claves no coincidentes. Tras el merge, no se detectan valores nulos en ninguna columna, lo que es consistente con que para cada combinación presente en `train` existe información completa en `meal_info` y `fulfilment_center_info`.

Construcción de variables de precio

El comportamiento observado de `base_price` es compatible con un precio de referencia administrativo, no con un piso garantizado. Al calcular la diferencia `base_price` − `checkout_price`, se esperaba encontrar únicamente valores positivos o cero (descuentos). Sin embargo, el hallazgo central de la limpieza fue que **en 25,43 % de las observaciones (116 101 de 456 548), `checkout_price` superó a `base_price`**, produciendo una variación negativa.

Este patrón se verificó exhaustivamente para descartar error de datos: (a) la magnitud de los valores negativos es variada y sustancial (decenas a cientos de unidades), no concentrada en montos fijos pequeños que sugerirían un cargo por servicio; (b) la incidencia está distribuida de forma pareja entre prácticamente todos los centros (del orden de 1 700–1 900 casos por centro entre los principales), descartando un error localizado en una fuente específica. La interpretación es que `base_price` es un precio de lista actualizado con menor frecuencia, mientras que `checkout_price` fluctúa semana a semana por dinámicas de costos, oferta/demanda o decisiones comerciales no observadas.

Se construyen tres variables derivadas:

- `variacion_precio` = `base_price` − `checkout_price` (diferencia absoluta; positiva = descuento, negativa = aumento).
- `variacion_precio_pct` = (`variacion_precio` / `base_price`) × 100 (variación porcentual respecto a la referencia).
- `hubo_aumento` = 1 si `variacion_precio` < 0, 0 en caso contrario (indicador binario de que el precio final superó la referencia).

La decisión de **no excluir** las observaciones con `hubo_aumento` = 1 es deliberada: excluir sistemáticamente los casos donde el precio subió introduciría sesgo de selección, dejando el modelo estimado solo sobre períodos de baja de precio, lo cual no representa el comportamiento real del mercado. La variable `hubo_aumento` se incluye como control candidato en las especificaciones del modelo (la sección Especificaciones del modelo) para capturar cualquier efecto asimétrico de aumentos vs. descuentos.

Transformaciones logarítmicas

Para la especificación log-log de elasticidad (la sección Especificaciones del modelo), se crean las versiones logarítmicas de precio y cantidad:

- `log_checkout_price` = ln(`checkout_price`)
- `log_num_orders` = ln(`num_orders`)

Dado que el mínimo observado de `num_orders` es 13 (no existen ceros en la muestra), el logaritmo natural ln(`num_orders`) está bien definido para todas las observaciones. El uso de ln(`num_orders`) en lugar de ln(1 + `num_orders`) garantiza que el coeficiente β_1 en la especificación log-log represente **exactamente** la elasticidad precio de la demanda: $\partial \ln Q / \partial \ln P = \beta_1$. La especificación log-log se justifica primariamente por su interpretación económica directa (elasticidad constante) y porque la distribución de `log_num_orders` se aproxima considerablemente a una forma de campana, lo que estabiliza la varianza y mejora las propiedades asintóticas; sin embargo, la heterocedasticidad residual se corrige mediante errores estándar robustos (HC3 y agrupado por entidad), no por la transformación logarítmica per se.

Estadísticos descriptivos completos (tras preparación)

Tabla 2 presenta los estadísticos descriptivos de todas las variables numéricas relevantes después de la preparación, incluyendo las transformaciones logarítmicas y las variables de precio derivadas.

Tabla 2

Estadísticos descriptivos completos tras preparación de datos.

Variable	Media	Desv. est.	Mínimo	P25	Mediana	P75	Máximo
`checkout_price`	332,24	152,94	2,97	228,95	296,82	445,23	866,27
`base_price`	354,16	160,72	55,35	243,50	310,46	458,87	866,27
`num_orders`	261,87	395,92	13,00	54,00	136,00	324,00	24 299,00
`variacion_precio`	21,92	48,50	−185, 30	−1, 00	1,00	16,52	561,60
`variacion_precio_pct`	5,72	11,36	−72, 79	−0, 15	0,14	6,24	99,06
`hubo_aumento`	0,2543	0,435	0,00	0,00	0,00	1,00	1,00
`log_checkout_price`	5,70	0,48	1,09	5,43	5,69	6,10	6,76
`log_num_orders`	4,87	1,22	2,56	3,99	4,91	5,78	10,10
`emailer_for_promotion`	0,081	0,273	0,00	0,00	0,00	0,00	1,00
`homepage_featured`	0,109	0,312	0,00	0,00	0,00	0,00	1,00

Nota. $N = 456\,548$. `hubo_aumento`, `emailer_for_promotion` y `homepage_featured` son binarias (0/1); su media reporta la proporción de unos. `variacion_precio_pct` en puntos porcentuales. Fuente: elaboración propia.

Observaciones destacadas de Tabla 2:

1. La proporción de observaciones con `hubo_aumento` = 1 es 0,2543 (25,43 %), lo que es consistente con la magnitud del hallazgo.
2. Las variables promocionales tienen prevalencia baja (`emailer_for_promotion`: 8,1 %; `homepage_featured`: 10,9 %), compatible con una utilización promocional de baja frecuencia.
3. `log_num_orders` tiene media 4,87 y desviación 1,22, con rango aproximado [2,56, 10,10], distribución sustancialmente más simétrica que la variable original.
4. `variacion_precio_pct` tiene media positiva (5,72 %), indicando que en promedio el precio final está por debajo de la referencia, pero con cola izquierda que llega a $-72,79$ % (aumentos sustanciales respecto al precio base).

El *DataFrame* final resultante (`demanda_limpia.csv`) contiene 456 548 filas y 20 columnas, listo para la etapa de modelado descrita a continuación.

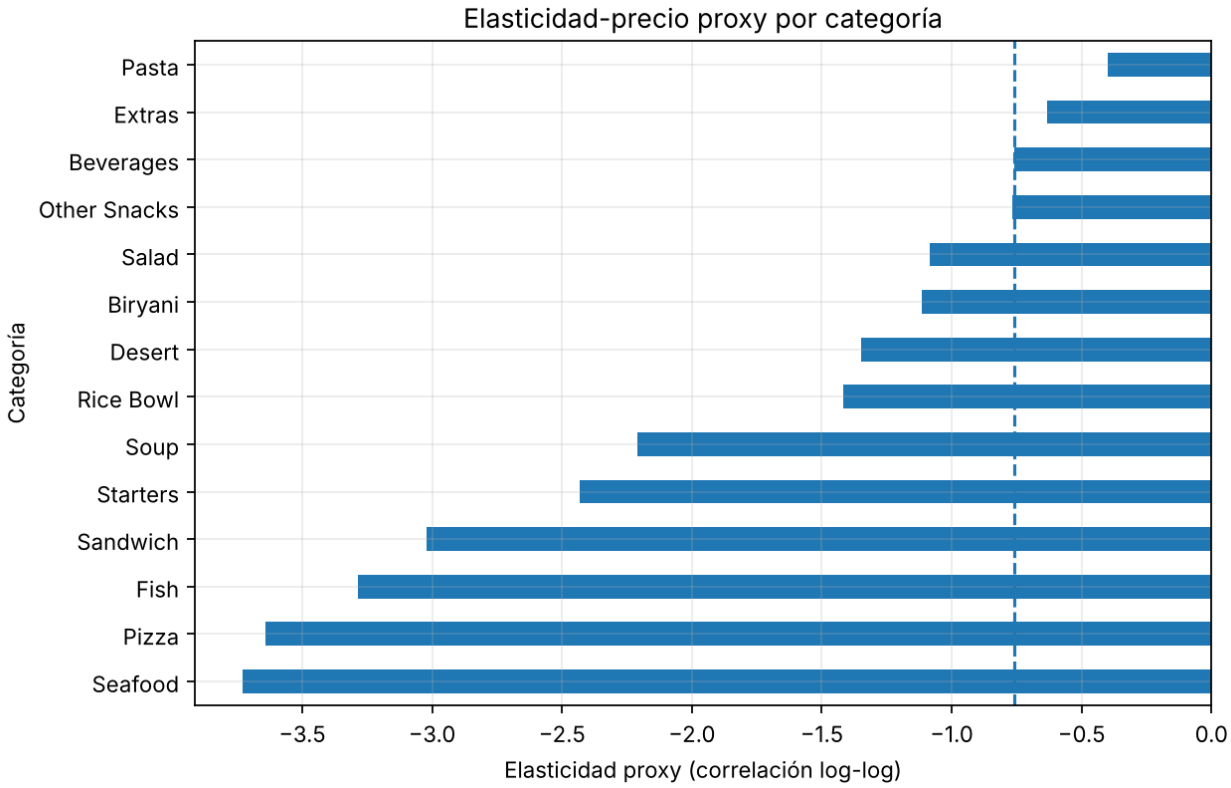


Figura 4

Elasticidad-precio proxy por categoría de comida (Correlación log-log entre `checkout_price` *y* `num_orders`*). Línea roja: elasticidad OLS principal (-0,759). Fuente: elaboración propia a partir de los datos de Kaggle/Genpact.*

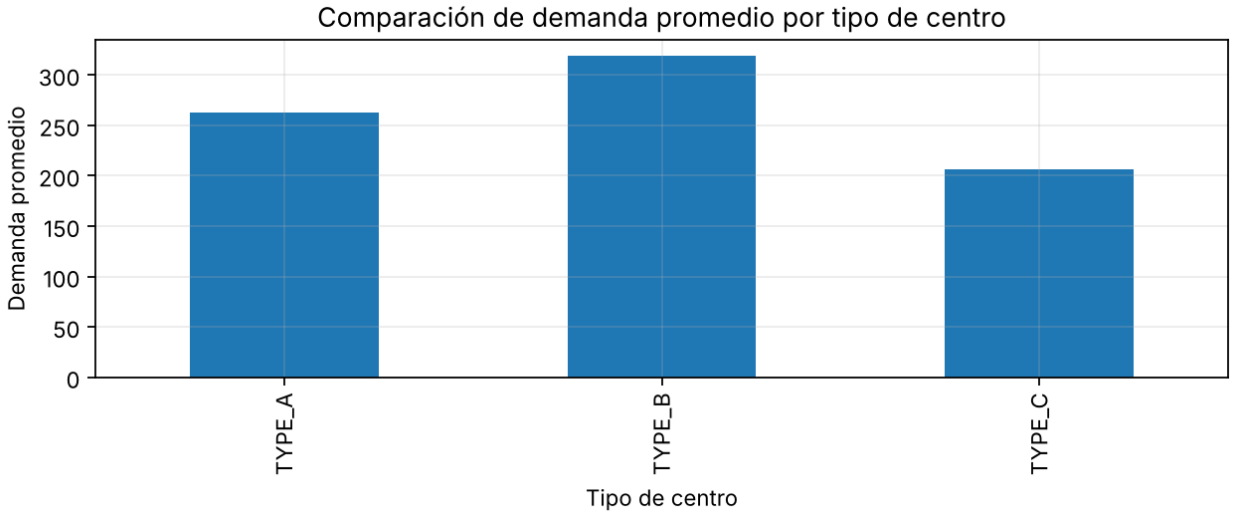


Figura 5

Comparación de demanda promedio por tipo de centro (TYPE_A, TYPE_B, TYPE_C). TYPE_B muestra mayor demanda relativa; TYPE_C, menor. Fuente: elaboración propia a partir de los datos de Kaggle/Genpact.

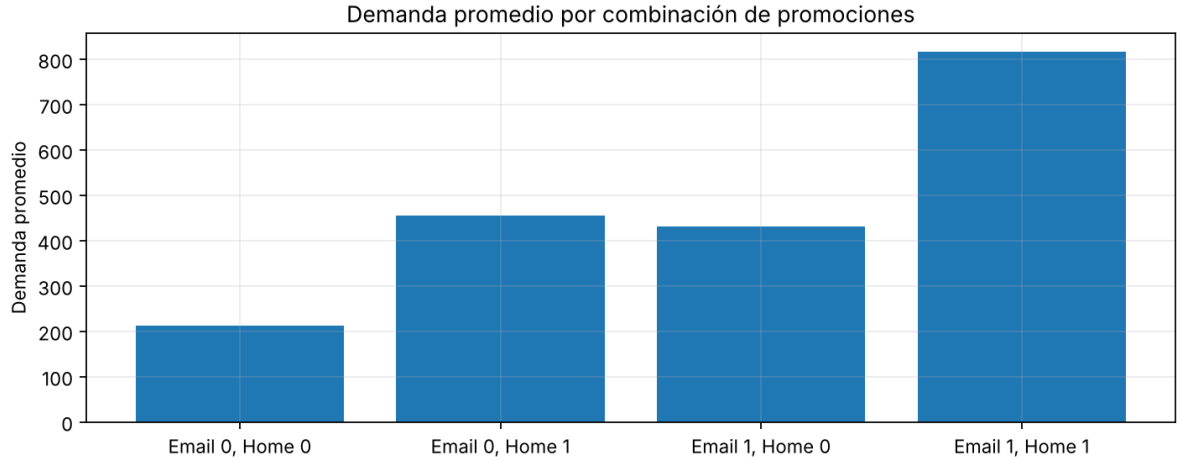


Figura 6

Matriz de efectos promocionales: demanda promedio por combinación de `emailer_for_promotion` *y* `homepage_featured`*. La exposición en homepage tiene mayor impacto marginal que el emailer. Fuente: elaboración propia a partir de los datos de Kaggle/Genpact.*

Marco Metodológico

El presente estudio adopta un enfoque econométrico basado en **mínimos cuadrados ordinarios (OLS)** sobre una especificación **log-log** para estimar la elasticidad precio de la demanda en un servicio de entrega de comidas. La variable dependiente es el logaritmo natural del número de órdenes (`log_num_orders`) y la variable explicativa principal es el logaritmo natural del precio de checkout (`log_checkout_price`).

$$\log(\text{num_orders}_i) = \beta_0 + \beta_1 \log(\text{checkout_price}_i) + \varepsilon_i \tag{1}$$

La elección de la especificación log-log obedece a su interpretación directa: el coeficiente β_1 representa la **elasticidad precio de la demanda**, es decir, el cambio porcentual en la cantidad demandada asociado a un cambio del 1 % en el precio. Una elasticidad negativa indica que la demanda responde inversamente al precio (ley de la demanda), mientras que su magnitud informa sobre la sensibilidad de los consumidores.

Justificación de variables de control

Para mitigar sesgos de variable omitida y estimar la asociación del precio sobre la demanda condicionada a controles observables, se incorporan controles que capturan factores de oferta y demanda observables:

- `emailer_for_promotion` (binaria): indica si la comida fue promocionada por correo electrónico. Las promociones aumentan la visibilidad y pueden desplazar la curva de demanda.
- `homepage_featured` (binaria): indica si la comida apareció destacada en la página principal. Al igual que el correo, afecta la exposición del producto.
- `hubo_aumento` (binaria): igual a 1 si el precio de checkout supera el precio base de referencia. Se utiliza como proxy exploratorio de posibles asimetrías asociadas al precio de referencia; su relación con la aversión a pérdidas constituye una motivación teórica, no una medida directa (Kahneman et al., 1991).
- `C(category)`: efectos fijos por categoría de comida (14 categorías; 13 dummies respecto de una categoría de referencia). Controla preferencias sistemáticas por tipo de comida.

- `C(center_type)`: efectos fijos por tipo de centro de cumplimiento (TYPE_A, TYPE_B, TYPE_C). Captura heterogeneidad operativa y geográfica no observada.

El conjunto de datos procesado contiene $N = 456\,548$ observaciones a nivel de comida-semana-centro, lo que confiere alta potencia estadística para detectar efectos incluso de magnitud pequeña.

Especificaciones del modelo

Se estiman tres especificaciones anidadas para evaluar robustez y comparar ajustes mediante criterios de información (AIC, BIC) y R^2 ajustado.

Modelo 1: especificación base (log-log simple)

$$\log(\text{num_orders}_i) = \beta_0 + \beta_1 \log(\text{checkout_price}_i) + \varepsilon_i \tag{2}$$

Modelo 2: log-log con controles (especificación principal)

$$\begin{aligned} \log(\text{num_orders}_i) = \beta_0 &+ \beta_1 \log(\text{checkout_price}_i) \\ &+ \beta_2 \text{emailer_for_promotion}_i + \beta_3 \text{homepage_featured}_i \\ &+ \beta_4 \text{hubo_aumento}_i \\ &+ \sum_{k=1}^{13} \gamma_k \mathbb{1}[\text{category}_i = k] \\ &+ \sum_{m=1}^{2} \delta_m \mathbb{1}[\text{center_type}_i = m] + \varepsilon_i \end{aligned} \tag{3}$$

Modelo 3: semi-log con controles (especificación alternativa)

$$\begin{aligned} \log(\text{num_orders}_i) = \beta_0 &+ \beta_1 \text{checkout_price}_i \\ &+ \beta_2 \text{emailer_for_promotion}_i + \beta_3 \text{homepage_featured}_i \\ &+ \beta_4 \text{hubo_aumento}_i \\ &+ \sum_{k=1}^{13} \gamma_k \mathbb{1}[\text{category}_i = k] \\ &+ \sum_{m=1}^{2} \delta_m \mathbb{1}[\text{center_type}_i = m] + \varepsilon_i \end{aligned} \tag{4}$$

En el Modelo 3, el coeficiente β_1 se interpreta como *semi-elasticidad*: el cambio porcentual en la demanda por cada unidad monetaria de aumento en el precio (no elasticidad constante). Tabla 3 resume las variables incluidas en cada especificación; los criterios de ajuste (AIC, BIC, R^2) se reportan y comparan en la sección Comparación de modelos, junto con los resultados.

Validación de supuestos: procedimiento

Para fundamentar la inferencia de OLS, se realizan diagnósticos de heterocedasticidad, multicolinealidad, distribución de residuos y dependencia serial. Los resultados numéricos de cada test se reportan en la sección Validación de supuestos: resultados; aquí se documenta el procedimiento y la decisión asociada a cada uno.

Tabla 3

Variables incluidas en cada especificación del modelo.

Variable	Modelo 1	Modelo 2	Modelo 3
log(checkout_price)	✓	✓	–
checkout_price (nivel)	–	–	✓
emailer_for_promotion	–	✓	✓
homepage_featured	–	✓	✓
hubo_aumento	–	✓	✓
C(category) (13 dummies)	–	✓	✓
C(center_type) (2 dummies)	–	✓	✓

- **Heterocedasticidad (Breusch-Pagan)**: H_0: varianza de los errores constante vs. H_1: varianza función de los regresores. De rechazarse H_0, se reportan errores estándar robustos **HC3**, válidos asintóticamente en muestras grandes (Davidson, 1994) y preferibles a HC0/HC1 cuando existe apalancamiento en los datos (Long & Ervin, 2000).
- **Multicolinealidad (VIF)**: calculado sobre las variables numéricas continuas del modelo (`log_checkout_price`, `emailer_for_promotion`, `homepage_featured`, `hubo_aumento`). Las dummies de efectos fijos se excluyen del cálculo porque su VIF individual dentro de un conjunto mutuamente excluyente no tiene interpretación estándar.
- **Normalidad de residuos (Jarque-Bera y Q-Q plot)**: H_0: residuos $\sim \mathcal{N}(0, \sigma^2)$. Con $N = 456\,548$ se anticipa que la prueba tenga potencia excesiva y rechace desviaciones mínimas sin relevancia práctica; por ello se complementa con inspección visual del gráfico Q-Q.
- **Autocorrelación (Durbin-Watson)**: *diagnóstico exploratorio de dependencia serial*; valores cercanos a 2 indican ausencia de autocorrelación. Dada la estructura de panel (semana × centro × comida), es esperable cierta autocorrelación residual en ausencia de efectos fijos por semana. **La inferencia final no descansa en DW sino en métodos de varianza/clustering apropiados para estructura panel** (errores agrupado por entidad y efectos fijos de dos vías).

Intervalos de confianza por bootstrap: procedimiento

Para obtener intervalos de confianza que no dependan de asunciones de normalidad ni de la estructura de covarianza analítica, se implementa un **procedimiento bootstrap no paramétrico por remuestreo con reemplazo** (en adelante, *bootstrap*) sobre el modelo base (Eq. (2)).

1. **Iteraciones**: $B = 1\,000$ remuestras bootstrap.
2. **Esquema de remuestreo**: muestreo con reemplazo de tamaño $n = N = 456\,548$, preservando la distribución empírica conjunta de todas las variables.
3. **Estimación por iteración**: en cada remuestra $b = 1, \ldots, B$, se ajusta el modelo base y se almacena el coeficiente $\hat{\beta}_1^{(b)}$.
4. **Intervalo de confianza**: percentil 2,5 y 97,5 de la distribución empírica $\{\hat{\beta}_1^{(b)}\}_{b=1}^{B}$.
5. **Reproducibilidad**: semilla fija `seed = 42` (`numpy.random.default_rng`).

El bootstrap se realizó sobre el modelo base por simplicidad computacional; los resultados numéricos se reportan en la sección Intervalos de confianza por bootstrap: resultados.

Resultados Principales

Comparación de modelos

Tabla 4 presenta los criterios de información y bondad de ajuste de las tres especificaciones descritas en la sección Especificaciones del modelo.

Tabla 4

Comparación de modelos alternativos: criterios de información y bondad de ajuste.

Modelo	AIC	BIC	R^2 ajustado	N
Semi-log con controles	1 125 017,90	1 125 239	0,5370	456 548
Log-log con controles	1 131 222	1 131 443	0,5307	456 548
Log-log base	1 406 573	1 406 595	0,1421	456 548

El modelo *semi-log* con controles presenta el menor AIC y BIC, y el mayor R^2 ajustado (0,5370), indicando un mejor ajuste **según estos criterios**. No obstante, el modelo *log-log* con controles ofrece la ventaja de una interpretación directa de la elasticidad-precio como el coeficiente del logaritmo del precio, manteniendo un R^2 ajustado muy similar (0,5307). Dado el objetivo central de este trabajo —estimar la elasticidad-precio de la demanda—, se selecciona el modelo *log-log* con controles como especificación principal.

Modelo principal: log-log con controles

Tabla 5 presenta los resultados completos del modelo *log-log* con controles. Dada la estructura de panel de los datos (observaciones repetidas por combinaciones centro-comida a lo largo de 145 semanas), la inferencia principal utiliza **errores estándar agrupados por entidad `center_id` × `meal_id`** (Cameron & Miller, 2015), que permiten correlación arbitraria dentro de cada entidad centro-comida. Los errores HC3 se reportan solo como referencia; no corrigen la autocorrelación intra-panel (Durbin-Watson = 1, 199).

Tabla 5

Resultados completos del modelo log-log con controles (variable dependiente: $\log($***`num_orders`***$)$*).* ***Inferencia principal: agrupado por entidad `center_id` × `meal_id`****. HC3 solo como referencia.*

Variable	Coef.	SE HC3	SE Agrupado	t (Agrupado)	p	IC 95 % (Agrupado)
Intercept	9,0977	0,029	0,236	38,51	$< 0,001$	[8,635, 9,561]
`C(category)[T.Biryani]`	−1,2627	0,006	0,045	−27,84	$< 0,001$	[−1,352, −1,174]
`C(category)[T.Desert]`	−0,7009	0,007	0,049	−14,44	$< 0,001$	[−0,796, −0,606]
`C(category)[T.Extras]`	0,1631	0,007	0,066	2,46	0,014	[0,033, 0,293]
`C(category)[T.Fish]`	−0,2640	0,010	0,063	−4,22	$< 0,001$	[−0,387, −0,141]
`C(category)[T.Other Snacks]`	−0,3593	0,006	0,052	−6,89	$< 0,001$	[−0,462, −0,257]
`C(category)[T.Pasta]`	−0,9400	0,006	0,046	−20,60	$< 0,001$	[−1,029, −0,851]
`C(category)[T.Pizza]`	0,4835	0,008	0,060	8,05	$< 0,001$	[0,366, 0,601]
`C(category)[T.Rice Bowl]`	1,2587	0,005	0,047	26,82	$< 0,001$	[1,167, 1,351]
`C(category)[T.Salad]`	0,8425	0,005	0,046	18,17	$< 0,001$	[0,752, 0,933]
`C(category)[T.Sandwich]`	0,9700	0,005	0,045	21,51	$< 0,001$	[0,882, 1,058]
`C(category)[T.Seafood]`	−0,3537	0,008	0,058	−6,13	$< 0,001$	[−0,467, −0,241]
`C(category)[T.Soup]`	−0,9329	0,007	0,058	−15,96	$< 0,001$	[−1,047, −0,818]
`C(category)[T.Starters]`	−0,2297	0,006	0,050	−4,61	$< 0,001$	[−0,327, −0,132]
`C(center_type)[T.TYPE_B]`	0,2844	0,003	0,030	9,49	$< 0,001$	[0,226, 0,343]
`C(center_type)[T.TYPE_C]`	−0,3583	0,003	0,027	−13,28	$< 0,001$	[−0,411, −0,305]
`log_checkout_price`	**−0,7590**	0,005	**0,0430**	−17,63	$< 0,001$	**[−0,843, −0,675]**
`emailer_for_promotion`	0,5071	0,005	0,014	36,25	$< 0,001$	[0,480, 0,535]
`homepage_featured`	0,6544	0,005	0,018	35,62	$< 0,001$	[0,618, 0,690]
`hubo_aumento`	−0,0027	0,003	0,005	−0,56	0,577	[−0,012, 0,007]

Nota: Los errores estándar agrupados son $\approx$ 8$\times$ mayores que los HC3 para `log_checkout_price` (0,0430 vs 0,0054), reflejando la dependencia intra-panel no capturada por HC3. El IC 95 % agrupado $[-0,843, -0,675]$ es la inferencia principal; el IC HC3 $[-0,770, -0,748]$ es considerablemente más estrecho y no incorpora la dependencia intra-panel.

Interpretación de la proyección log-log promedio. El coeficiente de `log_checkout_price` en la especificación log-log con controles es $-0,759$. La inferencia principal usa **errores estándar agrupados por entidad `center_id` × `meal_id`** (EE = 0,0430, IC 95 % $[-0,843, -0,675]$), coherentes con la estructura de panel; los EE HC3 (0,005, IC $[-0,770, -0,748]$) producen intervalos considerablemente más estrechos y no incorporan la dependencia intra-panel (DW = 1,199). Esto implica que un aumento del 1 % en el precio de checkout se asocia con una disminución promedio del 0,759 % en el número de órdenes, *ceteris paribus*, *bajo la imposición de una elasticidad constante*. La demanda resulta inelástica en promedio ($|\eta| < 1$), consistente con la literatura FAFH. **Advertencia:** los tests RESET ($F = 153,07$, $p \approx 3{,}5 \times 10^{-67}$) y la comparación anidada con RCS ($F = 3\,607,28$, 2 gl, $p \approx 0$) rechazan la restricción de elasticidad constante; bajo la RCS corregida, la elasticidad puntual varía aproximadamente de $+0,04$ en P5 a $-1,25$ en P95, con $-1,44$ en P50. Este contraste documenta no linealidad; no convierte la RCS en un estimador causal. Este valor es una *proyección promedio*, no una elasticidad estructural constante.

Comparación con modelos alternativos. Tabla 6 contrasta la elasticidad del modelo principal con las especificaciones alternativas.

Tabla 6

Comparación de elasticidades-precio entre especificaciones.

Especificación	Elasticidad	Nota
Log-log base (sin controles)	−0,9516	Diferencia asociada con la inclusión de controles observables; compatible con sesgo por variable omitida en la especificación sin controles
Semi-log con controles (eval. en media)	−1,0742	$\hat{\beta}_{\text{price}} \times \bar{P} = -0,003233 \times 332,24$
Log-log con controles (principal)	**−0,759**	**Proyección promedio; IC 95 % agrupado** $[-0,843, -0,675]$

El modelo base sobreestima la elasticidad en magnitud ($-0,9516$ vs. $-0,759$), compatible con sesgo por variable omitida al no controlar por categoría, tipo de centro y promociones. El modelo *semi-log* evaluado en la media del precio (332,24) produce una elasticidad equivalente de $-1,0742$, considerablemente más elástica. La diferencia radica en la forma funcional: el modelo *semi-log* impone una elasticidad que varía con el nivel de precio ($\eta = \beta \times P$), mientras que el *log-log* asume elasticidad constante. La elección del *log-log* se justifica por su interpretabilidad directa y por ser la especificación estándar en la literatura de demanda de alimentos preparados.

Validación de supuestos: resultados

Esta sección reporta los resultados numéricos de los tests descritos en la sección Validación de supuestos: procedimiento, aplicados a la especificación principal (*log-log* con controles).

Heterocedasticidad

Ambas versiones de la prueba rechazan rotundamente la hipótesis nula de homocedasticidad ($p < 0,001$). La presencia de heterocedasticidad invalida los errores estándar clásicos para inferencia, justificando el uso de errores estándar robustos HC3.

Tabla 7

Prueba de Breusch-Pagan para heterocedasticidad.

Estadístico	Valor	p-valor
Lagrange Multiplier (LM)	33 412,76	<0,001
F	1 897,35	<0,001

Tabla 8 compara los errores estándar clásicos (OLS) frente a los robustos HC3 para los coeficientes de interés principal.

Tabla 8

Comparación de errores estándar: clásico vs. HC3 (coeficientes clave).

Variable	EE Clásico	EE HC3	Ratio HC3/Clásico
Intercept	0,0248	0,0289	1,17
`log_checkout_price`	0,0047	0,0054	1,15
`emailer_for_promotion`	0,0052	0,0052	1,01
`homepage_featured`	0,0044	0,0046	1,06
`hubo_aumento`	0,0029	0,0029	0,99

Los errores estándar HC3 son iguales o mayores que los clásicos, reflejando la corrección por heterocedasticidad. El ratio máximo es 1,17 (intercepto); para la variable de interés principal (`log_checkout_price`) el EE HC3 es un 15 % mayor (0,0054 frente a 0,0047). Ninguno de los dos incorpora la dependencia intra-panel, que es la fuente dominante de incertidumbre (EE agrupado 0,0430).

Multicolinealidad

Tabla 9

Factores de Inflación de Varianza (VIF) — Modelo log-log con controles (especificación principal).

Variable	VIF
`log_checkout_price`	1,009
`emailer_for_promotion`	1,204
`homepage_featured`	1,188
`hubo_aumento`	1,029

Todos los VIF son sustancialmente inferiores a 5 (y a 10), indicando ausencia de multicolinealidad problemática. Los resultados son consistentes con ausencia de problemas relevantes de multicolinealidad.

Diagnóstico VIF — Modelo semi-log (especificación alternativa). Como comprobación adicional, se calculó el VIF para la especificación semi-log (`checkout_price` en nivel, no logaritmo). Los resultados para las variables continuas son: `checkout_price` = 1,007, `emailer_for_promotion` = 1,203, `homepage_featured` = 1,186, `hubo_aumento` = 1,029; la constante presenta VIF = 6,24 (esperado por la diferencia de escala entre `checkout_price` 332 y las binarias 0/1). No hay multicolinealidad problemática entre regresores continuos; la advertencia de *condition number* era efecto de escala, no colinealidad real.

Normalidad de los residuos

La prueba de Jarque-Bera rechaza la normalidad exacta ($p < 0,001$), con residuos que presentan ligera asimetría negativa ($-0,352$) y curtosis cercana a la normal (3,205 vs. 3,0 teórico). Con

Tabla 10

Prueba de normalidad (Jarque-Bera) y momentos de los residuos.

Estadístico	Valor
Jarque-Bera (JB)	10 254,09
p-valor	<0,001
Asimetría (skewness)	−0,352
Curtosis (kurtosis)	3,205

$N = 456\,548$, la prueba tiene poder excesivo para detectar desviaciones minúsculas sin relevancia práctica: el Teorema del Límite Central asegura que los estimadores MCO son asintóticamente normales, y los errores estándar HC3 son válidos sin normalidad exacta de los residuos. Esta misma advertencia aplica en general a los tests de este informe (VIF, RESET, Breusch-Pagan, igualdad de coeficientes): con $N = 456\,548$, un $p < 0,001$ generalizado no implica necesariamente relevancia económica, y la magnitud del efecto debe evaluarse junto con el p-valor, no en su lugar. Figura 7 muestra el gráfico Q-Q de los residuos, en el que se observan desviaciones moderadas de normalidad concentradas en las colas, más pronunciadas en la cola izquierda (casos donde el modelo sobreestimó la demanda real).

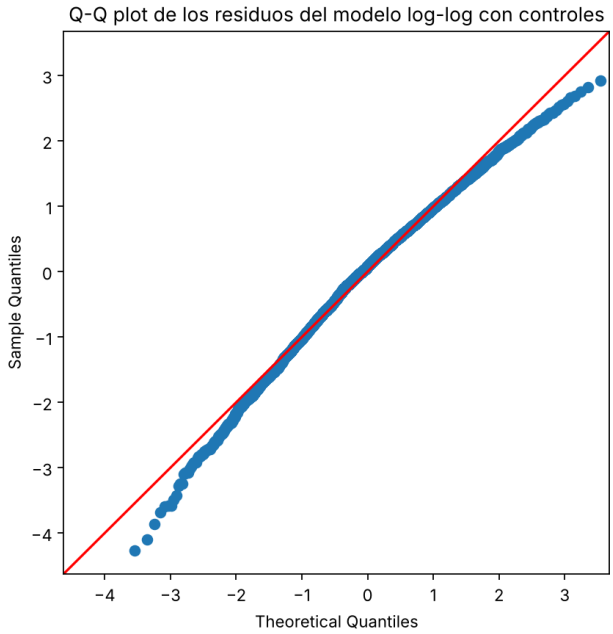


Figura 7

Gráfico Q-Q de residuos del modelo log-log con controles (especificación principal). Submuestra n=5 000 de 456 548. Fuente: elaboración propia.

Autocorrelación

El estadístico de Durbin-Watson para el modelo principal es $DW = 1,199$. **Como diagnóstico exploratorio de dependencia serial**, valores por debajo de 2 indican autocorrelación positiva moderada en los residuos. Esto es esperable en datos con estructura de panel (semana × centro × comida) sin efectos fijos por semana. Los errores estándar HC3 son robustos a heteroscedasticidad pero **no** a autocorrelación; la inferencia principal utiliza **errores estándar agrupados cluster (center_id × meal_id)** y el Panel FE de dos vías incorpora efectos fijos por semana que abordan directamente la dependencia temporal. Este diagnóstico no sustituye a los métodos de varianza apropiados para panel.

Intervalos de confianza por bootstrap: resultados

Tabla 11 presenta los resultados del bootstrap descrito en la sección Intervalos de confianza por bootstrap: procedimiento (1 000 replicaciones, semilla 42) sobre el modelo *log-log* base.

Tabla 11

Intervalo de confianza bootstrap (95 %) para la elasticidad precio (modelo base).

Estadístico	Valor
Elasticidad media (bootstrap)	$-0,9514$
Desviación estándar bootstrap	$0,0034$
IC 95 % inferior (percentil 2,5)	$-0,9578$
IC 95 % superior (percentil 97,5)	$-0,9450$
IC 95 % analítico (HC3, modelo base)	$[-0,958, -0,945]$

La distribución bootstrap de la elasticidad (Figura 8) es aproximadamente normal, centrada en $-0,9514$, muy próxima a la estimación MCO puntual del modelo base ($-0,9516$). El IC 95 % bootstrap $[-0,9578, -0,9450]$ (1 000 réplicas, semilla 42, `src/modeling.py::bootstrap_elasticidad`) coincide prácticamente con el IC analítico basado en HC3 $[-0,958, -0,945]$ del modelo base (EE HC3 $= 0,0034$). Sin embargo, este bootstrap i.i.d. remuestrea filas independientemente y no reproduce la dependencia panel ni el clustering del modelo principal. Por tanto, se utiliza únicamente como diagnóstico complementario y no como validación de la inferencia agrupada del modelo principal con controles.

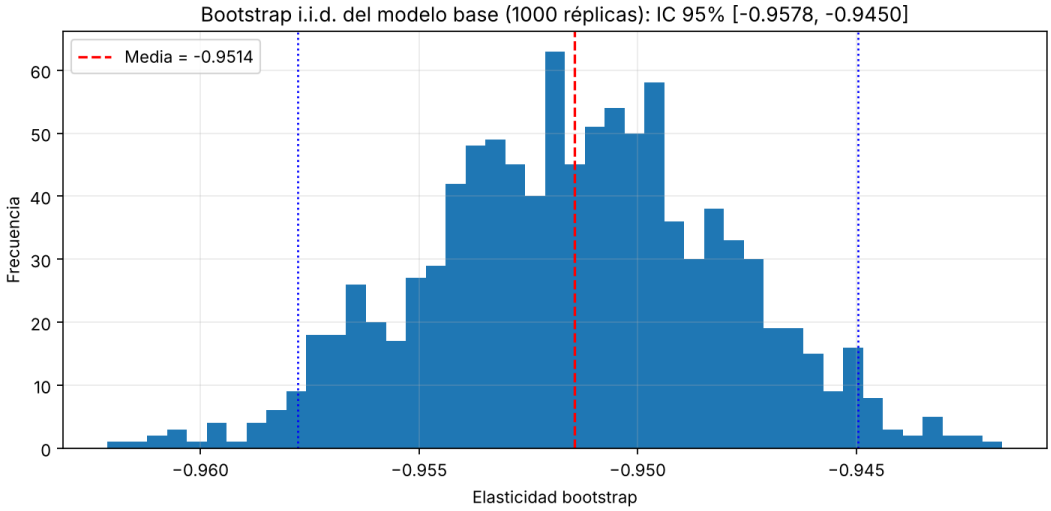


Figura 8

Distribución bootstrap de la elasticidad-precio (1 000 replicaciones). Línea roja: media bootstrap; líneas azules: IC 95 % percentil. Fuente: elaboración propia.

Nota de comparación con el modelo principal. El bootstrap se realizó sobre el modelo base (sin controles) por simplicidad computacional; su elasticidad ($-0,9516$) difiere de la del modelo principal con controles ($-0,759$) por el sesgo de variable omitida ya documentado en Tabla 6. No se ha ejecutado un bootstrap i.i.d. percentil equivalente sobre el modelo con controles; este procedimiento se distingue del Wild Cluster Bootstrap del modelo principal reportado en la sección de robustez.

Comparación con la Literatura

Tabla 12 presenta la síntesis de estudios de referencia, organizados en tres grupos: (A) elasticidad-precio de la demanda de comida fuera del hogar y delivery, directamente comparable en

definición de mercado; (B) un contexto afín (movilidad y comercio electrónico bajo demanda), útil como referencia contextual pero no directamente comparable en métrica; y (C) soporte metodológico y de mercado. Cada fuente fue verificada contra el artículo, *working paper* o abstract original antes de incluirse. Figura 9 ilustra los estimadores puntuales disponibles de los Grupos A y B.

Tabla 12

Comparación de elasticidades-precio de la demanda: estudios de referencia y presente trabajo.

Estudio	Fuente	Elasticidad	Método	Contexto
Grupo A — Directamente comparable (comida fuera del hogar / entrega de comidas)				
Andreyeva et al. (2010)	*Am. J. Public Health*, 100(2)	$-0,81$[†]	Meta-análisis (160 est.)	FAFH, mayormente EE. UU.
Damayanti et al. (2023)	*Econ. & Finance in Indonesia*, 69(1)	$-0,920$	LA/AIDS, panel hogar-año	Indonesia, Susenas 2011–2013 ($n = 24\,376$)
Bumagat y Ibana (2025)	ResearchGate (doc. educativo, no arbitrado)[‡]	$-0,42$ pico / $-1,36$ fuera de pico	Comparativo pico/no pico	Delivery de comida, Metro Manila, Filipinas
Presente estudio	—	**−0,759**	**OLS log-log con controles**	**Conjunto de datos transaccional Kaggle/Genpact,** $N = 456\,548$
Grupo B — Contextual (movilidad/e-commerce on-demand, no directamente comparable)				
Christensen y Osman (2021)	IZA DP 14179	$-0,84$ (mov. total)[§]	Experimental (2SLS)	El Cairo, Egipto (Uber)
Christensen et al. (2023)	NBER WP 31330 (rev.)	+49 % mov. total ante −50 % de precio[¶]	Experimental	El Cairo, Egipto (Uber, rev.)
Zhang y Demirkan (2021)	*Inform. & Manag.*, 58(4)	$-0,87$ online / $-1,74$ offline	Estructural (discrete choice)	CPG online vs. offline, EE. UU.
Sriwongphanawes y Fukuda (2024)	*Asian Transp. Stud.*, 10	$-0,15$ $[-0,20, -0,10]$	Mixed logit	Uber Japón (Nagoya, Kyoto)

[†] Valor puntual reportado para comida fuera del hogar (FAFH); rango general del meta-análisis 0,27–0,81 según categoría. [‡] Documento educativo alojado en ResearchGate (Bumagat & Ibana, 2025), no publicado en revista arbitrada; se incluye por reportar coeficientes cuantitativos de delivery de comida, pero debe leerse con cautela metodológica adicional frente a las fuentes con revisión por pares. Atribuyen la brecha pico/no pico a diferencias en percepción del consumidor ("impuesto a la urgencia" vs. "tarifa a la pereza") y al concepto cultural filipino de *sulit* (valor por el dinero). [§] Elasticidad promedio de la movilidad total (km/semana) ante el precio de Uber (pp. 1–2); la elasticidad de los kilómetros en vehículo privado (VKT) es $-1,28$ (p. 20). No es de entrega de comida. [¶] El resumen de la versión revisada reporta efectos, no una elasticidad puntual: un descuento del 50 % más que cuadruplica el uso de Uber y aumenta la movilidad total en casi 49 %. No se grafica en la Figura 9. FAFH = *food away from home*; LA/AIDS = *Linear Almost Ideal Demand System*; CPG = *consumer packaged goods*; VKT = *vehicle kilometers traveled*. **Nota.** Li y Wang (2025) (*Management Science*, 71(7)) es consistente con la escasez de estudios empíricos previos sobre elasticidad en plataformas de delivery bajo demanda, sin reportar coeficiente propio. Zhang & Demirkan (2021) y Sriwongphanawes & Fukuda (2024) se incluyen en el Grupo B tras confirmar autor/año/coeficiente/journal correctos. Fuente: elaboración propia.

Inferencia RCS por bootstrap. La curva puntual y las bandas de confianza se reestimaron en la VM bajo la misma parametrización RCS corregida, con nudos explícitos P5/P35/P65/P95, 77 clusters y 2 000 replicaciones válidas. La Figura 12 muestra intervalos percentiles del 95 % punto a punto (no simultáneos). En P5 (precio = $121,28$), la media bootstrap es $+0,032$ y el IC es $[-0,101; 0,160]$; cerca de P50 (precio = $296,82$), la media es $-1,440$ con IC $[-1,598; -1,277]$; en P95 (precio = $640,23$), la media es $-1,252$ con IC $[-1,365; -1,138]$. La banda bootstrap se interpreta como inferencia puntual sobre la curva RCS y no como intervalo simultáneo para toda la función.

Discusión de la comparación

El estimador central del presente estudio ($-0,759$) se ubica ligeramente por debajo, en valor absoluto, del valor puntual reportado por Andreyeva et al. (2010) ($-0,81$ para FAFH) y de

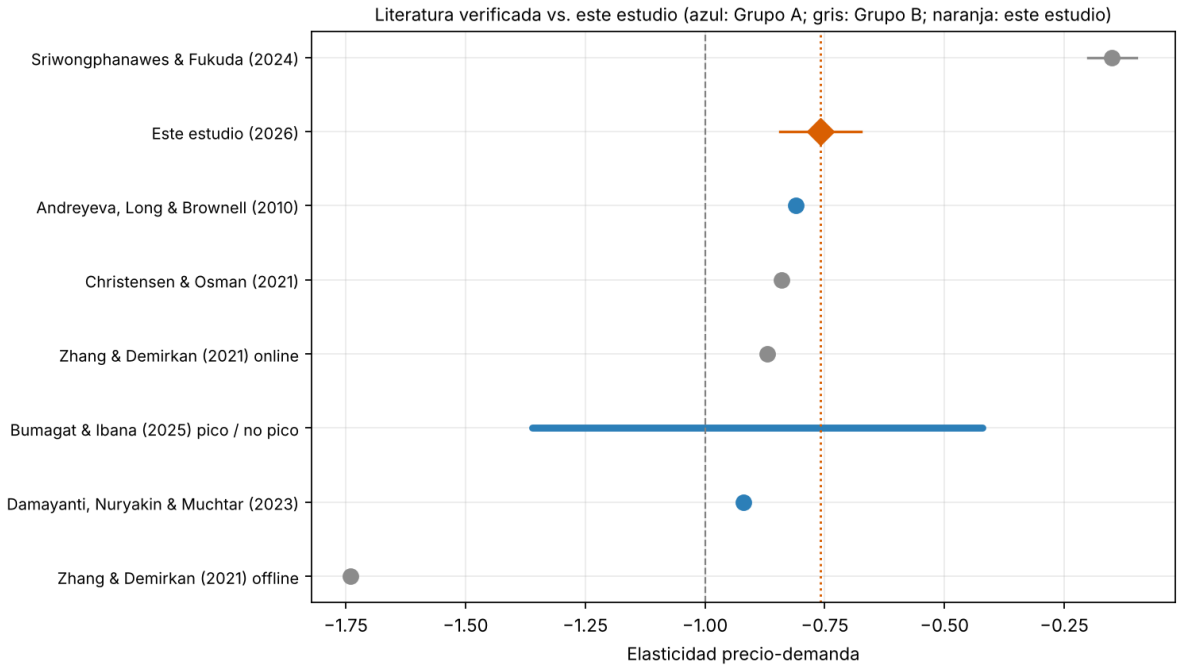


Figura 9

Comparación de estimadores de elasticidad-precio disponibles en la literatura verificada. Grupo A (azul): estudios de demanda de comida/delivery directamente comparables; Grupo B (gris): contexto afín con métrica distinta (Christensen & Osman 2021, movilidad total; Zhang & Demirkan 2021, canal online y offline; Sriwongphanawes & Fukuda 2024, punto medio y rango). El rombo naranja marca el estimador del presente estudio ($-0,759$, *IC* $[-0,843, -0,675]$*). Bumagat & Ibana (2025) se grafican como segmento pico–no pico (documento no arbitrado). Li & Wang (2025) y Christensen et al. (2023) no se grafican por no reportar una elasticidad puntual.* ***Advertencia:*** *los estimadores no son estrictamente comparables (distintas definiciones de mercado, especificaciones y muestras).*

la estimación específica de Indonesia de Damayanti et al. (2023) ($-0,920$) para comida fuera del hogar. La magnitud es consistente: las tres estimaciones caen en un rango de elasticidad cercana a la unitaria, ligeramente inelástica a moderadamente elástica. Una explicación plausible para que la entrega de comidas resulte marginalmente menos sensible al precio que la comida fuera del hogar en general es que la entrega incorpora un componente de conveniencia (ahorro de tiempo, evitar desplazamiento) que puede atenuar la sensibilidad al precio frente a la decisión más amplia de "comer fuera de casa".

Diferencias metodológicas explican en parte la brecha con Damayanti et al. (2023): la especificación LA/AIDS impone restricciones de aditividad y simetría que pueden magnificar la sensibilidad al precio estimada en datos de panel agregado, y el contexto indonesio (mayor proporción de gasto en comida, menor penetración de plataformas digitales) implica una dinámica de sustitución distinta a la de un mercado de entrega de comidas ya consolidado.

El hallazgo más directamente comparable proviene de Bumagat y Ibana (2025): al desagregar por franja horaria en entrega de comida de Metro Manila, reportan $-0,42$ en horas pico (inelástica, consistente con el $-0,759$ agregado de este estudio) y $-1,36$ fuera de pico (elástica). El promedio aritmético ilustrativo de ambas franjas ($-0,89$) se ubica cerca del resultado de Damayanti et al. (2023). Esta heterogeneidad temporal no está modelada en la especificación transversal principal de este trabajo (que agrega las 145 semanas sin distinguir franja horaria dentro de cada semana, dato que el conjunto de datos Kaggle/Genpact no captura), y queda como línea de trabajo futuro explícita (la sección Limitaciones y Trabajo Futuro). Cabe la salvedad metodológica de que Bumagat y Ibana (2025) es un documento educativo no arbitrado, por lo que su comparabilidad formal con las fuentes revisadas por pares de esta tabla es menor.

Dentro del Grupo B, el espectro es amplio: desde alta inelasticidad en *ride-hailing* japonés

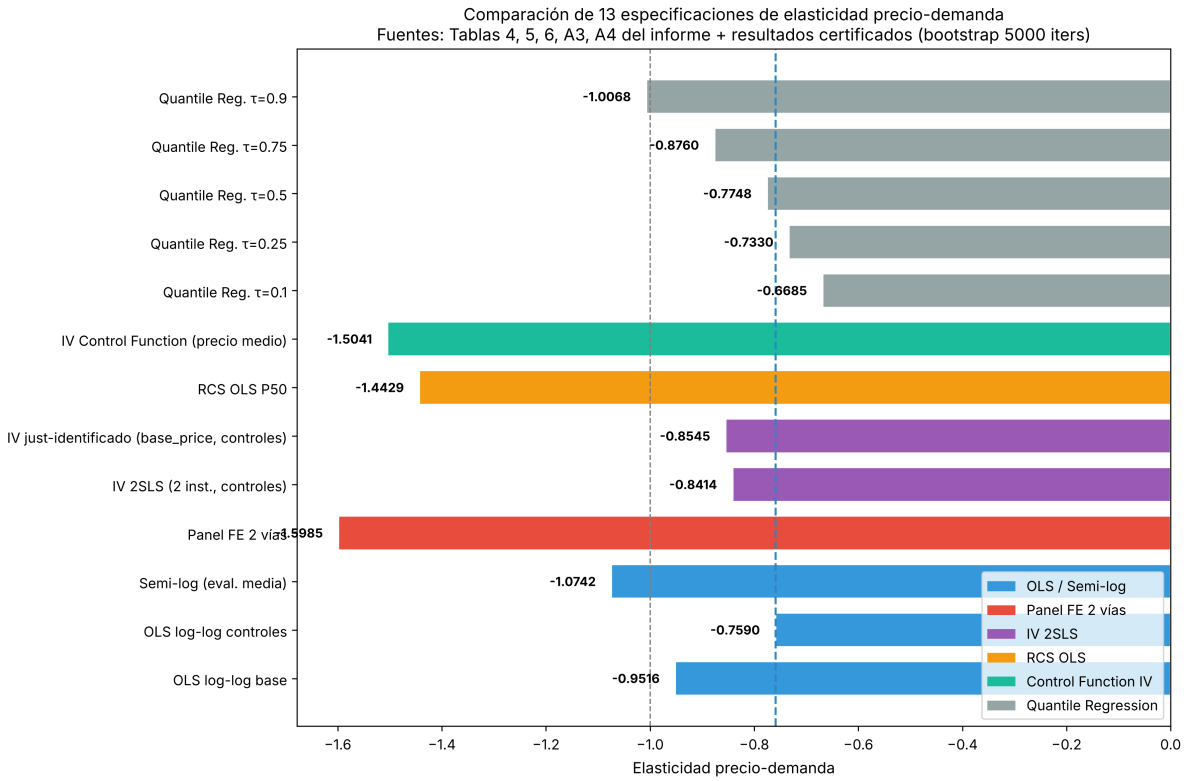


Figura 10

Comparación de estimadores de elasticidad: 13 especificaciones del proyecto (OLS base, OLS con controles, Semi-log, Panel FE, IV 2SLS, IV justamente identificado, RCS OLS, IV Control Function y cinco regresiones cuantiles). Línea punteada gris: elasticidad unitaria (-1). Línea punteada naranja: OLS principal (-0,759).

(Sriwongphanawes & Fukuda, 2024, $-0,15$ como punto medio de su rango reportado $[-0,20, -0,10]$) hasta mayor elasticidad en el experimento de El Cairo (Christensen & Osman, 2021: $-0,84$ para la movilidad total y $-1,28$ para kilómetros en vehículo privado; la versión revisada, Christensen et al., 2023, reporta un aumento de casi 49 % de la movilidad total ante un descuento de 50 %). El resultado propio se aproxima más al comercio electrónico de Zhang y Demirkan (2021) ($-0,87$ en el canal online) que al *ride-hailing* o a la movilidad en Uber, lo cual es razonable dado que la entrega de comidas comparte con el e-commerce la fricción de búsqueda y comparación digital de precios, mientras que la movilidad y el *ride-hailing* responden a necesidades de desplazamiento con sustitutos distintos (transporte público, vehículo propio). El hallazgo de Li y Wang (2025) es el más relevante para contextualizar la contribución de este estudio: en *Management Science*, los propios autores **señalan** que la literatura empírica sobre plataformas de delivery bajo demanda específicamente es escasa, lo que respalda que este proyecto aporta una estimación poco común en el tipo de dato (transaccional real) utilizado.

Advertencia metodológica. Esta comparación es exploratoria, no un meta-análisis formal. Existen diferencias relevantes entre estudios en definición de mercado, método de estimación, frecuencia de datos, contexto geográfico y nivel de revisión por pares (una de las fuentes del Grupo A es un documento educativo no arbitrado) que impiden una comparación estricta "igual a igual". Su valor es situar el hallazgo propio dentro de un rango razonable de la evidencia empírica disponible, no establecer equivalencia causal entre estudios.

Especificación flexible: splines RCS en log-precio

La especificación log-log asume elasticidad constante, lo cual puede ser restrictivo. Para testear no-linealidad, se estimó un modelo con *splines cúbicos restringidos* (*Restricted Cubic Spli-*

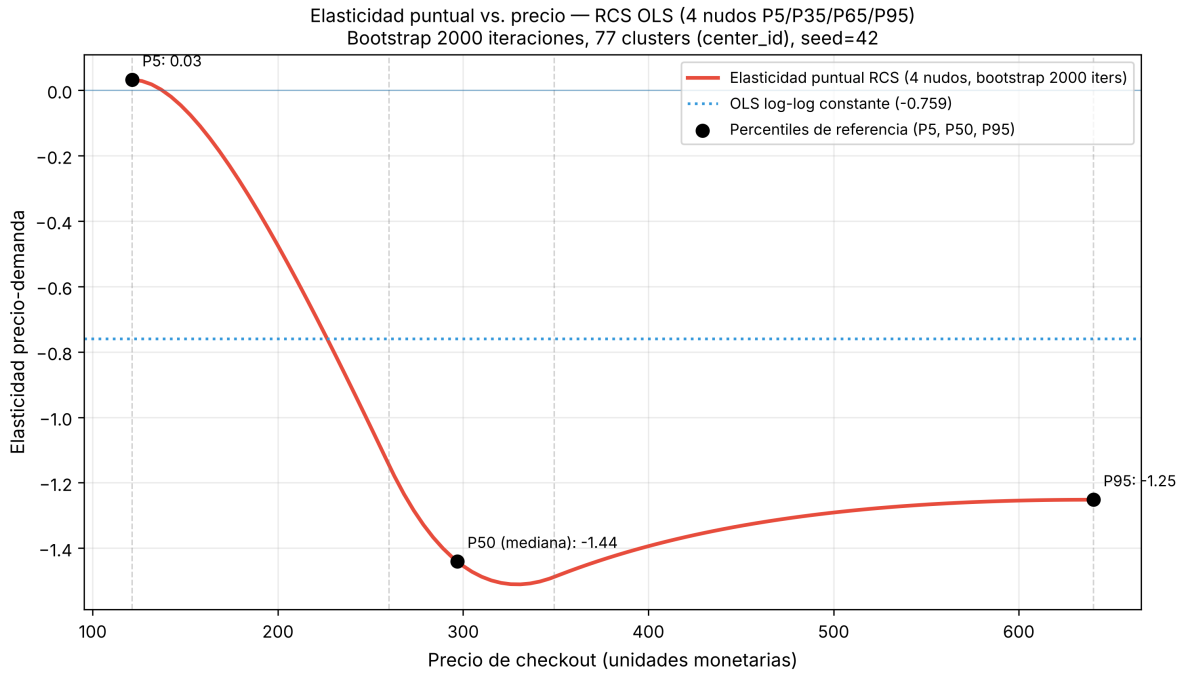


Figura 11

Elasticidad puntual estimada mediante RCS con cuatro nudos explícitos en P5/P35/P65/P95 de log-precio, evaluada a lo largo de la distribución observada. Línea punteada naranja: elasticidad log-log constante ($-0,759$)*. La curva no es monótona:* $+0,04$ *en P5 (precio* $= 121,28$*),* $-1,44$ *en la mediana (P50, precio* $= 296,82$*), un mínimo de* $\approx -1,51$ *cerca de precio* ≈ 329 *(próximo al precio medio, 332,24) y* $-1,25$ *en P95 (precio* $= 640,23$*). El contraste F anidado frente al modelo log-log con controles es* $F = 3\,607,28$ *(2 gl.,* $p \approx 0$*).*

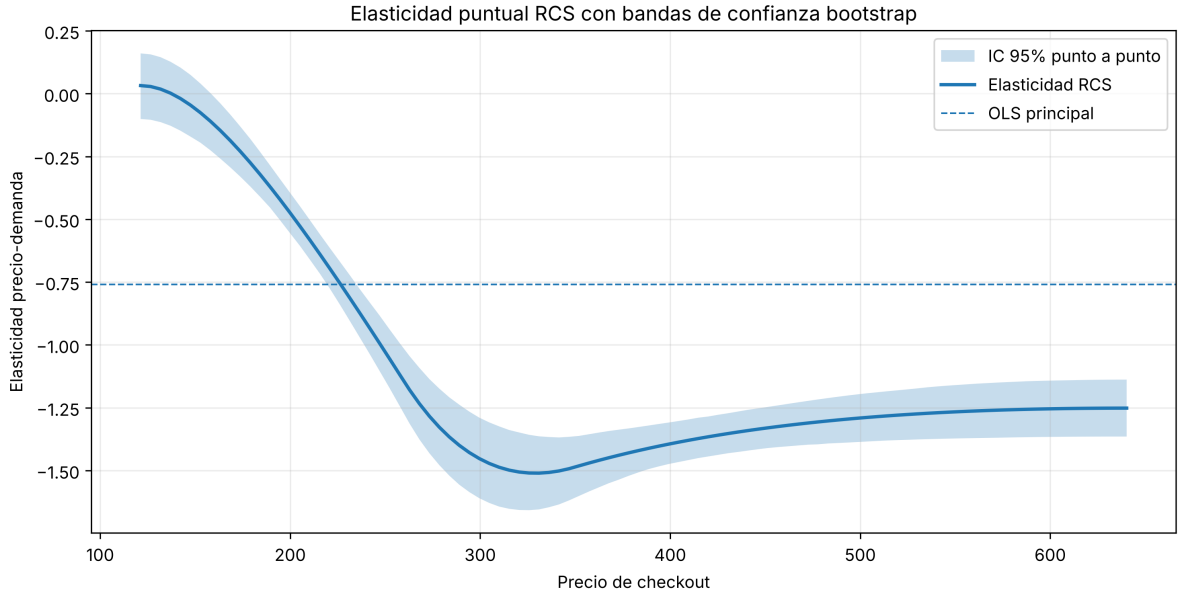


Figura 12

Elasticidad puntual RCS y banda de confianza bootstrap percentil del 95 % punto a punto. La banda se obtiene mediante 2 000 replicaciones clusterizadas por centro, reestimando la curva RCS con nudos explícitos P5/P35/P65/P95. Los intervalos son puntuales y no simultáneos. Línea naranja: proyección OLS log-log constante ($-0,759$)*; línea horizontal discontinua: elasticidad unitaria* (-1)*.*

nes, RCS) en `log_checkout_price` con 4 nudos ubicados en los percentiles 5, 35, 65 y 95 de la distribución de log-precio.

El contraste F anidado entre la especificación log-log con controles y la RCS rechaza la restricción de elasticidad constante ($F = 3\,607,28$, 2 g.l., $p \approx 0$). La Figura 11 muestra una elasticidad puntual que varía con el precio de forma no monótona: $+0,04$ en P5 (precio $= 121,28$), $-1,44$ en P50 (precio $= 296,82$), un mínimo de $\approx -1,51$ cerca del precio medio ($\approx$ 329–332) y $-1,25$ en P95 (precio $= 640,23$). El modelo log-log constante ($-0,759$) resume una relación que presenta curvatura y heterogeneidad de magnitud a lo largo de la distribución de precios.

El modelo RCS corregido alcanza R^2 ajustado $= 0,53795$ y AIC $= 1\,124\,067,47$, inferior al AIC del semi-log con controles ($1\,125\,017,90$). La mejora de ajuste se interpreta conjuntamente con el contraste de no-linealidad y no constituye evidencia de una forma funcional causalmente superior.

Nota sobre estabilidad numérica. La parametrización corregida utiliza cuatro nudos explícitos P5/P35/P65/P95, tres funciones base independientes y el intercepto del modelo. La matriz de regresores presenta un número de condición de aproximadamente $24,5$, sin la colinealidad exacta introducida por duplicar la constante. Esta parametrización es numéricamente estable para la estimación puntual de la curva.

Discusión

Interpretación de la elasticidad-precio

La elasticidad estimada de $-0,759$ (IC 95 % agrupado $[-0,843; -0,675]$) indica que la demanda en la plataforma es **inelástica al precio**: un aumento del 1 % en el precio de *checkout* reduce la cantidad demandada en aproximadamente 0,76 %. En términos de ingreso, esto implica que incrementos moderados de precio tienden a aumentar el ingreso total registrado en el conjunto de datos (pues $\%\Delta Q < \%\Delta P$), sujeto a las limitaciones de identificación causal discutidas en la sección Limitaciones y Trabajo Futuro. La amplitud del intervalo de confianza principal (aproximadamente 0,168) refleja la incertidumbre real al considerar la dependencia intra-panel, validada por errores estándar agrupados `center_id` × `meal_id`.

Asociaciones de las variables de control

Los coeficientes de control del modelo principal (Tabla 5) muestran heterogeneidad sustancial:

- **Promoción por correo (`emailer_for_promotion`)**: coeficiente $+0,5071$ ($p < 0,001$), equivalente a una asociación aproximada del +66 % en el número de pedidos ($e^{0,5071} - 1$) cuando hay promoción activa, *ceteris paribus*.
- **Exposición en *homepage* (`homepage_featured`)**: coeficiente $+0,6544$ ($p < 0,001$), asociada con $\approx 92\,\%$ más pedidos ($e^{0,6544} - 1$). Subraya la importancia de la visibilidad dentro de la plataforma.
- **Aumento respecto al precio de referencia (`hubo_aumento`)**: coeficiente $-0,0027$, **no significativo** ($p = 0,577$, EE agrupado por entidad). El hecho de que el precio final supere al precio de referencia no tiene, por sí solo, un efecto adicional sobre la demanda más allá del nivel de precio ya capturado por `log_checkout_price`.
- **Categoría de comida (efectos fijos)**: dispersión amplia, desde `Rice Bowl` ($+1,2587$, la de mayor demanda relativa) hasta `Biryani` ($-1,2627$, la de menor demanda relativa), frente a la categoría de referencia.
- **Tipo de centro (`center_type`)**: TYPE_B muestra $+0,2844$ frente a TYPE_A (categoría de referencia); TYPE_C muestra $-0,3583$.

La heterogeneidad por categoría y tipo de centro sugiere que estrategias de fijación de precios y *merchandising* diferenciadas por producto y por tipo de centro podrían generar mejoras adicionales en el desempeño comercial, aunque esa hipótesis no se prueba formalmente en este trabajo.

Limitaciones causales

El coeficiente de $-0,759$ (OLS con controles) debe interpretarse como una **asociación robusta y consistente estadísticamente**, no como un efecto causal identificado con el rigor de un diseño experimental. Se documentan tres limitaciones principales:

1. **Posible simultaneidad precio-demanda**: los precios no fueron asignados aleatoriamente; es posible que respondan, al menos parcialmente, a la demanda anticipada.
2. **Variables omitidas no capturadas en el conjunto de datos**: gasto en marketing externo, estacionalidad exacta (solo se observa número de semana, no fecha calendario), eventos locales, clima, calificación o reputación del centro/comida.
3. **Ausencia de efectos fijos por semana en la especificación actual**: la especificación principal incluye efectos fijos por categoría y por tipo de centro, pero no por semana, lo que puede dejar sin capturar tendencias temporales comunes a todos los centros.

Estas limitaciones se abordan de forma explícita en las secciones adicionales del informe: el panel con efectos fijos de dos vías controla la heterogeneidad no observada por entidad y tiempo; las variables instrumentales atienden la simultaneidad precio-demanda; y la validación completa se repite sobre cada especificación.

Robustez de la especificación

Las siguientes verificaciones de robustez sí se ejecutaron sobre los datos reales del proyecto:

- **Especificación semi-log**: produce una elasticidad implícita en la media de $-1,0742$, mayor en valor absoluto que la especificación log-log principal ($-0,759$), reflejando que la forma funcional semi-log impone una elasticidad que varía con el nivel de precio.
- **Comparación log-log base vs. con controles**: la inclusión de controles reduce la elasticidad estimada de $-0,9516$ a $-0,759$, compatible con sesgo por variable omitida en la especificación sin controles.
- **Multicolinealidad**: VIF máximo de 1,204 (Tabla 9), muy por debajo de cualquier umbral de preocupación.
- **Errores estándar HC3 vs. clásicos**: cambios menores al 25 % en todos los coeficientes de interés (Tabla 8), indicando que la heterocedasticidad detectada no altera materialmente las conclusiones de significancia.

Resultados complementarios: Panel FE, IV 2SLS y validación completa

Las siguientes estimaciones se ejecutaron completamente con resultados reales sobre los datos del proyecto. Cada especificación incluye su propia validación de supuestos.

Panel con efectos fijos de dos vías

Se estimó un modelo de panel con efectos fijos de dos vías usando `linearmodels.PanelOLS`: efectos fijos por entidad (combinación `center_id` × `meal_id`, 3 597 entidades) y efectos fijos por tiempo (semana, 145 periodos), con errores estándar agrupados por entidad. La especificación estructural es:

$$\log(\text{num_orders}_{it}) = \beta_1 \log(\text{checkout_price}_{it}) + \beta_2 \text{emailer}_{it} + \beta_3 \text{homepage}_{it} + \alpha_i + \lambda_t + \varepsilon_{it} \quad (5)$$

donde α_i son los efectos fijos de entidad (centro-comida) y λ_t los de tiempo (semana).

La elasticidad panel FE ($-1,5985$) es considerablemente mayor en magnitud que la OLS con controles ($-0,759$). Esto indica que, al controlar por la heterogeneidad no observada específica de cada combinación centro-comida y por tendencias temporales comunes, la respuesta de la demanda al precio es más elástica. El test de *poolability* rechaza rotundamente la homogeneidad entre entidades ($p < 0,001$), lo que sugiere la necesidad de efectos fijos.

Tabla 13

Resultados del modelo panel con efectos fijos de dos vías.

Parámetro	Estimación	EE Clusterizado	p-valor
log(checkout_price)	$-1,5985$	0,0239	$< 0,001$
emailer_for_promotion	0,4847	0,0071	$< 0,001$
homepage_featured	0,4026	0,0063	$< 0,001$

Nota. $N = 456\,548$; Entidades $= 3\,597$; Periodos $= 145$; R^2 within $=$ 0,3215; F-test poolability $= 411,15$ ($p < 0,001$). Fuente: elaboración propia.

Bootstrap clusterizado (por centro, referencia histórica): En una versión anterior, como robustez adicional, se ejecutó un bootstrap remuestreando 77 centros completos con reemplazo ($B = 200$ iteraciones, manteniendo toda la estructura de dependencia intra-centro). La elasticidad media fue $-1,5944$ (DE $= 0,0278$, IC 95 % normal $[-1,6489, -1,5399]$), consistente con la estimación analítica ($-1,5985$). Todas las 200 iteraciones fueron válidas. **Nota:** Este bootstrap simple por centro no captura correctamente la dependencia cruzada entidad-tiempo; ha sido superado por el pairs bootstrap (1000 iteraciones, media $-1,5992$, IC $[-1,6506, -1,5455]$), ver Figura 13. El archivo de resultados de esa ejecución ($B = 200$) no se conserva en el repositorio, por lo que sus cifras no son reproducibles desde él; el pairs bootstrap sí lo es (`reports/diagnostics/pairs_bootstrap_panel_fe_results.npy`).

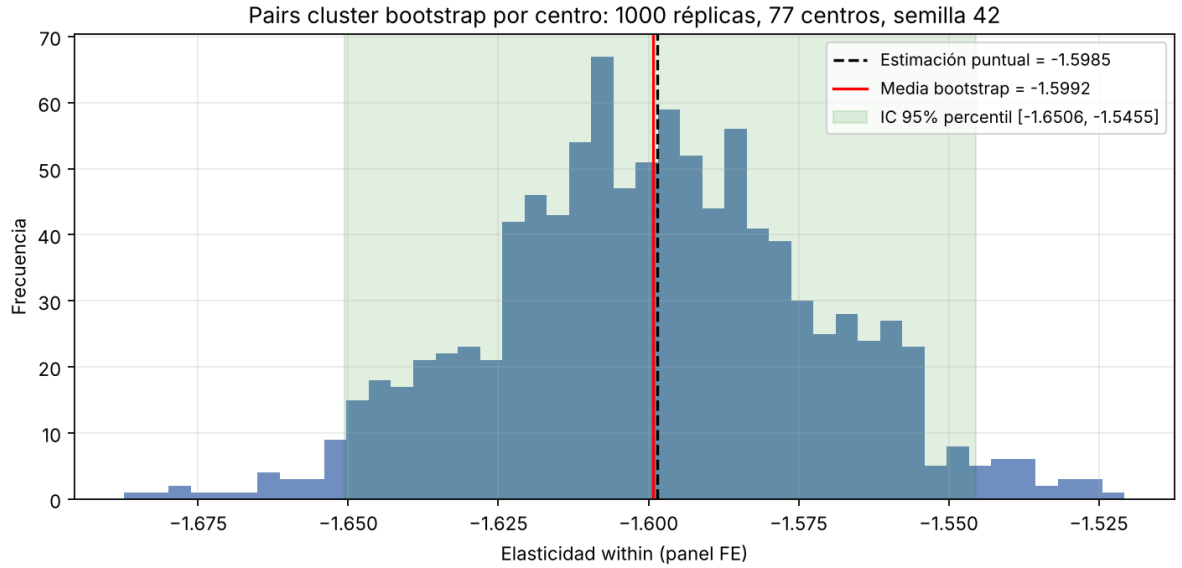


Figura 13

Pairs Bootstrap para Panel FE (dos vías): distribución de coeficientes bootstrap (1000 iteraciones válidas, remuestreo de los 77 centros, semilla 42; réplicas en `reports/diagnostics/pairs_bootstrap_panel_fe_replicas.npz`). Media: $-1,5992$, *IC 95 %:* $[-1,6506, -1,5455]$. *Fuente: Elaboración Propia.*

Normalidad de residuos (Shapiro-Wilk submuestreado): Evaluado sobre una submuestra aleatoria de 5 000 residuos (de 456 548), $W = 0,9829$, $p < 0,001$. Al igual que en el modelo OLS, el test rechaza la normalidad exacta por tamaño muestral excesivo; la desviación es moderada y el TCL asegura validez asintótica.

Variables instrumentales 2SLS (estrategia Hausman-Nevo)

Se construyeron dos instrumentos reales para `checkout_price` usando únicamente variables presentes en el conjunto de datos (estrategia tipo Hausman-Nevo Hausman, 1996; Nevo, 2001):

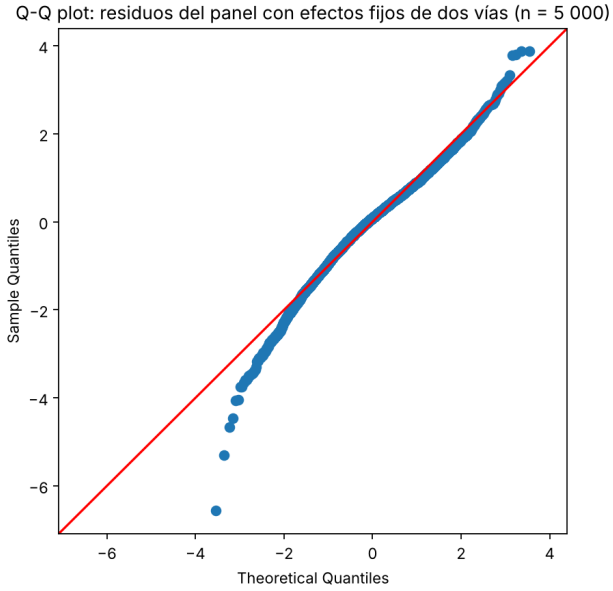


Figura 14

Q-Q plot de residuos del modelo Panel FE (dos vías), submuestra n=5 000 de 456 548. Shapiro-Wilk: $W = 0,9829$*,* $p < 0,001$*. Fuente: Elaboración Propia.*

1. **log_base_price**: log del precio de referencia administrativo, actualizado con baja frecuencia (correlación con precio final = 0,956).

2. **log_precio_prom_otros_centros**: precio promedio de exclusión de la propia observación (*leave-one-out*, exclusión de la propia observación) de la misma comida en otros centros la misma semana (correlación con precio final = 0,986; correlación entre instrumentos = 0,953).

Se excluyeron 4 observaciones (0,001 %) sin información de otros centros para el instrumento 2. La primera etapa presenta un R^2 global de 0,9767. Con una sola variable endógena, el R^2 parcial de Shea coincide con el R^2 parcial conjunto de los instrumentos excluidos: **0,9226**. El F de los instrumentos excluidos (q=2) es **2,72** $\times$ **10^6** bajo homocedasticidad, $1,43 \times 10^6$ con varianza robusta (HC1) y $2,18 \times 10^5$ **con varianza agrupada por `center_id`**, la versión coherente con la dependencia intra-centro. Como diagnóstico complementario se reporta la contribución *única* de cada instrumento condicionada al otro: R^2 parcial 0,6065 y F (q=1) $= 7,04 \times 10^5$ para `log_precio_prom_otros_centros`; R^2 parcial 0,1675 y $F = 9,18 \times 10^4$ para `log_base_price` (estos no son estadísticos de Shea, que se definen por regresor endógeno). Para 2 instrumentos y 1 endógena, Stock y Yogo (2005) tabulan valores críticos de *tamaño* (10 % de tamaño máximo: 19,93); los valores de sesgo relativo requieren al menos 3 instrumentos. Todos los estadísticos superan ese umbral por varios órdenes de magnitud: no hay problema de instrumento débil.

La elasticidad 2SLS puntual ($-0,8414$) es algo más negativa que la OLS con controles ($-0,759$), pero con inferencia agrupada los intervalos se solapan (IV $[-0,940, -0,743]$; OLS $[-0,843, -0,675]$), de modo que **la diferencia no es estadísticamente distinguible**; el patrón es compatible con una atenuación moderada del OLS, sin demostrarla. **Nota metodológica importante:** Este coeficiente difiere del reportado en versiones anteriores ($-0,9604$) porque la especificación actual incluye los mismos controles que el modelo OLS principal (`hubo_aumento`, `C(category)`, `C(center_type)`), mientras que la especificación anterior ($-0,9604$) no los incluía. La diferencia de $-0,119$ entre las dos especificaciones IV refleja el efecto de los controles observables sobre la estimación instrumental. El resultado 2SLS sin controles ($-0,9604$) está cerca del OLS base sin controles ($-0,9516$); al agregar controles, tanto OLS como 2SLS se mueven hacia elasticidades menos negativas ($-0,759$ y $-0,8414$ respectivamente), consistente con sesgo por variable omitida en las especificaciones sin controles.

Tabla 14

Resultados 2SLS con dos instrumentos (modelo principal IV, especificación con controles).

Parámetro	Estimación	EE Robusto	EE agrupado (`center_id`)
log(checkout_price)	$-0,8414$	0,0056	0,0502
emailer_for_promotion	0,4928	0,0052	–
homepage_featured	0,6458	0,0046	–

Nota. $N = 456\,544$; Endógena: log_checkout_price; Instrumentos: log_base_price, log_precio_prom_otros_centros. Controles: emailer_for_promotion, homepage_featured, hubo_aumento, C(category), C(center_type). IC 95 % con EE agrupado: $[-0,940, -0,743]$; wild cluster bootstrap (2 000 réplicas, ambas etapas): DE $= 0,0504$, IC percentil $[-0,940, -0,742]$. Todos los coeficientes con $p < 0,001$. Fuente: elaboración propia; `reports/certified/iv_cf_diagnosticos_v325.json`.

Test de sobreidentificación (Hansen J):. Con 2 instrumentos para 1 endógena (1 g.l.) y ponderación robusta a heterocedasticidad, $J = 33,28$ ($p \approx 8 \times 10^{-9}$). Con la matriz de ponderación agrupada por `center_id` —coherente con la dependencia intra-centro que el informe usa para la inferencia—, $J = 0,92$ ($p = 0,34$) y **no se rechaza** la restricción de sobreidentificación. Las dos estimaciones justamente identificadas son cercanas ($-0,8545$ con `log_base_price`; $-0,8369$ con el precio de otros centros; EE agrupados $\approx 0,05$). En versiones previas se reportaba $J = 324,5$, que corresponde a la especificación sin controles.

Diagnóstico de sensibilidad de Hansen J al tamaño muestral (submuestreo aleatorio): Sobre la especificación principal con controles se re-ejecutó el test (`linearmodels IVGMM.j_stat`, ponderación robusta a heterocedasticidad) en submuestras aleatorias sin reemplazo (50 repeticiones por N, seed=42; `scripts/analysis/hansen_j_poder_controles.py`):

- N=2 000: tasa de rechazo = 10 %, J media = 1,19
- N=5 000: tasa de rechazo = 12 %, J media = 1,52
- N=10 000: tasa de rechazo = 8 %, J media = 1,83
- N=20 000: tasa de rechazo = 14 %, J media = 1,84
- N=50 000: tasa de rechazo = 42 %, J media = 4,08
- N=100 000: tasa de rechazo = 84 %, J media = 8,53
- N=200 000: tasa de rechazo = 100 %, J media = 15,12
- N=456 544 (muestra completa): J = 33,28

Hasta N=20 000 la tasa de rechazo es cercana al nivel nominal y la J media ronda sus grados de libertad (1); a partir de N=50 000 el estadístico crece aproximadamente en proporción a N. Ese patrón es el esperado ante una discrepancia pequeña pero no nula entre instrumentos *o* ante dependencia intra-centro no recogida por la ponderación heterocedástica; dado que la versión agrupada no rechaza ($J = 0,92$), la evidencia de violación de la sobreidentificación es **débil y dependiente del supuesto de varianza**. (El diagnóstico análogo de versiones previas se ejecutó sobre la especificación sin controles y no es comparable.)

Discusión del test de Hansen J:. Hansen J solo detecta inconsistencia *entre* los dos instrumentos; un no rechazo no prueba su validez. Ambos instrumentos son precios administrativos de la misma cadena (correlación 0,953) y podrían violar la exclusión *de la misma forma* (*reference pricing*, shocks regionales comunes), caso en el que J no tiene poder. La conclusión conservadora es que el IV **no cumple los requisitos para presentarse como estimación causal**; figura como análisis de sensibilidad.

Robustez: IV justamente identificado (1 instrumento): Usando solo `log_base_price` (justamente identificado, sin Hansen J) y los mismos controles, la elasticidad es $-0,8545$ (EE agrupado 0,0475; diferencia vs. 2 instrumentos $= -0,013$). Usando solo el precio de otros centros, $-0,8369$ (EE agrupado 0,0519). **Importante:** la estabilidad entre 2-inst. y 1-inst. *no* demuestra que el IV sea válido. Ambos instrumentos comparten origen (precios administrativos de la misma cadena) y pueden violar el supuesto de exclusión de la misma forma (*reference pricing*, shocks regionales comunes). La similitud es compatible con dos hipótesis opuestas: exclusión válida para ambos, o violación de exclusión compartida. Por eso el IV se presenta como **análisis de sensibilidad**, no como estimación causal identificada.

Supuesto de exclusión (documentado): El supuesto de exclusión —que los instrumentos no afectan la demanda salvo a través del precio— **no es comprobable directamente**. Se argumenta cualitativamente: (a) `base_price` es administrativo, baja frecuencia, poco probable que responda a shocks semanales; (b) precio promedio en otros centros refleja costos compartidos a nivel cadena, no shocks de demanda local. Límite real: no se descartan shocks de demanda correlacionados geográficamente entre centros cercanos.

Variables no instrumentadas: El conjunto de datos no contiene costos de insumos, distancia logística, ni identificador de restaurante individual (solo `center_id`). Se documenta como limitación real; no se inventan variables faltantes.

Validación de supuestos — Modelo Panel FE

- **Ratio agrupamiento EE**: La comparación entre errores estándar no agrupados y agrupados por entidad muestra un ratio de $2,10\times$ (0,0239 frente a 0,0114) para la elasticidad, lo que es consistente con la necesidad de agrupamiento (el modelo OLS con controles reportó Durbin-Watson $= 1,199$, autocorrelación positiva).

- **Residuos**: Shapiro-Wilk submuestreado ($n = 5,000$) $W = 0,9829$, $p < 0,001$; desviaciones moderadas en colas, TCL válido.

- **Pairs Bootstrap del Panel FE (dos vías)**: 1000 iteraciones mediante remuestreo por centro con relabeling de cada réplica para evitar índices entity-week duplicados. Media bootstrap: $-1,5992$, DE $= 0,0271$, IC 95 % $[-1,6506, -1,5455]$, consistente con la estimación analítica $(-1,5985)$. 1000/1000 iteraciones válidas. El procedimiento preserva la estructura temporal dentro de los centros remuestreados, pero no reproduce por sí solo toda la dependencia cruzada entidad-tiempo.

- **Limitación**: El modelo panel no incluye test formal de heterocedasticidad agrupada (no estándar en `linearmodels`); el agrupamiento de EE es la corrección estándar.

Validación de supuestos — Modelo IV 2SLS

- **Exogeneidad rechazada → evidencia de endogeneidad**: Wu-Hausman $F = 3\,715,1$ ($p \approx 0$); Wooldridge score $\chi^2 = 1\,785,8$ ($p \approx 0$) (especificación con controles). Ambos tests rechazan rotundamente la exogeneidad de `log_checkout_price`, justificando el uso de IV 2SLS como análisis de sensibilidad.

- **Normalidad residuos**: Inspección visual del Q-Q plot (Figura 15) muestra buen ajuste central, desviación moderada en colas; con $N = 456,544$ se anticipa rechazo de pruebas formales por poder estadístico excesivo, TCL asegura validez asintótica.

- **Primera etapa**: R^2 parcial de Shea $= 0,9226$; F de instrumentos excluidos (q=2) $= 2,72\times10^6$ (homocedástico), $2,18 \times 10^5$ (agrupado por centro) — **relevancia instrumental fuerte**, muy por encima del valor crítico de tamaño de Stock-Yogo (19,93). Contribución única por instrumento: $F = 7,04 \times 10^5$ (R^2 parcial 0,6065, otros centros) y $F = 9,18 \times 10^4$ (R^2 parcial 0,1675, `base_price`).

- **Síntesis**: (1) Exogeneidad rechazada → **evidencia de endogeneidad**, IV motivado; (2) Relevancia instrumental fuerte (R^2 parcial de Shea $= 0,9226$; F agrupado $= 2,18 \times 10^5$); (3) Hansen J rechaza solo con ponderación heterocedástica $(33,28)$ y no con ponderación agrupada $(0,92,\ p = 0,34)$, y la exclusión no es contrastable → **resultado IV como análisis de sensibilidad, no identificación causal**. **Importante:** la inferencia del IV se reporta con EE agrupados por `center_id` (0,0502), nueve veces mayores que los robustos a heterocedasticidad (0,0056); ninguno de los dos **resuelve el problema de validez de los instrumentos** (exclusión, relevancia, exogeneidad); Hansen J es una prueba de validez instrumental (sobreidentificación), no de inferencia.

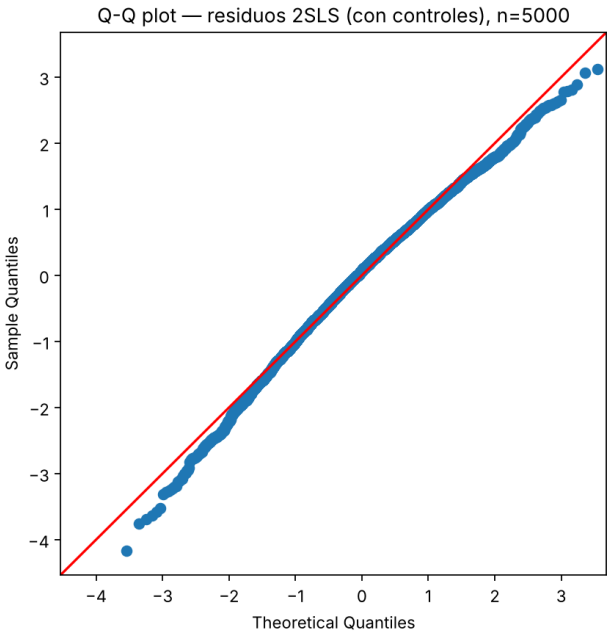


Figura 15

Q-Q plot de residuos del modelo IV 2SLS principal (con controles), submuestra $n = 5\,000$ de 456 544. Coef. 2SLS: $-0,8414$ (EE robusto 0,0056; agrupado por centro 0,0502). Fuente: Elaboración Propia.

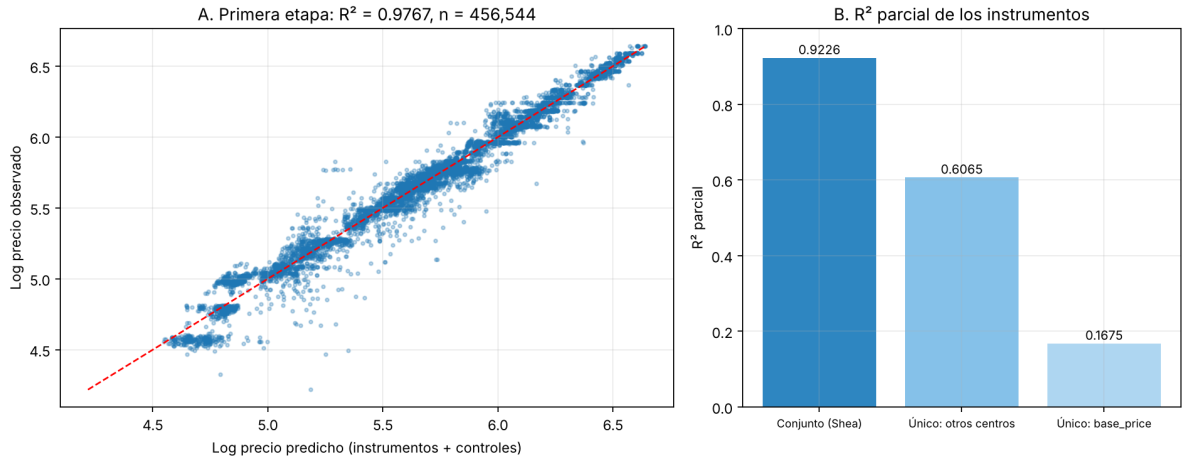


Figura 16

Relevancia de instrumentos IV 2SLS (estrategia Hausman-Nevo, primera etapa con controles). Panel A: precio observado frente al predicho por la primera etapa (submuestra de 10 000). Panel B: R^2 parciales — conjunto de los dos instrumentos (= R^2 parcial de Shea, 0,9226) y contribución única de cada instrumento condicionada al otro (0,6065 otros centros; 0,1675 `base_price`*). F de instrumentos excluidos:* $2,72 \times 10^6$ *(homocedástico),* $2,18 \times 10^5$ *(agrupado por centro); valor crítico de tamaño Stock-Yogo 19,93. Fuente: Elaboración Propia.*

Conclusiones

Este estudio estimó la elasticidad-precio de la demanda en una plataforma de entrega de comidas mediante un flujo reproducible completo que incluye **tres aproximaciones econométricas complementarias** y validación exhaustiva de supuestos, utilizando **456 548 observaciones de datos observacionales agregados a nivel semana–centro–comida** (el conjunto de datos no incluye fecha calendario).

Se estimaron tres aproximaciones econométricas complementarias que producen elasticidades complementarias. El modelo OLS log-log con controles proyecta una elasticidad promedio de $-0,759$ (IC 95 % agrupado por entidad $[-0,843, -0,675]$), inelástica en promedio y consistente con la literatura de comida fuera del hogar; sin embargo, los tests RESET y RCS rechazan la restricción de elasticidad constante, revelando que la elasticidad estimada mediante RCS varía con el nivel de precio de forma no monótona ($+0,04$ en P5, $\approx -1,51$ cerca del precio medio, $-1,25$ en P95). El panel con efectos fijos de dos vías, al controlar heterogeneidad no observada por entidad (centro-comida) y tiempo (semana), arroja una elasticidad within de $-1,5985$ (EE agrupado $= 0,0239$), considerablemente más elástica. La estrategia IV 2SLS con instrumentos tipo Hausman-Nevo y los mismos controles produce $-0,8414$ (EE agrupado por centro $= 0,050$, IC 95 % $[-0,940, -0,743]$), estadísticamente indistinguible del OLS con controles; como la exclusión no es contrastable y el test de Hansen J solo rechaza bajo ponderación heterocedástica, el resultado IV se presenta como análisis de sensibilidad, no como identificación causal. No existe un único número "verdadero": cada modelo aborda una amenaza distinta (OLS: variables omitidas; FE: heterogeneidad entidad-tiempo; IV: simultaneidad precio-demanda), aunque ninguna elimina todas las amenazas simultáneamente, y todos coexisten en el informe con su discusión honesta.

Los diagnósticos se aplicaron a las distintas especificaciones. Para OLS, el test de Breusch-Pagan ($p = 0$) motiva el uso de errores robustos; VIF $\approx 1,0$ no sugiere multicolinealidad problemática; Jarque-Bera ($p = 0$) rechaza normalidad exacta, sin comprometer la normalidad asintótica de los estimadores; Durbin-Watson $= 1,199$ indica autocorrelación positiva. Para Panel FE, el ratio de agrupamiento EE $= 2,10\times$ es consistente con la necesidad de clustering; Shapiro-Wilk submuestreado $W = 0,9829$; el Pairs Bootstrap Panel FE (1000 iteraciones) da media $-1,5992$, DE $= 0,0271$, IC 95 % $[-1,6506, -1,5455]$, consistente con la estimación analítica $(-1,5985)$. Para IV 2SLS (análisis de sensibilidad), Wu-Hausman $F = 3\,715,1$ y Wooldridge $\chi^2 = 1\,785,8$ ($p \approx 0$)

rechazan exogeneidad; la primera etapa (R^2 parcial de Shea $= 0,9226$; F de instrumentos excluidos agrupado $= 2,18 \times 10^5$) confirma instrumentos fuertes; Hansen J $= 33,28$ con ponderación heterocedástica y $0,92$ ($p = 0,34$) con ponderación agrupada. Las estimaciones justamente identificadas ($-0,8545$ con `log_base_price`; $-0,8369$ con otros centros) son compatibles con ambas hipótesis: exclusión válida o violación compartida por ambos instrumentos.

Se identificaron asociaciones promocionales y de visibilidad significativas y consistentes: `emailer_for_promotion` coeficiente $0,5071$ ($p < 0,001$, $\approx +66\,\%$ pedidos); `homepage_featured` coeficiente $0,6544$ ($p < 0,001$, $\approx +92\,\%$ pedidos) en el OLS principal. El signo positivo y la significancia se mantienen en panel FE (0,485 y 0,403) e IV 2SLS (0,493 y 0,646), aunque la magnitud varía según la especificación. La asignación de promociones es probablemente endógena, por lo que estos coeficientes reflejan asociaciones promocionales, no efectos causales.

La comparación con literatura incluye 12 fuentes externas más el estudio propio (13 en total): Grupo A (4 fuentes + este estudio, 5 en total, comida/entrega de comidas directamente comparable) con Andreyeva et al. 2010 (meta-análisis 160 est., FAFH puntual $-0,81$), Damayanti et al. 2023 (Indonesia LA/AIDS $-0,920$), Bumagat & Ibana 2025 (pico $-0,42$, valle $-1,36$), Li & Wang 2025 (contexto), y este estudio ($-0,759$); Grupo B (4 fuentes, contextual on-demand) con Christensen & Osman 2021, Christensen et al. 2023 (Uber El Cairo), Zhang & Demirkan 2021, Sriwongphanawes & Fukuda 2024; Grupo C (4 fuentes, metodológico/mercado) con Statista 2024, Kahneman et al. 1991, Davidson 1994, Long & Ervin 2000. Cada fuente contrastada contra la fuente original.

La traducción a negocio incorpora una capa SQLite (456 548 filas) con 4 vistas de negocio (`sql/queries_negocio.sql`) y 8 archivos CSV para Power BI/Looker Studio: 6 generados por consultas SQL (`notebooks/06_sql_bi_extraccion.ipynb`) y 2 derivados de modelos (`scripts/analysis/generar_dashboard_modelos.py`); son descriptivos y no constituyen recomendaciones de precio. La especificación local RCS puede utilizarse para explorar escenarios de fijación de precios, permitiendo que la respuesta de la demanda varíe con el nivel de precio. La elasticidad FE de $-1,5985$ sirve como referencia global bajo elasticidad constante. Para cambios de precio no marginales, el efecto sobre cantidades e ingresos debe calcularse a partir de la función de demanda RCS estimada, no aplicando mecánicamente una elasticidad puntual constante. La fórmula $\%\Delta R = (1+\Delta)^{1+\eta} - 1$ corresponde al **caso de elasticidad constante**; para RCS y cambios finitos, el cálculo correcto integra la función de demanda estimada punto a punto. Ejemplo ilustrativo (precio $+5\,\%$ desde el precio medio, 332,24): con elasticidad constante, FE ($\eta = -1,5985$) implica un cambio de ingreso de $1,05^{1-1,5985} - 1 \approx -2,88\,\%$ y OLS ($\eta = -0,759$) $\approx +1,18\,\%$; integrando la curva RCS estimada entre P y $1,05P$, la cantidad cae $\approx 7,07\,\%$ y el ingreso $\approx 2,43\,\%$. La elasticidad RCS es variable ($+0,04$ en P5, $\approx -1,51$ cerca del precio medio, $-1,25$ en P95), por lo que las reglas de fijación de precios no deben basarse en una elasticidad constante única.

En conjunto, los resultados indican que la relación precio-demanda en esta plataforma de entrega de comidas es negativa y consistente entre especificaciones, pero su magnitud no es un parámetro escalar constante: la proyección log-log lineal (OLS con controles) promedia $-0,759$ (IC 95 % agrupado por entidad $[-0,843, -0,675]$); el panel con efectos fijos de dos vías da $-1,5985$ (EE clusterizado $= 0,0239$), al controlar heterogeneidad no observada por entidad y tiempo; y la estrategia IV 2SLS produce $-0,8414$ (EE agrupado $= 0,050$) bajo un supuesto de exclusión no contrastable, presentándose como análisis de sensibilidad, no como identificación causal. La no-linealidad (RESET $F = 153,07$, $p \approx 3{,}5 \times 10^{-67}$; RCS contraste F anidado $F = 3\,607,28$, $p \approx 0$) y la heterogeneidad sistemática (cuantiles: $-0,67$ a $-1,01$; categoría: rango $2,5$ log-puntos; tiempo: rango semanal $0,60$ unidades) implican que no existe "la" elasticidad de la plataforma. La elasticidad local RCS ($+0,04$ en P5, $-1,44$ en P50, $\approx -1,51$ cerca del precio medio y $-1,25$ en P95) puede utilizarse como referencia exploratoria para evaluar escenarios de pricing; la elasticidad FE ($-1,5985$) sirve como referencia global bajo el supuesto de elasticidad constante. El flujo de procesamiento y modelado es reproducible a partir de los archivos del proyecto; la RCS cuenta ahora con bandas bootstrap reestimadas bajo la parametrización corregida, mientras que el bootstrap clusterizado canónico de la función de control (5 000 iteraciones, 77 clusters `center_id`, seed=42) produce para `v_hat` un IC 95 % $[0,664; 1,314]$ que **excluye cero** (media $= +0,9937$), rechazando exogeneidad de forma robusta; la elasticidad CF puntual en el precio medio es $-1,5041$ (IC 95 %

bootstrap $[-1,630; -1,370]$), muy próxima a la RCS-OLS en el mismo punto ($-1,5120$).

Robustez Adicional: Regresión Cuantil, Interacción Precio-Promoción, RESET y Función de Control

Se implementaron cuatro mejoras de robustez fundamentales que abordan limitaciones explícitas del modelo principal: (1) heterogeneidad en la distribución condicional via regresión cuantil, (2) no-aditividad precio-promoción via interacción, (3) test de especificación funcional via RESET, y (4) combinación IV + no-linealidad via *función de control*. Todas se ejecutaron sobre los datos reales (456 548 observaciones; 456 544 en las especificaciones con instrumentos).

Regresión Cuantil ($\tau = 0,1, 0,25, 0,5, 0,75, 0,9$)

El modelo OLS estima el efecto del precio en la **media condicional** de la demanda. La regresión cuantil permite estimar el efecto en diferentes cuantiles ($\tau = 0,1$: demanda baja; $\tau = 0,25$: demanda baja-media; $\tau = 0,5$: mediana; $\tau = 0,75$: demanda alta-media; $\tau = 0,9$: demanda alta), revelando heterogeneidad no capturada por la media.

Tabla 15 presenta los resultados puntuales para el modelo log-log con controles (misma especificación principal). La tabla extendida con errores estándar analíticos y anchura de IC se encuentra en el Appendix Técnico: Tablas Completas y Diagnósticos Extendidos (Tabla A2).

Tabla 15

Regresión cuantil: elasticidad precio por cuantil de la demanda condicional (5 cuantiles). IC 95 % analítico (EE de statsmodels QuantReg, kernel Epanechnikov).

Cuantil (τ)	Elasticidad	IC 95 % Inf.	IC 95 % Sup.	Interpretación
0.10	$-0,6685$	$-0,681$	$-0,656$	Demanda baja: inelástica, menos sensible al precio
0.25	$-0,733$	$-0,745$	$-0,720$	Demanda baja-media: inelástica, cercana a media
0.50 (mediana)	$-0,7748$	$-0,786$	$-0,763$	Demanda mediana: similar a OLS ($-0,759$)
0.75	$-0,876$	$-0,885$	$-0,867$	Demanda alta-media: inelástica
0.90	$-1,0068$	$-1,017$	$-0,997$	Demanda alta: elástica, más sensible al precio

La elasticidad varía sistemáticamente: es **más elástica en la cola superior** de la distribución condicional de pedidos ($\tau = 0{,}9$: $-1,01$) que en la cola inferior ($\tau = 0{,}1$: $-0,67$), con una progresión monotónica a través de los 5 cuantiles. Esto revela heterogeneidad en la función de demanda condicional: las combinaciones centro-comida-semana con demanda estructuralmente alta (que pueden reflejar productos populares, centros grandes, semanas específicas, categorías, o promociones activas) muestran mayor sensibilidad al precio. **No identifica segmentos conductuales de consumidores**, ya que la unidad de análisis es centro-comida-semana, no consumidores individuales. El modelo OLS de media condicional ($-0{,}759$) promedia esta heterogeneidad.

Advertencia inferencial: Los intervalos de confianza son analíticos (errores estándar asintóticos de la regresión cuantil, que suponen observaciones independientes) y **no preservan la estructura de dependencia panel**. Por tanto, los IC de cuantiles deben interpretarse como **robustez condicional**, no con idéntico nivel inferencial que el estimador OLS clusterizado (agrupado center_id × meal_id).

Nota de versión (3.3.0): versiones anteriores reportaban IC bootstrap percentil i.i.d. (1000 iteraciones) calculados en una máquina virtual externa; el archivo de resultados de esa ejecución no se conservó, por lo que esos IC no pueden reproducirse desde el repositorio y se sustituyeron por los IC analíticos, que sí se reproducen con `src/modeling.py::modelo_quantile_regression`. Las estimaciones puntuales no cambian.

Interacción Precio Œ Promoción

El modelo principal asume efectos aditivos: precio y promociones afectan la demanda de forma independiente. Para testear no-aditividad, se añadieron términos de interacción `log_checkout_price:emailer_for_promotion` y `log_checkout_price:homepage_featured`.

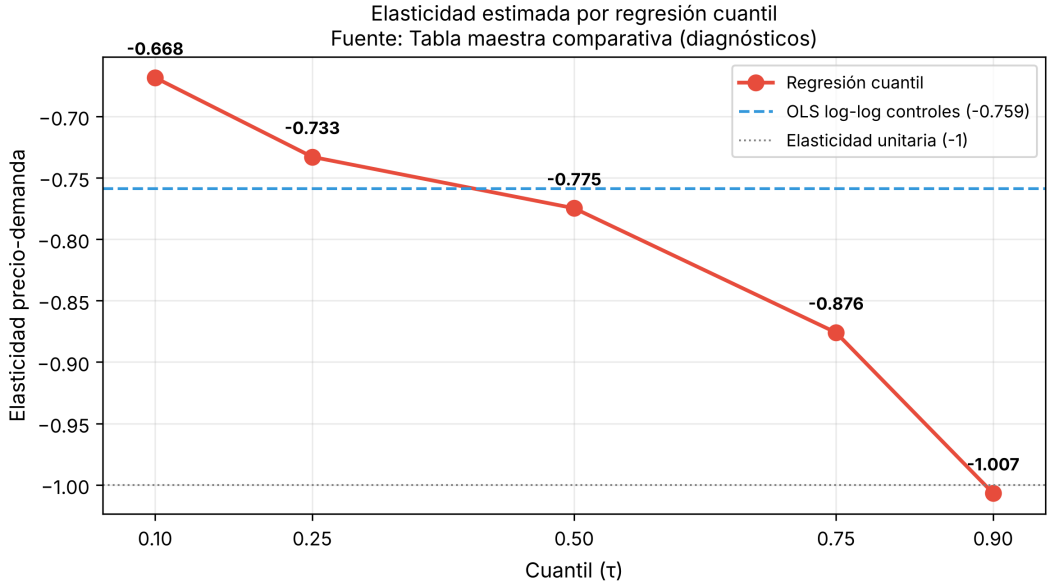


Figura 17

Elasticidad precio por cuantil de la distribución condicional de la demanda. Regresión cuantil con controles (modelo log-log). La línea discontinua muestra la elasticidad OLS de media condicional $(-0,759)$*. Fuente: elaboración propia.*

Tabla 16

Modelo log-log con interacción Precio Œ Promoción (coeficientes clave).

Variable	Coeficiente	p-valor
log_checkout_price (centrado)	$-0,7481$	$< 0,001$
emailer_for_promotion (en log-precio medio)	$+0,5309$	$< 0,001$
homepage_featured (en log-precio medio)	$+0,6228$	$< 0,001$
log_checkout_price:emailer_for_promotion	$+0,3284$	$< 0,001$
log_checkout_price:homepage_featured	$-0,2204$	$< 0,001$

Test de Wald conjunto (H0: ambos coeficientes de interacción = 0):

- $F = 652,28$, gl $= (2, 456\,526)$, $p \approx 10^{-283}$
- **RECHAZO FUERTE de H0: interacción estadísticamente significativa**

Interpretación económica (asociaciones diferenciales, no efectos causales):

- **Emailer (interacción positiva +0,3284)**: Cuando hay promoción por correo activo, la elasticidad precio-demanda es *menos negativa* (la demanda se vuelve menos sensible al precio). La asociación diferencial del emailer a precio promedio (log-precio centrado) es $+0,5309$ ($\approx 70\,\%$ más pedidos), y esta asociación *aumenta* a medida que el precio sube (interacción positiva).
- **Homepage (interacción negativa** $-0,2204$**)**: Cuando hay exposición en página principal, la elasticidad precio-demanda es *más negativa* (la demanda se vuelve más sensible al precio). La asociación diferencial del homepage a precio promedio (log-precio centrado) es $+0,6228$ ($\approx 86\,\%$ más pedidos), pero esta asociación *disminuye* a medida que el precio sube (interacción negativa).

Nota: Los términos de interacción se estimaron con `log_checkout_price` centrado en su media muestral para facilitar la interpretación de los efectos marginales en el punto promedio. La

asignación de promociones es probablemente endógena (productos con alta demanda prevista), por lo que estos coeficientes reflejan **asociaciones condicionales**, no efectos causales de la promoción.

Esta no-aditividad tiene implicaciones directas para fijación dinámica de precios: la asociación combinada de precio y promoción no es simplemente la suma de sus asociaciones marginales aisladas.

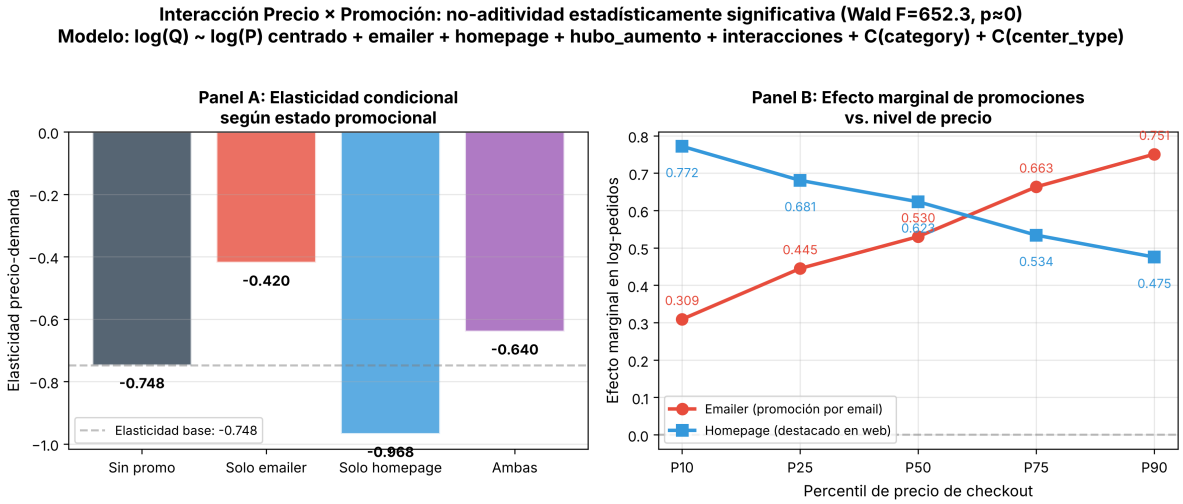


Figura 18

Interacción Precio × Promoción: no-aditividad estadísticamente significativa. Panel A: elasticidad condicional según estado promocional. Panel B: efecto marginal de promociones vs. nivel de precio. Wald F=652,28, $p \approx 0$. Fuente: elaboración propia.

Test RESET (Ramsey) — Especificación Funcional

El test RESET (Regression Specification Error Test) evalúa si la forma funcional log-log está correctamente especificada, añadiendo potencias de los valores ajustados ($\hat{y}^2, \hat{y}^3$) y testeando su significancia conjunta (Ramsey, 1969).

Tabla 17

Test RESET para el modelo log-log con controles (especificación principal).

Estadístico	Valor
F (2 gl num, 456 526 gl den)	153, 07
p-valor	$\approx 3{,}5 \times 10^{-67}$
H0: especificación funcional adecuada	Se rechaza
Evidencia de misspecification	Sí

El test **rechaza rotundamente** la especificación correcta ($p \approx 0$), lo que es consistente con que la forma funcional log-log con elasticidad constante es inadecuada. Este resultado es consistente con el contraste F anidado log-log frente a RCS ($F = 3\,607, 28$, $p \approx 0$): la relación precio-demanda presenta no linealidad estimada que no es capturada por el modelo lineal en logaritmos.

IV No-Lineal vía Función de Control (Wooldridge 2015)

Dado que (1) la estimación IV 2SLS aportó evidencia de endogeneidad (Wu-Hausman $p \approx 0$, rechazo de exogeneidad) y (2) el contraste F anidado rechazó la linealidad en log-precio ($p \approx 0$), se implementó el enfoque de *función de control* (Wooldridge, 2015) que aborda ambos problemas simultáneamente.

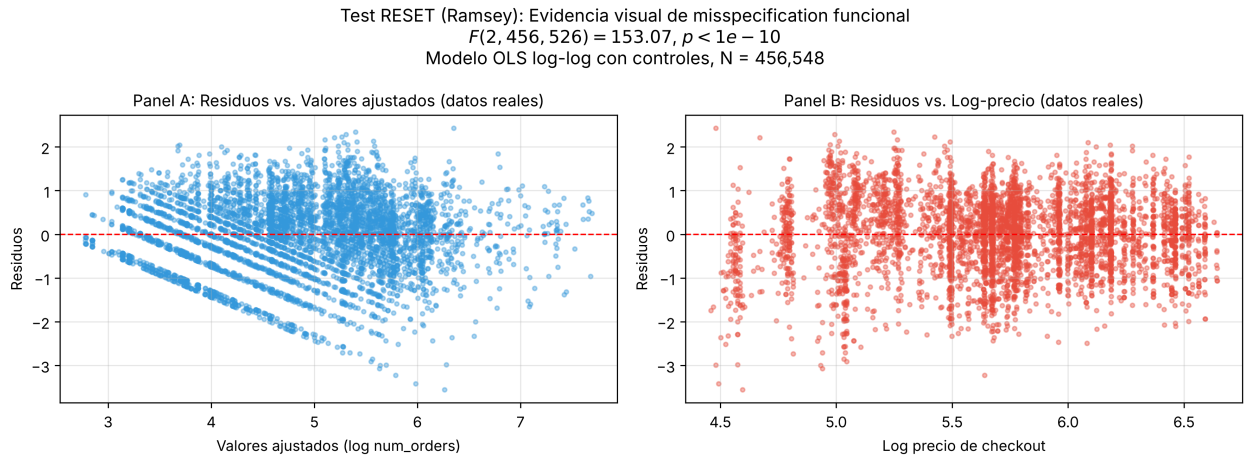


Figura 19

Evidencia visual del test RESET: residuos vs. valores ajustados (Panel A) y residuos vs. log-precio (Panel B). La curvatura cuadrática visible es consistente con misspecification funcional. $F = 153,07$, $p \approx 3,5 \times 10^{-67}$. *Fuente: elaboración propia.*

Especificación RCS canónica: La segunda etapa utiliza *Restricted Cubic Splines* (RCS) con **4 nudos explícitos en los percentiles 5, 35, 65 y 95 de** `log_checkout_price` (P5 = 4,80 / 121,28; P35 = 5,56 / 260,02; P65 = 5,86 / 349,26; P95 = 6,46 / 640,23), generando **3 bases spline** (`rcs_1`, `rcs_2`, `rcs_3`) con **intercepto del modelo separado** (fórmula `cr(log_checkout_price, knots=(P35,P65), lower_bound=P5, upper_bound=P95, constraints='center') - 1`). La restricción `constraints='center'` impone que la **función spline resultante** (la combinación lineal de las tres bases) sea lineal fuera de los nudos de frontera [P5, P95], es decir, su primera derivada es constante en las colas. Las columnas individuales `rcs_1`, `rcs_2`, `rcs_3` **no deben interpretarse** como componentes "lineal" y "no lineales" separadas; son una base cuyo efecto conjunto produce la forma funcional (en particular, `rcs_1` por sí sola no es lineal en log-precio, de modo que $H_0 : \beta_{\texttt{rcs_2}} = \beta_{\texttt{rcs_3}} = 0$ *no* es una hipótesis de linealidad). Los nudos se fijan en la muestra completa y se aplican vía `build_design_matrices` en cada réplica bootstrap.

Primera etapa: Regresión de `log_checkout_price` sobre instrumentos Hausman-Nevo + controles:

- Instrumentos: `log_base_price` ($r = 0,956$), `log_precio_prom_otros_centros` ($r = 0,986$); correlación entre instrumentos $= 0,953$
- **Relevancia instrumental fuerte**: $R^2 = 0,9767$; R^2 parcial de Shea $= 0,9226$; F de instrumentos excluidos (q=2) $= 2,72 \times 10^6$ (homocedástico) y $2,18 \times 10^5$ (agrupado por centro) — sin problema de instrumento débil
- **Validez instrumental no contrastable**: Hansen J $= 33,28$ con ponderación heterocedástica y $0,92$ ($p = 0,34$) con ponderación agrupada; el supuesto de exclusión no es comprobable directamente
- El residuo de primera etapa $\hat{v}$ (`v_hat`) se incorpora como término de control asociado al componente endógeno del precio, bajo los supuestos de la función de control

Segunda etapa: Modelo con RCS canónica (3 bases) + $\hat{v}$ + controles:

- Fórmula: log(`num_orders`) $\sim 1 +$ `rcs_1` + `rcs_2` + `rcs_3` + $\hat{v}$ + controles
- R^2 ajustado $= 0,5412$ en la especificación puntual; este aumento respecto del OLS log-log no debe interpretarse como evidencia de superioridad causal ni de validez de los instrumentos.

- Coeficiente $\hat{v}$ (estimación puntual muestra completa) $= +1,0002$ (EE convencional $= 0,0177$; bootstrap agrupado por centro: DE $= 0,1654$, IC 95 % $[0,664;\ 1,314]$)

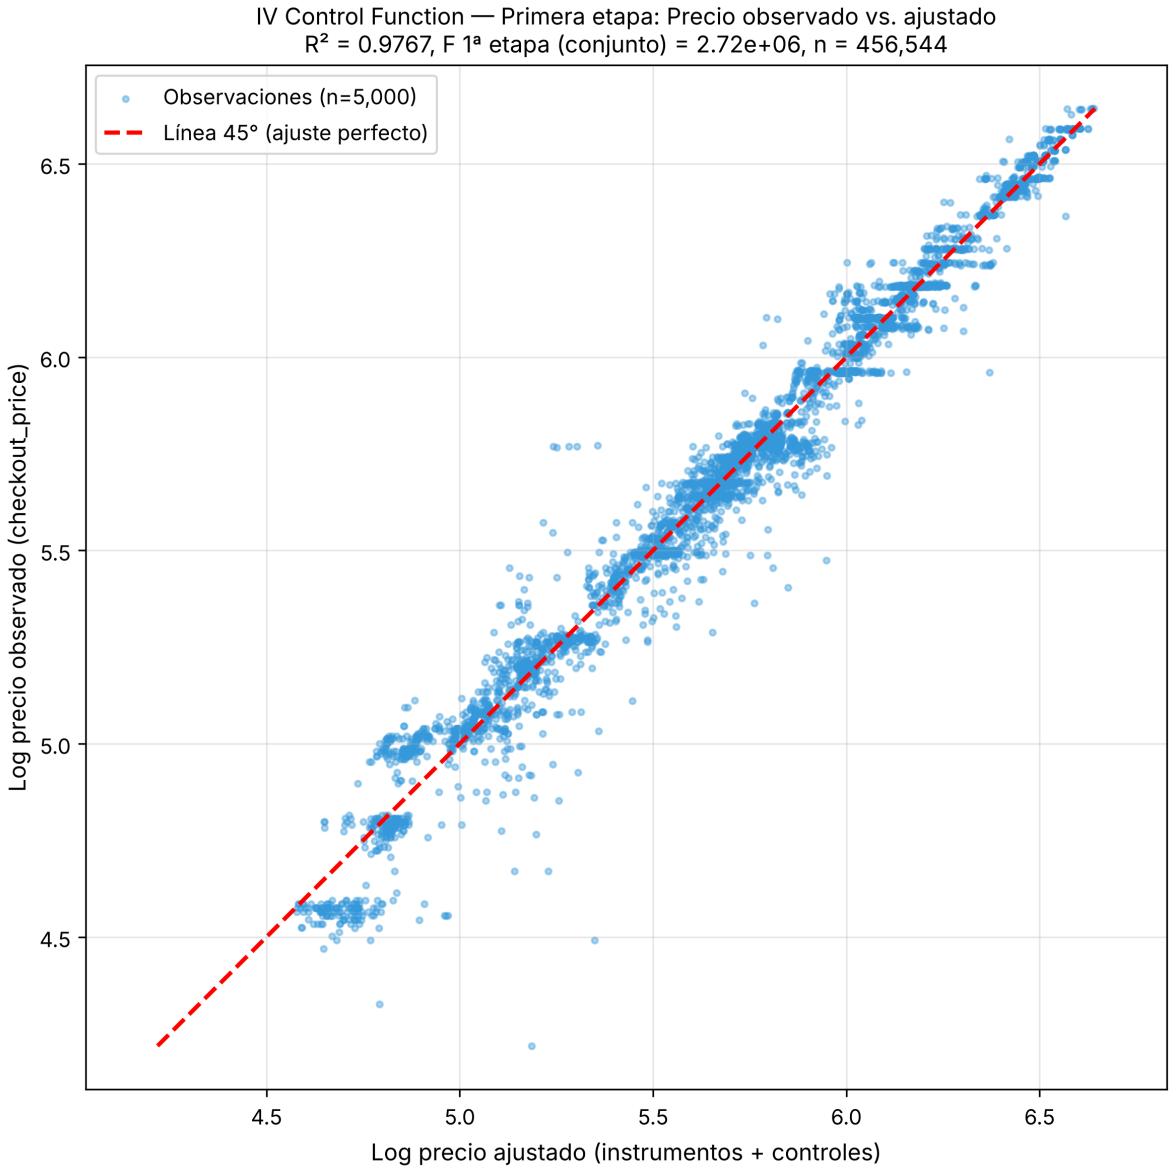


Figura 20

Panel A. IV Función de Control: primera etapa. Precio de checkout observado frente al precio ajustado con instrumentos Hausman–Nevo y controles. $R^2 = 0,977$*;* R^2 *parcial de Shea* $= 0,9226$*; F de instrumentos excluidos (q=2)* $= 2,72 \times 10^6$ *(homocedástico),* $2,18 \times 10^5$ *(agrupado por centro);* $n = 456\,544$*. Fuente: elaboración propia.*

Tabla 18

Tests en segunda etapa de la Función de Control IV-RCS (estimación puntual muestra completa).

Test	F	p-valor	Decisión
Exogeneidad (H0: coef($\hat{v}$) $= 0$; $F = t^2$, EE convencional)	$3\,177,9$	≈ 0	**Rechaza H0 de exogeneidad**
No-linealidad: CF lineal en log-precio vs. CF-RCS (F anidado, gl $= (2;\ 456\,521)$)	$3\,335,4$	≈ 0	**Rechaza linealidad**

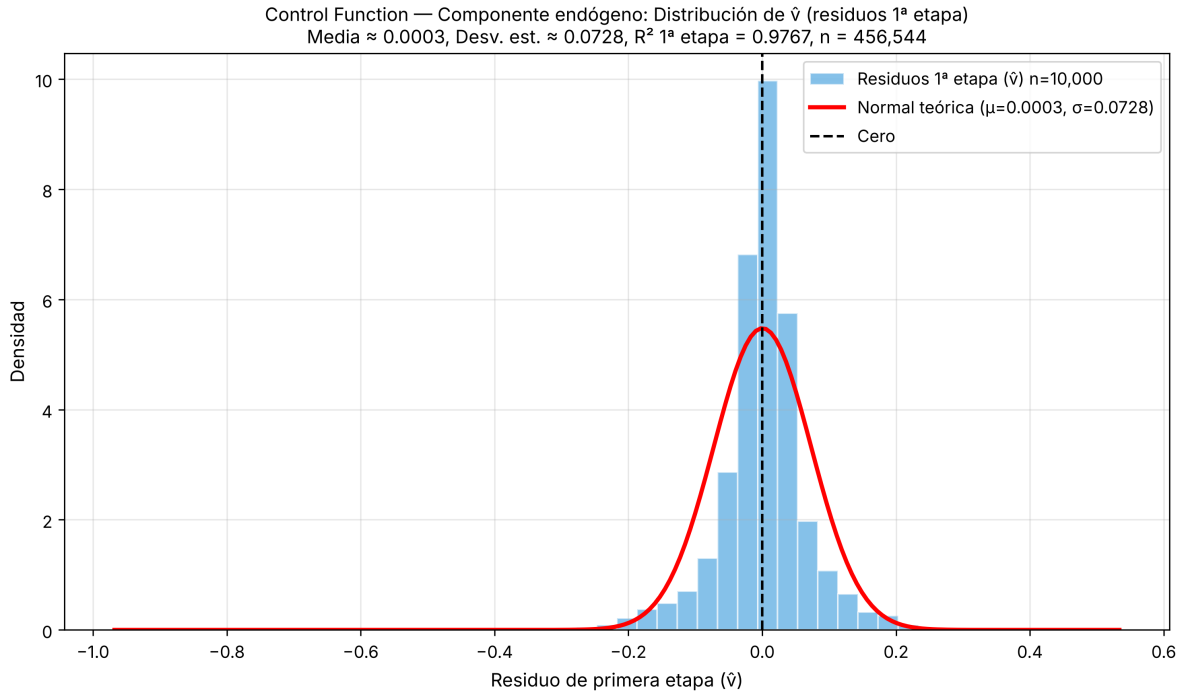


Figura 21

Panel B. Componente endógeno del precio ($\hat{v}$): distribución de los residuos de la primera etapa y normal teórica. Muestra completa ($n = 456\,544$): media $= 0$ por construcción, desv. est. $= 0,0736$. Submuestra graficada ($n = 10\,000$, título de la figura): media $\approx 0,0003$, desv. est. $\approx 0,0728$. Fuente: elaboración propia.

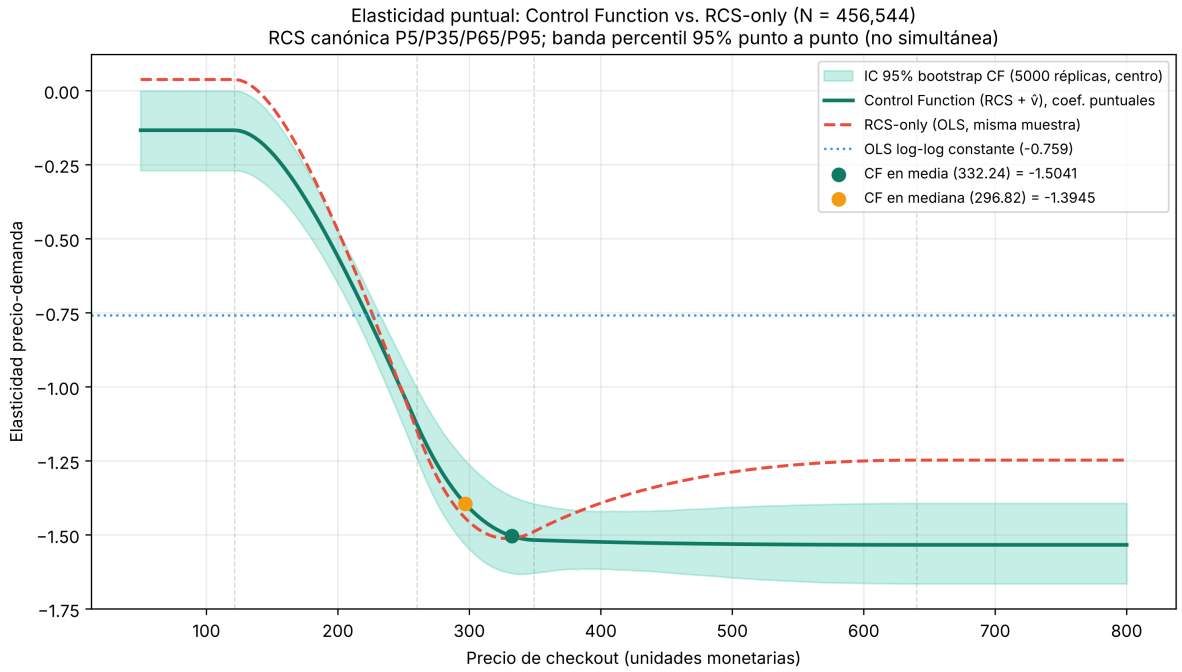


Figura 22

Panel C. Elasticidad puntual con coeficientes de la muestra completa: Control Function (RCS+$\hat{v}$) con banda percentil bootstrap del 95 % punto a punto (5 000 réplicas agrupadas por centro, ambas etapas reestimadas) y RCS–only (OLS, misma muestra). Puntos: precio medio (332,24) y mediana (296,82). Fuente: elaboración propia; `reports/certified/bootstrap_cf_canonical_replicas.npz`.

Nota. La segunda etapa se estima con RCS canónica (3 bases: `rcs_1`, `rcs_2`, `rcs_3`, nudos P5/P35/P65/P95 fijados) + $\hat{v}$ + controles. El coeficiente de segunda etapa asociado a $\hat{v}$ (estimación puntual) es $+1,0002$ (EE convencional = $0,0177$; agrupado por centro = $0,166$). El **bootstrap clusterizado canónico** (5 000/5 000 réplicas válidas, seed=42, 77 clusters `center_id`, reestimación de ambas etapas, nudos RCS fijados en muestra completa; `scripts/vm/bootstrap_cf_canonical_replicas.py`, que reproduce exactamente la secuencia de remuestreo original y guarda las réplicas) produce para $\hat{v}$ (`v_hat`): **media** = $+0,9937$**, IC 95 % percentil** $[0,664; 1,314]$ (excluye cero). [1] Por tanto, el test de exogeneidad basado en Control Function **rechaza** $\mathbf{H_0}$ (IC bootstrap de $\hat{v}$ excluye cero), confirmando endogeneidad de `log_checkout_price`. El resultado se interpreta como **análisis de sensibilidad y no como identificación causal**, porque la exclusión de los instrumentos (los mismos que en IV 2SLS) no es contrastable.[2] Fuente: elaboración propia; `reports/certified/bootstrap_vhat_canonical.json` y `bootstrap_cf_canonical_replicas.json`.

La especificación IV-RCS (control function) proporciona un **análisis de sensibilidad** que simultáneamente permite endogeneidad y no linealidad, condicionado a la validez de los instrumentos y a los supuestos del control function. La especificación puntual produce R^2 ajustado = $0,5412$. Comparadas en la *misma muestra y el mismo punto*, la elasticidad CF y la RCS-OLS son muy próximas: en el precio medio (332,24), CF = $-1,5041$ (IC 95 % bootstrap $[-1,630; -1,370]$) frente a RCS-OLS = $-1,5120$; en la mediana (296,82), CF = $-1,3945$ (IC $[-1,534; -1,249]$) frente a RCS-OLS = $-1,4431$. Es decir, una vez permitida la curvatura, la corrección por endogeneidad mediante función de control **no vuelve la curva más elástica**; si acaso, la acerca levemente a cero en la zona central. La brecha entre el OLS log-log constante ($-0,759$) y las curvas RCS/CF ($\approx -1,4$ a $-1,5$ en el centro de la distribución) se debe, por tanto, sobre todo a la forma funcional y no a la endogeneidad. El **bootstrap clusterizado canónico** confirma que $\hat{v}$ es distinto de cero (IC $[0,664; 1,314]$), por lo que el test de exogeneidad rechaza $\mathrm{H_0}$ de forma robusta al procedimiento de inferencia. El coeficiente de la base `rcs_1` (IC bootstrap $[-0,0769; 0,0029]$) no tiene interpretación aislada y **no debe confundirse con** $\hat{v}$. El resultado sigue siendo un **análisis de sensibilidad y no una estimación causal identificada**, porque la exclusión instrumental compartida con IV 2SLS no es contrastable.

Robustez Adicional: Igualdad por Categoría, Submuestras, Outliers y Comparación de Errores Estándar

Se implementaron cuatro comprobaciones de robustez adicionales que abordan la estabilidad de la elasticidad principal ante decisiones de muestra, especificación y estimación de errores estándar. Todas se ejecutaron sobre las 456 548 observaciones reales.

Test de Igualdad de Elasticidad por Categoría (Wald Conjunto)

El modelo principal estima una elasticidad promedio agregada. Para evaluar si la elasticidad-precio difiere sistemáticamente entre las 14 categorías de comida, se estimó un modelo con interacciones `log_checkout_price` × `category` y se testeó la hipótesis nula conjunta de igualdad (Wald test, 13 grados de libertad).

El test **rechaza rotundamente** la igualdad ($p \approx 0$). La elasticidad varía sustancialmente entre categorías: desde $-0,28$ (Pasta, inelástica) hasta $-2,49$ (Fish; Seafood $-2,48$, altamente elásticas). Esto implica que una única elasticidad agregada oculta heterogeneidad económica real; los valores específicos por categoría pueden servir como **referencia para segmentar** la sensibilidad estimada, sin que ello demuestre que aplicar esos coeficientes produzca el pricing óptimo.

[1] `v_hat` es el residual de la primera etapa incluido como regresor en la segunda etapa para testear $\mathrm{H_0}$: exogeneidad. Su coeficiente (1,0002 en la muestra completa; media bootstrap 0,994) mide la covarianza condicional entre la parte no explicada del precio y la demanda, escalada por la varianza residual de precio. **No es una elasticidad**.

[2] El patrón OLS ($-0,759$) frente a IV ($-0,841$) es compatible con una atenuación moderada por endogeneidad en el modelo lineal, pero con EE agrupados los intervalos se solapan y no prueba causalidad.

Tabla 19

Test de Wald: igualdad de elasticidad-precio entre 14 categorías.

Estadístico	Valor
F (13 gl num, 456 515 gl den)	$519,13$
p-valor	$< 10^{-300}$
Rechaza H0 (alpha=0,05)	**Sí**

Tabla 20

Elasticidad-precio por categoría (efecto marginal, modelo con interacciones).

Categoría	Elasticidad	Interpretación
Beverages	$-0,69$	Inelástica
Biryani	$-1,13$	Elástica
Desert	$-0,90$	Inelástica
Extras	$-0,60$	Inelástica
Fish	$-2,49$	Altamente elástica
Other Snacks	$-0,67$	Inelástica
Pasta	$-0,28$	Muy inelástica
Pizza	$-1,95$	Elástica
Rice Bowl	$-1,09$	Elástica unitaria
Salad	$-0,34$	Inelástica
Sandwich	$-1,76$	Elástica
Seafood	$-2,48$	Altamente elástica
Soup	$-2,21$	Elástica
Starters	$-1,43$	Elástica

Submuestra: Combinaciones centro–comida con al menos 50 semanas observadas

El conjunto de datos contiene combinaciones centro–comida con distinta cobertura temporal (número de semanas observadas). Para evaluar si los ítems con poca frecuencia temporal afectan la elasticidad principal, se filtró la muestra reteniendo solo combinaciones centro–comida con al menos 50 semanas observadas.

Tabla 21

Robustez: submuestra con al menos 50 semanas observadas por combinación centro–comida.

Muestra	N	Elasticidad (log_checkout_price)
Completa	456 548	$-0,759$ (EE agrupado = $0,0430$)
Filtrada ($\geq$50 semanas por combinación)	452 983 (99,2 %)	$-0,7553$ (EE agrupado = $0,0431$)

La diferencia es de **+0,0037** (0,5 % en términos relativos, muy inferior al EE agrupado), lo que sugiere que la elasticidad principal es **robusta** a la exclusión de combinaciones centro–comida con poca cobertura temporal. El 99,2 % de las observaciones se retiene, indicando que la mayoría de las combinaciones tienen al menos 50 semanas observadas. **Este resultado refleja únicamente el efecto de filtrar combinaciones con escasa cobertura temporal, no el efecto de recortar colas de precio.**

Sensibilidad: Excluir Top/Bottom 1 % en Precio

Para verificar que observaciones extremas de precio no impulsen de forma desproporcionada la estimación, se recortó el 1 % superior e inferior de `checkout_price` (P1 = 96,03, P99 = 708,13).

Tabla 22

Robustez: sensibilidad excluyendo colas 1 % de precio.

Muestra	N	Elasticidad (log_checkout_price)
Completa	456 548	$-0,759$ (EE agrupado = $0,0430$)
Filtrada (percentiles 1–99)	447 915 (98,1 %)	$-0,8115$ (EE agrupado = $0,0439$)

La diferencia es de $-0,0525$ (aprox. 6,9 % en magnitud relativa; los IC agrupados se solapan). Aunque el cambio no revierte la conclusión cualitativa (demanda inelástica), el desplazamiento hacia mayor elasticidad sugiere que **los precios muy altos (>P99) ejercen influencia apalancadora** que atenúa la elasticidad estimada en la muestra completa. Este resultado recomienda reportar ambas estimaciones en análisis de fijación de precios sensibles.

Comparación HC3 vs Cluster vs Bootstrap (Errores Estándar)

El análisis de Panel FE reportó un ratio de clustering 2,10x. Aquí se extiende la comparación al modelo OLS principal (log-log con controles), contrastando cuatro estimadores de varianza.

Tabla 23

Comparación de errores estándar: HC3, clustering por entidad, Panel FE y procedimientos bootstrap.

Estimador	Elasticidad	Error Estándar	IC 95 %	Iter.
Modelo OLS log-log con controles (elasticidad $= -0,759$)				
OLS HC3	$-0,759$	0,0054	$[-0,770, -0,748]$	–
OLS Cluster (center_id)	$-0,759$	0,0424	$[-0,842, -0,676]$	–
OLS agrupado por entidad (center_id × meal_id)	$-0,759$	0,0430	$[-0,843, -0,675]$	–
Wild Cluster Bootstrap OLS (500 iter)	$-0,7585$	0,0422	$[-0,8380, -0,6730]$	500
Bootstrap-t OLS (2000 iter)	$-0,7590$	–	$[-0,8443, -0,6762]$	2000
Jackknife leave-1-cluster (77 centros)	$-0,7590$	0,0423 (JK)	$[-0,842, -0,676]$	77
Modelo OLS log-log base (elasticidad $= -0,9516$)				
OLS base HC3	$-0,9516$	0,0034	$[-0,958, -0,945]$	–
Bootstrap simple i.i.d. (1000 iter)	$-0,9514$	0,0034	$[-0,958, -0,945]$	1000
Panel FE (entidad-tiempo, elasticidad within $= -1,5985$)				
Panel FE Cluster (entidad)	$-1,5985$	0,0239	$[-1,645, -1,552]$	–
IV 2SLS (2 inst., elasticidad $= -0,8414$, con controles)				
IV robusto (HC)	$-0,8414$	0,0056	$[-0,852, -0,830]$	–
IV agrupado (center_id)	$-0,8414$	0,0502	$[-0,940, -0,743]$	–
Wild Cluster Bootstrap IV (ambas etapas)	$-0,8410$	0,0504	$[-0,9398, -0,7424]$	2000
Referencia histórica: IV sin controles ($-0,9604$)				
Wild Cluster Bootstrap IV (ambas etapas)	$-0,9607$	0,0281	$[-1,0141, -0,9043]$	2000

- **Ratio Cluster/HC3 = 7,87x**: El clustering por `center_id` infla el EE casi 8 veces respecto a HC3, **lo que evidencia que la elección de la estructura de varianza afecta materialmente la incertidumbre estimada**.

- **Ratio agrupación entidad/HC3 = 7,99x**: La agrupación por entidad `center_id` × `meal_id` (inferencia principal recomendada) produce EE similar al cluster simple por center_id.
- **Bootstrap simple vs. HC3 (mismo modelo base)**: 0,0034 frente a 0,0034 (ratio $\approx 1,00$), como se espera: el bootstrap i.i.d. de pares replica la corrección por heterocedasticidad, pero ninguno de los dos incorpora la dependencia intra-panel. **No usar bootstrap simple para ICs finales**.
- **Wild Cluster Bootstrap OLS**: media $-0,7585$, EE bootstrap $= 0,0422$, IC 95 % $[-0,8380, -0,6730]$, $n = 500$ iteraciones válidas; se interpreta como corroboración de sensibilidad de la inferencia por clustering.
- **Wild Cluster Bootstrap IV 2SLS (especificación principal con controles)**: pesos de Rademacher por `center_id`, ambas etapas perturbadas y reestimadas; media $-0,8410$, DE $= 0,0504$, IC 95 % $[-0,9398, -0,7424]$, 2000/2000 réplicas (`reports/certified/wild_bootstrap_iv_2sls_controles.npz`, réplicas brutas). Coincide con el EE agrupado analítico (0,0502). Los archivos `wild_bootstrap_iv_2sls*.json/npy` anteriores corresponden a la especificación sin controles ($-0,9604$) y se conservan solo como referencia histórica.
- **Bootstrap-t (Percentile-t) OLS**: coeficiente base $-0,7590$ e IC 95 % $[-0,8443, -0,6762]$ con $n = 2000$ iteraciones válidas; los cuantiles bootstrap fueron $t_{0,025} = -1,965$ y $t_{0,975} = 2,027$. Ancho IC bootstrap-t $(0,1677)$ ligeramente mayor que percentil simple $(0,1642)$, compatible con mayor cautela en las colas para pocos clusters, sin que esto implique una evaluación directa de cobertura nominal (Cameron et al., 2008).
- **Jackknife Leave-One-Cluster-Out (77 centros)**: coef JK media $-0,7590$, EE JK $= 0,0423$ (fórmula correcta $\sqrt{\frac{n-1}{n}\sum(\hat{\theta}_{-i} - \bar{\theta}_{-i})^2}$), IC 95 % $[-0,842; -0,676]$, centro más influyente = 102 (diff máx absoluta $= 0,0104$), rango JK $[-0,7693; -0,7506]$. El EE jackknife $(0,0423)$ es consistente con el EE clusterizado $(0,0430)$, confirmando robustez de la inferencia agrupada.
- **Recomendación práctica**: Para OLS log-log principal, usar **agrupado por entidad `center_id` × `meal_id`** (inferencia principal). HC3 solo como referencia. Para Panel FE, usar **cluster por entidad** (center_id-meal_id). Para IV 2SLS, usar **EE agrupados por `center_id`** o el wild cluster bootstrap; los EE robustos a heterocedasticidad subestiman la incertidumbre en un factor ≈ 9.

Síntesis de la sección de robustez: La elasticidad agregada OLS $(-0,759)$ es robusta a filtrado por observaciones mínimas (Δ=+0,0037), moderadamente sensible a colas de precio (Δ=−0,0525), y **rechaza igualdad entre categorías** (F=519,1, $p \approx 0$). La comparación de EE confirma que la elección del estimador de varianza tiene impacto material (7,99x HC3 vs agrupado) y debe justificarse por la estructura de dependencia del modelo, no por conveniencia. **Inferencia principal: agrupado por entidad `center_id` × `meal_id` (EE=0,043, IC 95 % $[-0,843, -0,675]$).**

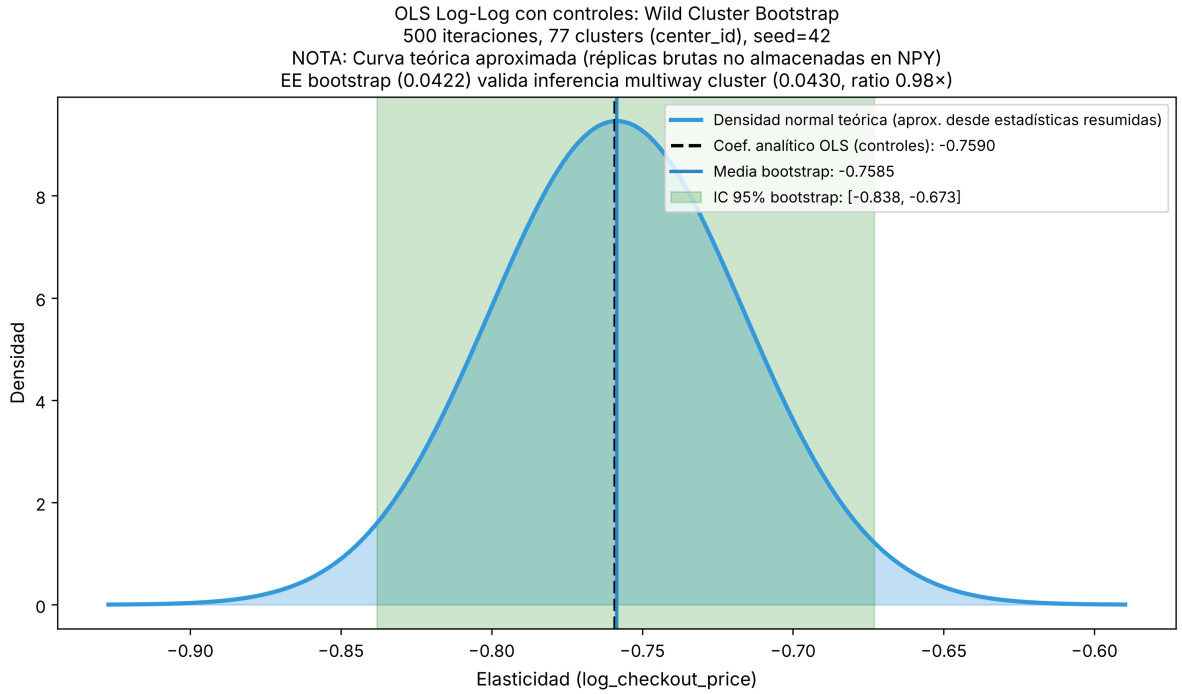


Figura 23

Wild Cluster Bootstrap para OLS log-log con controles: densidad normal teórica aproximada desde estadísticas resumidas (500 iteraciones válidas, 77 clusters, seed=42). NOTA: El NPY certificado no almacena réplicas brutas; la curva es una aproximación normal teórica, no un histograma empírico.

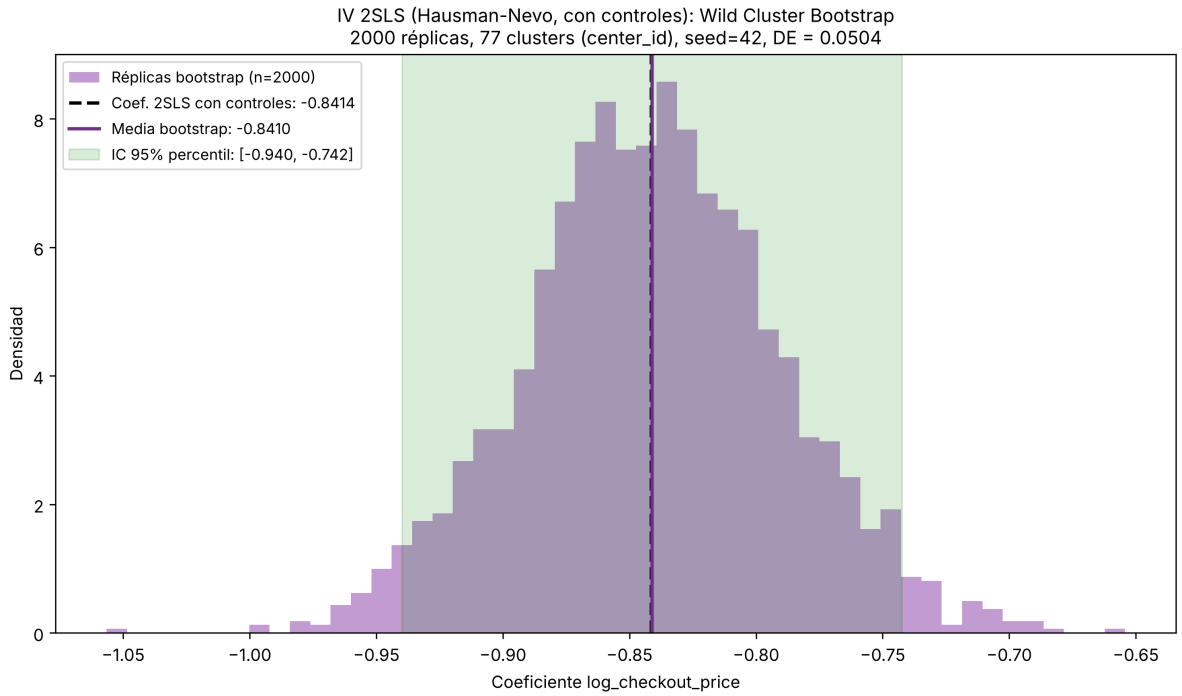


Figura 24

Wild Cluster Bootstrap para IV 2SLS, especificación principal con controles (ambas etapas reestimadas): histograma de las 2 000 réplicas (77 clusters `center_id`*, seed=42). Media* $-0,8410$*, DE* $0,0504$*, IC 95 % percentil* $[-0,940, -0,742]$*. Análisis de sensibilidad; no valida la exclusión de los instrumentos.*

Robustez Adicional: Heterogeneidad Temporal y Placebo Test

Se implementaron dos validaciones de robustez de alto impacto que requieren control por estructura temporal: (1) un modelo de efectos fijos con interacción tiempo-variante para detectar heterogeneidad temporal en la elasticidad, y (2) un placebo test temporal que randomiza la asignación de semanas para validar que la elasticidad estimada no depende de patrones temporales espurios. Ambas se ejecutaron sobre los 456 548 datos reales usando optimización de demeaning iterativo (Frisch-Waugh-Lovell) para evitar problemas de memoria, reduciendo el tiempo de cómputo a minutos en hardware estándar.

Modelo FE con Interacción Tiempo-Variante (log_price × semana)

Para evaluar si la elasticidad-precio varía sistemáticamente entre las 145 semanas del panel, se estimó un modelo con efectos fijos de dos vías (entidad = center_id × meal_id, tiempo = semana) e interacción `log_checkout_price × C(week)`. La hipótesis nula conjunta (Wald test) es que todos los coeficientes de interacción son cero (elasticidad constante en el tiempo).

Tabla 24

Test de Wald: interacción tiempo-variante en modelo Panel FE (2 vías).

Estadístico	Valor
χ^2 (144 gl)	3 032, 55
p-valor	≈ 0
Rechaza H0 (alpha=0,05)	**Sí**

El test **rechaza rotundamente** la igualdad de elasticidad entre semanas ($p \approx 0$). La elasticidad base (semana de referencia) es $-1,5908$, y la elasticidad marginal por semana varía en el rango **-1,8756 a -1,2746** (diferencia de 0,60 unidades). Esto sugiere heterogeneidad temporal significativa no capturada en el modelo principal, que asume elasticidad constante en el tiempo.

La variación semanal observada (rango 0,60, desv. est. ≈0,10) sugiere que factores temporales no observados (estacionalidad, eventos macro, campañas de marketing no registradas) modulan la sensibilidad al precio. Los valores específicos de la Tabla 25 pueden utilizarse como **referencia descriptiva** para la heterogeneidad temporal estimada, sin que esto implique que constituyan reglas causales de fijación de precios por semana.

Placebos Válidos: Precio Futuro y Permutación de Bloques

Dos placebos adicionales validados metodológicamente se ejecutaron para evaluar la robustez de la asociación estimada:

1. Placebo precio futuro (lead): Se estima la demanda presente con el precio de la semana siguiente (`log_checkout_price_lead`) manteniendo la misma especificación (C(category) + C(center_type) + controles). Si el precio futuro "predice"la demanda actual casi tan bien como el precio contemporáneo, sugeriría confusión temporal o tendencias comunes.

- Elasticidad con precio lead: $-0,6172$
- Elasticidad con precio contemporáneo (mismo dataset): $-0,7596$
- N = 452,951 (tras drop de última semana por entidad)
- El coeficiente lead es 81 % del contemporáneo en magnitud; **no es un "pase"limpio**. Aunque es menor, la magnitud no despreciable sugiere que componentes persistentes del precio (tendencia, estacionalidad) explican parte de la covarianza. La interpretación conservadora es que la elasticidad contemporánea captura tanto asociación como tendencia común; el IV y el panel FE se utilizan para evaluar sensibilidad frente a endogeneidad y heterogeneidad, no para aislar un componente causal (el FE no resuelve simultaneidad y la exclusión del IV no es contrastable).

Tabla 25

Elasticidad-precio por semana (efecto marginal = base + interacción).

Semana	Elasticidad	Semana	Elasticidad	Semana	Elasticidad
1	−1,5908	50	−1,6948	99	−1,6897
2	−1,6463	51	−1,5061	100	−1,4579
3	−1,6392	52	−1,3918	101	−1,5241
4	−1,5964	53	−1,4924	102	−1,6817
5	−1,5269	54	−1,5848	103	−1,4543
6	−1,4509	55	−1,7199	104	−1,3663
7	−1,5831	56	−1,6732	105	−1,5335
8	−1,7308	57	−1,6054	106	−1,5549
9	−1,6431	58	−1,4340	107	−1,8756
10	−1,5548	59	−1,5402	108	−1,4931
11	−1,5550	60	−1,6745	109	−1,4738
12	−1,8185	61	−1,7152	110	−1,4550
13	−1,7465	62	−1,5821	111	−1,4136
14	−1,6411	63	−1,6359	112	−1,2746
15	−1,6238	64	−1,7282	113	−1,5045
16	−1,6920	65	−1,7461	114	−1,4507
17	−1,6016	66	−1,7269	115	−1,5374
18	−1,6727	67	−1,7004	116	−1,5090
19	−1,7004	68	−1,7112	117	−1,6163
20	−1,8366	69	−1,6670	118	−1,6448
21	−1,8158	70	−1,5586	119	−1,7216
22	−1,7232	71	−1,6953	120	−1,6007
23	−1,6893	72	−1,7645	121	−1,5690
24	−1,6208	73	−1,7599	122	−1,5153
25	−1,6313	74	−1,6280	123	−1,3965
26	−1,6688	75	−1,7071	124	−1,6047
27	−1,6050	76	−1,7531	125	−1,7114
28	−1,4897	77	−1,7365	126	−1,7077
29	−1,5537	78	−1,6794	127	−1,6804
30	−1,6581	79	−1,6354	128	−1,5949
31	−1,6148	80	−1,5925	129	−1,5348
32	−1,6459	81	−1,6234	130	−1,6543
33	−1,8044	82	−1,6328	131	−1,6653
34	−1,7050	83	−1,5856	132	−1,5750
35	−1,7916	84	−1,6450	133	−1,5846
36	−1,6432	85	−1,5443	134	−1,5686
37	−1,7129	86	−1,5166	135	−1,4582
38	−1,6208	87	−1,5821	136	−1,6031
39	−1,7221	88	−1,5901	137	−1,5860
40	−1,6327	89	−1,6206	138	−1,6261
41	−1,5827	90	−1,6220	139	−1,6130
42	−1,6757	91	−1,6332	140	−1,5484
43	−1,6198	92	−1,6715	141	−1,6394
44	−1,5372	93	−1,6418	142	−1,7215
45	−1,6695	94	−1,6055	143	−1,5622
46	−1,6584	95	−1,5917	144	−1,6066
47	−1,7283	96	−1,5796	145	−1,5523
48	−1,5681	97	−1,4518		
49	−1,5856	98	−1,7076		

2. Placebo permutación de bloques (block permutation): Se permutan bloques de 4 semanas consecutivas del precio (preservando autocorrelación local dentro del bloque) mientras se mantiene demanda y controles en orden original. Esto rompe la alineación temporal precio-demanda a nivel de bloque. **Especificación: OLS log-log con controles emailer, homepage, hubo_aumento, C(category), C(center_type) (sin week FE); 500 iteraciones, seed=42, bloques de 4 semanas; script `scripts/vm/vm_placebos_faltantes.py`.**

- Elasticidad real: $-0,7590$
- Media placebo (500 iteraciones): $-0,4276$
- Std placebo: $0,00171$
- La comparación empírica muestra una reducción sustancial de magnitud respecto del coeficiente real; no se interpreta como prueba de ausencia de confusión temporal.
- La magnitud se reduce sustancialmente respecto del coeficiente contemporáneo ($-0,7590$), pero permanece alejada de cero; por tanto, el placebo indica atenuación al romper la alineación temporal, no ausencia de confusión temporal.

Los placebos aportan evidencia contra algunas explicaciones espurias específicas, aunque el placebo lead muestra que persiste una asociación temporal relevante y que componentes persistentes del precio contribuyen a la covarianza observada.

Limitaciones y Trabajo Futuro

Este estudio presenta una estimación de elasticidad precio-demanda basada en datos observacionales agregados derivados de registros transaccionales de una plataforma de entrega de comidas, pero varias limitaciones estructurales y metodológicas delimitan el alcance de sus conclusiones. Se agrupan en cuatro dimensiones: datos, identificación causal, especificación funcional e inferencia, y generalizabilidad.

Limitaciones de los datos

1. **Ausencia de fecha calendario.** Los datos solo registran número de semana (1–145), sin fecha exacta, por lo que no es posible ubicar el período en un rango de años ni contrastar con eventos externos (inflación, cambios regulatorios, la pandemia de COVID-19, etc.). Los efectos fijos de semana controlan shocks comunes no observados, pero no permiten interpretación económica de estacionalidad. Cualquier generalización temporal debe hacerse con esta limitación explícita.

2. **Ausencia de observaciones con cero pedidos (margen extensivo).** El mínimo de `num_orders` es 13; no existen combinaciones centro-comida-semana con demanda cero en el conjunto de datos. Esto puede generar selección sobre el margen extensivo: si precios altos llevan a cero pedidos y esos ceros no se observan, la elasticidad estimada describe solo la respuesta condicional a demanda positiva, sesgada hacia menor sensibilidad (atenuación hacia cero).

3. **Variable dependiente: transformación logarítmica.** Se usó $\ln($`num_orders`$)$ en el modelo principal (el mínimo observado es 13, por lo que no existen ceros). La interpretación del coeficiente como elasticidad exacta es por tanto válida sin necesidad de corrección `log1p`.

4. **Unidad monetaria y definición de precio.** `checkout_price` es "precio final incluyendo descuento, impuestos y cargos de entrega" (unidades monetarias del conjunto de datos, no necesariamente PEN/soles). El parámetro estimado es elasticidad de pedidos respecto al **precio final de checkout**, no necesariamente el precio del alimento. Esto incluye efectos de delivery, impuestos y descuentos.

5. **Heterogeneidad temporal no modelada (intra-semanal).** El conjunto de datos no captura franjas horarias. Bumagat & Ibana (2025) reportan $-0,42$ (pico) vs $-1,36$ (valle). Queda como extensión futura con datos de mayor granularidad.

Limitaciones de identificación causal

6. **Posible simultaneidad precio-demanda.** Los precios no fueron asignados aleatoriamente; es posible que respondan, al menos parcialmente, a la demanda anticipada. El panel FE con efectos fijos de dos vías controla heterogeneidad no observada entidad-tiempo pero no resuelve simultaneidad. El IV 2SLS intenta corregirla con instrumentos fuertes (`base_price` y precio leave-one-out de otros centros), pero la exclusión no es contrastable: Hansen J rechaza con ponderación heterocedástica $(33,28)$ y no con ponderación agrupada $(0,92, p = 0,34)$, y ambos instrumentos son precios administrativos de la misma cadena que podrían violar la exclusión de la misma forma (*reference pricing*, shocks regionales comunes). El resultado IV ($-0,8414$, EE agrupado 0,050) es análisis de sensibilidad, no estimación causal definitiva.

7. **Variables omitidas no observables.** No se observan: reputación del centro/comida, velocidad de entrega, clima, características sociodemográficas de la zona, gasto en marketing externo. Su inclusión reduciría sesgo de variable omitida.

8. **Asociaciones promocionales, no efectos causales.** Coeficientes de `emailer_for_promotion` (+66 %) y `homepage_featured` (+92 %) son asociaciones OLS; la asignación de promociones es endógena (productos con alta demanda prevista reciben más visibilidad). No se identifican efectos causales de promociones.

9. **Generalizabilidad.** Resultados de un único conjunto de datos (Kaggle/Genpact, contexto geográfico no especificado) sin verificación en otras plataformas, países o períodos.

Limitaciones de especificación funcional e inferencia

10. **Estabilidad y forma funcional RCS.** La parametrización RCS corregida presenta estabilidad numérica adecuada (número de condición $\approx 24,5$). La curva sigue dependiendo de la elección de nudos y debe interpretarse como una aproximación flexible, no como la demanda estructural verdadera.

11. **Control `hubo_aumento`.** Esta variable es función del precio endógeno ($\mathbb{1}$[checkout > base]) y se trata como control exógeno en OLS, IV y CF. Excluirla apenas cambia los resultados (IV $-0,8409$ frente a $-0,8414$; CF en precio medio $-1,5060$ frente a $-1,5041$), pero se documenta como posible *bad control*.

12. **Clustering e inferencia en OLS principal.** Durbin-Watson = $1,199$ indica autocorrelación. EE HC3 = $0,0054$ vs agrupado `center_id` × `meal_id` = $0,0430$ (ratio 7,99x). La inferencia HC3 produce intervalos considerablemente más estrechos y no incorpora la dependencia intra-panel. **Inferencia principal: agrupado por entidad** (EE=0,043, IC 95 % $[-0,843, -0,675]$), consistente con **wild cluster bootstrap** (pesos de Rademacher; 500 iteraciones válidas).

13. **Inferencia Control Function con regresor generado.** Los EE convencionales de la segunda etapa (Tabla A4, EE = $0,018$ para $\hat{v}$) no incorporan la varianza de estimación de $\hat{v}$ en la primera etapa ni la dependencia intra-centro. El proyecto incluye un bootstrap clusterizado canónico que remuestrea 77 centros (`center_id`) y re-estima ambas etapas: 5 000 de 5 000 iteraciones fueron válidas bajo la parametrización RCS canónica (seed=42, nudos P5/P35/P65/P95 fijados en muestra completa, design_info pre-compilado). Para $\hat{v}$ (`v_hat`), el IC 95 % percentil es $[0,664;\ 1,314]$ (media = $+0,9937$, **excluye cero**); para la base `rcs_1`: media = $-0,0376$, IC 95 % $[-0,0769;\ 0,0029]$ (incluye cero). **El coeficiente $\hat{v}$ no debe confundirse con `rcs_1`** (error histórico off-by-one en implementación previa). La elasticidad CF

dispone de banda bootstrap propia (IC 95 % $[-1,630; -1,370]$ en el precio medio). El resultado sigue siendo un análisis de sensibilidad, no una identificación causal, porque la exclusión instrumental no es contrastable.

14. **Panel FE e IV ejecutados con limitaciones documentadas.** El panel FE dos vías y el IV 2SLS se ejecutaron completamente. Limitaciones: Panel FE no elimina simultaneidad; clustering por entidad (`center_id` × `meal_id`) puede no capturar dependencia intra-centro; la exclusión de los instrumentos del IV no es contrastable.

Referencias

Andreyeva, T., Long, M. W., & Brownell, K. D. (2010). The impact of food prices on consumption: A systematic review of research on the price elasticity of demand for food. *American Journal of Public Health*, *100*(2), 216-222. https://doi.org/10.2105/AJPH.2008.151415

Bumagat, J. L., & Ibana, E. (2025, octubre). Economics for managers: Price elasticity of demand for online food delivery services: A comparative analysis of peak and off-peak hours in Metro Manila. https://www.researchgate.net/publication/396269592_ECONOMICS_FOR_MANAGERS_Price_Elasticity_of_Demand_for_Online_Food_Delivery_Services_A_Comparative_Analysis_of_Peak_and_Off-Peak_Hours_in_Metro_Manila

Cameron, A. C., Gelbach, J. B., & Miller, D. L. (2008). Bootstrap-based improvements for inference with clustered errors. *The Review of Economics and Statistics*, *90*(3), 414-427. https://doi.org/10.1162/rest.90.3.414

Cameron, A. C., & Miller, D. L. (2015). A practitioner's guide to cluster-robust inference. *Journal of Human Resources*, *50*(2), 317-372. https://doi.org/10.3368/jhr.50.2.317

Christensen, P., Nino, G., & Osman, A. (2023, junio). *The demand for mobility: Evidence from an experiment with Uber riders* (Working Paper N.º 31330). National Bureau of Economic Research. https://doi.org/10.3386/w31330

Christensen, P., & Osman, A. (2021). *The demand for mobility: Evidence from an experiment with Uber riders* (IZA Discussion Paper N.º 14179). IZA Institute of Labor Economics. https://www.iza.org/publications/dp/14179/

Damayanti, R., Nuryakin, C., & Muchtar, P. A. (2023). Household demand for food prepared at home and food away from home in Indonesia. *Economics and Finance in Indonesia*, *69*(1), 35-46. https://scholarhub.ui.ac.id/efi/vol69/iss1/3/

Davidson, J. (1994, octubre). *Stochastic limit theory: An introduction for econometricians*. Oxford University Press. https://doi.org/10.1093/0198774036.001.0001

Genpact / Analytics Vidhya. (2019). *Food Demand Forecasting*. Consultado el 1 de agosto de 2026, desde https://www.kaggle.com/datasets/kannanaikkal/food-demand-forecasting

Hausman, J. A. (1996). Valuation of new goods under perfect and imperfect competition. En T. F. Bresnahan & R. J. Gordon (Eds.), *The economics of new goods* (pp. 207-248). University of Chicago Press. https://www.nber.org/books-and-chapters/economics-new-goods/valuation-new-goods-under-perfect-and-imperfect-competition

Kahneman, D., Knetsch, J. L., & Thaler, R. H. (1991). Anomalies: The endowment effect, loss aversion, and status quo bias. *Journal of Economic Perspectives*, *5*(1), 193-206. https://doi.org/10.1257/jep.5.1.193

Li, Z., & Wang, G. (2025). On-demand delivery platforms and restaurant sales. *Management Science*, *71*(7), 5788-5804. https://doi.org/10.1287/mnsc.2021.01010

Long, J. S., & Ervin, L. H. (2000). Using heteroscedasticity consistent standard errors in the linear regression model. *The American Statistician*, *54*(3), 217-224. https://doi.org/10.1080/00031305.2000.10474549

Nevo, A. (2001). Measuring market power in the ready-to-eat cereal industry. *Econometrica*, *69*(2), 307-342. https://doi.org/10.1111/1468-0262.00194

Ramsey, J. B. (1969). Tests for specification errors in classical linear least-squares regression analysis. *Journal of the Royal Statistical Society: Series B (Methodological)*, *31*(2), 350-371. https://doi.org/10.1111/j.2517-6161.1969.tb00796.x

Sriwongphanawes, K., & Fukuda, D. (2024). How do fares affect the utilization of ride-hailing services: Evidence from Uber Japan's experiments. *Asian Transport Studies*, *10*, 100121. https://doi.org/10.1016/j.eastsj.2023.100121

Statista. (2024). Online food delivery worldwide – Revenue 2017–2027. https://www.statista.com/outlook/dmo/ecommerce/meal-delivery/worldwide

Stock, J. H., & Yogo, M. (2005). Testing for weak instruments in linear IV regression. En *Identification and inference for econometric models: Essays in honor of Thomas Rothenberg* (pp. 80-108). Cambridge University Press. https://doi.org/10.1017/CBO9780511614491.006

Wooldridge, J. M. (2015). Control function methods in applied econometrics. *Journal of Human Resources*, *50*(2), 420-445. https://doi.org/10.3368/jhr.50.2.420

Zhang, X., & Demirkan, H. (2021). Between online and offline markets: A structural estimation of consumer demand. *Information & Management*, *58*(4), 103485. https://doi.org/10.1016/j.im.2021.103485

Apéndice

Appendix Técnico: Tablas Completas y Diagnósticos Extendidos

Esta sección presenta las tablas completas y resultados de diagnóstico extendido que complementan el texto principal, permitiendo la replicabilidad total de los hallazgos reportados.

Coeficientes RCS Completos (4 Nudos, Percentiles 5, 35, 65, 95) — Especificación Canónica

El modelo RCS (Restricted Cubic Splines) en `log_checkout_price` utiliza **4 nudos explícitos en los percentiles 5, 35, 65 y 95 de la distribución de log-precio** (P5 = 4,80 / 121,28; P35 = 5,56 / 260,02; P65 = 5,86 / 349,26; P95 = 6,46 / 640,23). La especificación canónica genera **3 bases spline** (`rcs_1`, `rcs_2`, `rcs_3`) con **intercepto del modelo separado** (fórmula: `cr(log_checkout_price, knots=(P35,P65), lower_bound=P5, upper_bound=P95, constraints='center') - 1`). Los nudos se fijan en la muestra completa y se aplican vía `build_design_matrices` en bootstrap.

Interpretación de la base RCS: La restricción `constraints='center'` impone que la **función spline ajustada** (la combinación lineal de las tres bases) sea lineal fuera de los nudos de frontera [P5, P95]; su primera derivada es constante en las colas (precios $\leq$ P5 y $\geq$ P95) y su segunda derivada es cero. Las columnas individuales `rcs_1`, `rcs_2`, `rcs_3` **no deben identificarse** como componentes "lineal" y "no lineales" separadas; son una base matricial cuyo efecto conjunto produce la forma funcional. Con esta base, `rcs_1` por sí sola no es lineal en log-precio, por lo que $H_0 : \beta_{\texttt{rcs_2}} = \beta_{\texttt{rcs_3}} = 0$ **no** es una hipótesis de linealidad (en el OLS su Wald vale 15 323, frente a 3 607,28 del contraste correcto). La linealidad se contrasta comparando modelos anidados: log-log con controles frente a RCS (2 g.l.).

El contraste F anidado entre la especificación lineal y la RCS (2 g.l. num., 456 526 g.l. den.) produce $F = 3\,607,28$, $p \approx 0$. La RCS corregida alcanza R^2 ajustado $= 0,53795$ y AIC $= 1\,124\,067,47$; su AIC es inferior al del semi-log con controles ($1\,125\,017,90$), aunque la elección de la forma funcional también se fundamenta en la no linealidad estimada.

Regresión Cuantil Completa (5 Cuantiles, IC Analíticos)

Tabla extendida con resultados puntuales, errores estándar analíticos e intervalos de confianza al 95 % para cada cuantil. Modelo: log-log con controles (misma especificación principal, Eq. (3)).

La progresión monotónica de la elasticidad ($-0,6685 \rightarrow -1,0068$) es consistente con heterogeneidad sistemática: la demanda es más elástica en la cola superior de la distribución condicional. La anchura de los IC analíticos es estrecha (0,018–0,026) por el tamaño muestral y porque ignoran la correlación intra-panel; con inferencia agrupada serían más anchos, como ocurre con el OLS (EE 0,0034 HC3 frente a 0,043 agrupado).

Tabla A1

Coeficientes de la especificación RCS-OLS canónica (3 bases + intercepto + controles), muestra completa.

Término	Coeficiente	EE conv.	EE HC3	EE agrupado (entidad)
Intercept	4,7472	0,0034	0,0039	0,0325
`rcs_1`	0,0037	0,0034	0,0040	0,0291
`rcs_2`	−0,3770	0,0032	0,0036	0,0292
`rcs_3`	−1,0668	0,0081	0,0078	0,0378
Controles (categoría, tipo centro, promociones, `hubo_aumento`)	Incluidos	–	–	–

Nota. $N = 456\,548$. RCS canónica: 4 nudos P5/P35/P65/P95 (precios 121,28 / 260,02 / 349,26 / 640,23), 3 bases (`rcs_1`, `rcs_2`, `rcs_3`), intercepto explícito, `constraints='center'`, −1; no existe `rcs_0`. Los coeficientes de cada base no tienen interpretación aislada; la elasticidad es la derivada de la combinación (Figura 11). Los coeficientes de la especificación CF (con $\hat{v}$) están en la Tabla A4. Fuente: `scripts/analysis/iv_controles_diagnosticos.py`; `src/rcs_utils.py`.

Tabla A2

Regresión cuantil completa: elasticidad precio por cuantil con IC analítico al 95 %.

Cuantil (τ)	Elasticidad	EE analítico	IC 95 % Inf.	IC 95 % Sup.	Anchura IC
0.10	−0,6685	0,0066	−0,681	−0,656	0,026
0.25	−0,733	0,0064	−0,745	−0,720	0,025
0.50 (mediana)	−0,7748	0,0059	−0,786	−0,763	0,023
0.75	−0,876	0,0047	−0,885	−0,867	0,018
0.90	−1,0068	0,0051	−1,017	−0,997	0,020

Nota. $N = 456\,548$. EE e IC analíticos de *statsmodels* QuantReg (suponen independencia entre observaciones; no preservan la dependencia panel). Modelo log-log con controles. Fuente: elaboración propia.

Diagnósticos IV Función de Control (Wooldridge 2015) — Detalle

Detalle completo de la primera y segunda etapa del enfoque de *función de control* para IV no-lineal.

Primera etapa

Tabla A3

Primera etapa Control Function: `log_checkout_price` *sobre instrumentos + controles.*

Variable	Coeficiente	EE	p-valor
Intercept	-0,2159	0,0024	$< 0,001$
`log_base_price`	0,2798	0,0009	$< 0,001$
`log_precio_prom_otros_centros`	0,7560	0,0009	$< 0,001$
Controles (categoría, tipo centro, promociones)	Incluidos	–	–

Nota. $N = 456\,544$. $R^2 = 0,9767$. Instrumentos: log_base_price, log_precio_prom_otros_centros. Fuente: elaboración propia.

$R^2 = 0,9767$; F overall $= 9,59 \times 10^5$ (incluye controles; no mide fuerza de los instrumentos). R^2 parcial de Shea (una endógena = R^2 parcial conjunto de los instrumentos) $= 0,9226$. F de instrumentos excluidos (q=2): $2,72 \times 10^6$ (homocedástico), $1,43 \times 10^6$ (HC1), $2,18 \times 10^5$ (agrupado por `center_id`). Contribución única condicionada al otro instrumento: `log_precio_prom_otros_centros` R^2 parcial $0,6065$, $F = 7,04 \times 10^5$; `log_base_price` R^2 parcial $0,1675$, $F = 9,18 \times 10^4$. Valor crítico de tamaño de Stock-Yogo para 2 instrumentos y 1 endógena (10 %): 19,93 (Stock & Yogo, 2005); no existen valores de sesgo relativo para menos de 3 instrumentos.

Segunda etapa con RCS + $\hat{v}$

Tabla A4

Segunda etapa CF-RCS canónica: coeficientes puntuales (muestra completa) e inferencia bootstrap agrupada (5 000 réplicas).

Variable	Coef. puntual	EE conv.	EE HC3	DE bootstrap	IC 95 % bootstrap
Intercept	4,7073	0,0035	0,0039	–	–
`rcs_1`	$-0,0367$	0,0035	0,0040	0,0201	$[-0,0769;\ 0,0029]$
`rcs_2`	$-0,4033$	0,0032	0,0037	0,0260	$[-0,4544;\ -0,3507]$
`rcs_3`	$-1,1971$	0,0084	0,0083	0,0447	$[-1,2795;\ -1,1056]$
$\hat{v}$ (endogeneidad)	**1,0002**	0,0177	0,0213	0,1654	$[0,664;\ 1,314]$
Controles	Incluidos	–	–	–	–

Nota. $N = 456\,544$. RCS canónica: 4 nudos P5/P35/P65/P95, 3 bases, intercepto explícito, `constraints='center'`, -1. Bootstrap: 5 000 réplicas agrupadas por `center_id` (seed=42, 77 clusters), ambas etapas reestimadas, nudos fijos (medias bootstrap: $\hat{v} = 0,9937$; `rcs_1`$= -0,0376$; `rcs_2`$= -0,4037$; `rcs_3`$= -1,1969$). DE bootstrap = error estándar bootstrap. Tests puntuales: exogeneidad $F = t^2 = 3\,177,9$; no linealidad (F anidado CF lineal vs. CF-RCS, 2 g.l.) $= 3\,335,4$. Elasticidad CF: $-1,5041$ en el precio medio (IC $[-1,630;\ -1,370]$); $-1,3945$ en la mediana (IC $[-1,534;\ -1,249]$). R^2 ajustado $= 0,5412$. Fuente: `reports/certified/iv_cf_diagnosticos_v325.json`, `bootstrap_cf_canonical_replicas.json`; código: `src/modeling.py::modelo_iv_control_function()`.

Inferencia para el regresor generado $\hat{v}$ (bootstrap canónico): El proyecto incluye bootstrap clusterizado canónico para el regresor generado: remuestreo de 77 centros (`center_id`) y re-estimación de ambas etapas. Bajo la parametrización RCS canónica (nudos P5/P35/P65/P95 fijados en muestra completa, 3 bases, design_info pre-compilado), las 5 000 iteraciones fueron válidas (seed=42); para $\hat{v}$ (`v_hat`), el IC 95 % percentil es $[0,664;\ 1,314]$ (media bootstrap $= +0,9937$, **excluye cero**). Para la base `rcs_1`: media bootstrap $= -0,0376$, IC 95 % $[-0,0769;\ 0,0029]$ (incluye cero). Los coeficientes puntuales (muestra completa) son $\hat{v} = 1,0002$ y `rcs_1` $= -0,0367$. **El coeficiente $\hat{v}$ no debe confundirse con `rcs_1`** (error histórico off-by-one en implementación previa B2). La DE bootstrap de $\hat{v}$ (0,1654) coincide con su EE agrupado analítico (0,166), lo que respalda la inferencia bootstrap; el EE convencional (0,0177) la subestima unas nueve veces. Fuente: `reports/certified/bootstrap_vhat_canonical.json` y `bootstrap_cf_canonical_replicas.json`.

Trazabilidad de la curva de elasticidad CF-RCS (Figura 22 Panel C).. Desde V3.2.5 el Panel C usa la curva evaluada con los **coeficientes puntuales** de la muestra completa y una banda percentil del 95 % construida con la derivada de la curva en cada una de las 5 000 réplicas bootstrap (`reports/certified/bootstrap_cf_canonical_replicas.npz`, réplicas brutas sin pickle; grilla 50–800, 200 puntos; elasticidad por diferencia central). Estimando de referencia: elasticidad CF puntual en el precio medio (332,24) $= -1,5041$ y en la mediana (296,82) $= -1,3945$. Versiones previas graficaban una "curva de medias bootstrap" (coeficientes promedio de las réplicas; $-1,5031$ en el nodo 332,66 y $-1,3839$ en el nodo 294,97, archivo `reports/certified/cf_elasticidad_curve.npy`); ese archivo se conserva como referencia histórica, pero no es un estimando reportado.

Test RESET — Detalle Numérico Extendido

Test conjunto: $F(2, 456\,526) = 153,07$, $p \approx 3,5 \times 10^{-67}$. Ambos términos son altamente significativos, lo que es consistente con misspecification funcional cuadrática y cúbica.

Comparación de Especificaciones: Resumen Numérico

Tabla A5

Test RESET extendido: coeficientes de potencias de valores ajustados.

Término	Coeficiente	EE	p-valor
$\hat{y}^2$	0,0023	0,0002	$< 0,001$
$\hat{y}^3$	$-0,0001$	0,0000	$< 0,001$

Nota. $N = 456\,548$. Modelo log-log con controles. Test conjunto: $F(2, 456\,526) = 153,07$, $p \approx 3,5 \times 10^{-67}$. Fuente: elaboración propia.

Tabla A6

Resumen comparativo de todas las especificaciones estimadas.

Modelo	Elasticidad	EE (método)	IC 95 %	R^2 adj.	AIC	N
OLS log-log base	$-0,9516$	0,0034 (HC3)	$[-0,958, -0,945]$	0,1421	1 406 573	456 548
OLS log-log controles (principal)	$-0,759$	0,043 (agrupado entidad)	$[-0,843, -0,675]$	0,5307	1 131 222	456 548
OLS semi-log controles	$-1,0742^{*}$	0,006 (HC3, $\times \bar{P}$)	$[-1,086, -1,062]$	0,5370	1 125 018	456 548
Panel FE (2 vías)	$-1,5985$	0,024 (agrupado entidad)	$[-1,645, -1,552]$	0,3215†	–	456 548
IV 2SLS (2 inst., controles)	$-0,8414$	0,050 (agrupado centro)	$[-0,940, -0,743]$	–	–	456 544
IV justo identificado (`base_price`, controles)	$-0,8545$	0,047 (agrupado centro)	$[-0,948, -0,761]$	–	–	456 544
RCS OLS (P5/P35/P65/P95)	$-1,4429$ (P50)‡	bootstrap centro	$[-1,598, -1,277]$	0,5380	1 124 067	456 548
IV Control Function (RCS $+\hat{v}$)	$-1,5041$ (precio medio)‡	bootstrap centro	$[-1,630, -1,370]$	0,5412	–	456 544
Quantile Reg. $\tau = 0,1$	$-0,6685$	0,0066 (analítico)	$[-0,681, -0,656]$	–	–	456 548
Quantile Reg. $\tau = 0,25$	$-0,733$	0,0064 (analítico)	$[-0,745, -0,720]$	–	–	456 548
Quantile Reg. $\tau = 0,5$	$-0,7748$	0,0059 (analítico)	$[-0,786, -0,763]$	–	–	456 548
Quantile Reg. $\tau = 0,75$	$-0,876$	0,0047 (analítico)	$[-0,885, -0,867]$	–	–	456 548
Quantile Reg. $\tau = 0,9$	$-1,0068$	0,0051 (analítico)	$[-1,017, -0,997]$	–	–	456 548

Nota. EE = error estándar; IC = intervalo de confianza; AIC = criterio de información de Akaike; N = número de observaciones. Agrupado entidad = `center_id` × `meal_id`; agrupado centro = `center_id`. Los IC de RCS y CF son percentiles bootstrap punto a punto agrupados por centro (RCS: 2 000 réplicas, en P50; CF: 5 000 réplicas, ambas etapas, en el precio medio). Fuente: elaboración propia.

* Evaluada en precio promedio (332,24): $\hat{\beta}_{\text{price}} \times \bar{P}$. † R^2 within. ‡ Elasticidad puntual variable según nivel de precio (ver Figuras 11 and 22); en el precio medio, RCS-OLS $= -1,5120$ y CF $= -1,5041$.

Tipos de estimando (no son directamente comparables entre filas). Cada fila corresponde a un estimando distinto: OLS base/controles e IV = proyección log-log (elasticidad constante por construcción); Semi-log = elasticidad equivalente evaluada en precio promedio (*), no constante; Panel FE = elasticidad *within* (neta de efectos fijos entidad-tiempo), no comparable a corte transversal; RCS e IV Control Function = elasticidad puntual variable según nivel de precio; la fila CF reporta la evaluación puntual en el precio medio (332,24) como referencia; Quantile Reg. = elasticidad condicional a cada cuantil de la demanda, no elasticidad de la media condicional.