Elasticidad Precio-Demanda en el Servicio de Delivery de Comidas: Evidencia desde Datos Transaccionales

Jharol André Vilca Ramos
Estudiante de Ingeniería Industrial y Ciencia de Datos

Resumen

Este estudio examina la relación entre el precio final de checkout y la demanda en una plataforma de delivery de comidas, utilizando datos transaccionales de 456,548 observaciones (semana × centro de distribución × tipo de comida) del conjunto de datos público *Food Demand Forecasting* (Kaggle/Genpact). Se estimaron múltiples especificaciones complementarias: (1) OLS log-log con controles (elasticidad promedio = −0,7513, IC 95 % clusterizado [−0,833, −0,669]); (2) Panel con efectos fijos de dos vías (entidad y tiempo, elasticidad within = −1,5755, EE clusterizado por entidad = 0,0236); (3) Variables instrumentales 2SLS con instrumentos tipo Hausman-Nevo (elasticidad = −0,9487, EE robusto = 0,0032), donde el test de Hansen J ($\chi^2 = 320$, $p \approx 0$) rechaza la validez conjunta de los instrumentos, por lo que el resultado IV se presenta como análisis de sensibilidad, no como estimación causal definitiva. Los tests de especificación (RESET $F = 119{,}57$, $p \approx 0$; RCS Wald $\chi^2(3) = 10\,279$, $p \approx 0$) rechazan la linealidad log-log, y la regresión cuantil revela heterogeneidad sistemática ($\tau = 0{,}1$: −0,66 a $\tau = 0{,}9$: −1,00). La conclusión principal es que la elasticidad precio-demanda **no es un parámetro escalar constante**: su magnitud depende del nivel de precio, la categoría de comida, el momento temporal y la fuente de variación explotada. Se incluye capa SQL + BI (SQLite + 6 CSVs para Power BI/Looker Studio) y pipeline reproducible completo en 10 notebooks Jupyter.

Palabras Claves: elasticidad precio-demanda, delivery de comidas, econometría aplicada, regresión log-log, datos transaccionales, panel data, variables instrumentales, 2SLS, efectos fijos, reproducible research, python, sqlite, business intelligence

Introducción

El crecimiento sostenido de las plataformas de *food delivery* ha transformado los hábitos de consumo alimentario urbano en la última década. Según estimaciones de mercado, el sector de entrega de comidas a domicilio ha experimentado tasas de crecimiento anual compuesto superiores al 10 % en múltiples economías, impulsado por la penetración de smartphones, la urbanización y, más recientemente, por cambios de comportamiento tras la pandemia de COVID-19 (Statista, 2024). En este contexto, comprender cómo responde la demanda ante cambios de precio no es solo un ejercicio académico: es una entrada crítica para la sostenibilidad económica de las plataformas, el diseño de estrategias comerciales (promociones, *dynamic pricing*, suscripciones) y la evaluación de políticas públicas relacionadas con el acceso a la alimentación y la regulación de mercados digitales.

La elasticidad precio de la demanda —definida como el cambio porcentual en la cantidad demandada ante un cambio porcentual en el precio— es el parámetro central para cuantificar esta sensibilidad. Sin embargo, la evidencia empírica disponible para el segmento específico de *delivery* de comidas sigue siendo limitada. La mayoría de los estudios existentes se centran en comida fuera del

hogar (*food away from home*, FAFH) en sentido amplio (Andreyeva et al., 2010; Damayanti et al., 2023) o en transporte por aplicación (Christensen & Osman, 2021), pero escasean las estimaciones basadas en datos transaccionales reales de plataformas de entrega de comidas. Li y Wang (2025) confirman explícitamente esta brecha en *Management Science*, señalando la ausencia de estudios empíricos previos que midan la elasticidad en plataformas *on-demand* de comida con datos de transacciones observadas.

Este estudio cubre esa brecha examinando la relación entre precio final de checkout y demanda en un contexto real de *delivery* de comidas, utilizando un conjunto de datos transaccionales de 456,548 observaciones (semana × centro de distribución × tipo de comida) provenientes de la competencia pública *Food Demand Forecasting* de Genpact/Analytics Vidhya, alojada en Kaggle (Genpact / Analytics Vidhya, 2019). Se estimaron múltiples especificaciones: un modelo log-log con controles produce una elasticidad promedio de $-0{,}7513$ (EE clusterizado por centro: 0.0421, IC 95 % $[-0{,}833, -0{,}669]$); el panel con efectos fijos de dos vías da $-1{,}5755$ (EE clusterizado por entidad 0.0236); y la estrategia IV 2SLS con instrumentos tipo Hausman-Nevo produce $-0{,}9487$ (EE robusto 0.0032), aunque el test de Hansen J ($\chi^2 = 320$, $p \approx 0$) rechaza la validez conjunta de los instrumentos, limitando su interpretación causal. Crucialmente, los tests de especificación (RESET $F = 119{,}57$, $p \approx 0$; RCS Wald $\chi^2(3) = 10\,279$, $p \approx 0$) rechazan la linealidad log-log, y la regresión cuantil muestra heterogeneidad sistemática ($-0{,}66$ a $-1{,}00$ según cuantil). La conclusión central es que la elasticidad **no es un parámetro escalar constante**: varía con el nivel de precio, la categoría, el momento y la fuente de identificación.

Relación con trabajo previo

Este proyecto constituye una segunda iteración metodológica de un estudio previo del autor sobre el mismo tema, desarrollado en un contexto académico y publicado con anterioridad. Aquella primera versión (v1) utilizó una encuesta propia analizada en hoja de cálculo, y presentó limitaciones metodológicas en el diseño muestral identificadas durante la revisión del curso. La presente versión **no reutiliza esos datos**: emplea una fuente transaccional real, un pipeline reproducible de análisis en Python (carga, merge, construcción de variables, modelado, validación) y una comparación sistemática con literatura verificada cita por cita. Por tanto, los resultados no son directamente comparables entre ambas versiones en sentido estricto; representan una evolución en la capacidad técnica de análisis y en el rigor metodológico del autor.

Objetivos y contribuciones

El objetivo general es estimar la elasticidad precio-demanda en un contexto real de *delivery* de comidas y contextualizar el hallazgo dentro de la evidencia empírica existente. Los objetivos específicos son:

1. Construir un pipeline reproducible de limpieza y preparación de datos transaccionales, documentando decisiones críticas (p. ej., el hallazgo de que `base_price` no es un precio mínimo garantizado).

2. Estimar y comparar múltiples especificaciones de modelo de demanda (log-log base, log-log con controles, semi-log con controles) usando criterios cuantitativos (AIC, BIC, R^2 ajustado) y cualitativos (interpretabilidad, advertencias numéricas).

3. Validar formalmente los supuestos estadísticos del modelo seleccionado (heterocedasticidad con Breusch-Pagan y errores robustos HC3, multicolinealidad con VIF, normalidad con Jarque-Bera y Q-Q plot).

4. Ubicar el resultado propio dentro de una comparación estructurada con literatura verificada (meta-análisis FAFH, estudio indonesio con LA/AIDS, experimento de movilidad con Uber, evidencia emergente en *delivery on-demand*).

Las contribuciones del trabajo son: (a) una estimación de elasticidad (−0,7513) basada en datos transaccionales reales de *delivery* de comidas, poco común en la literatura; (b) un pipeline reproducible y documentado que permite replicar y extender el análisis; (c) la verificación de que `base_price` funciona como precio de referencia y no como piso, con 25.43 % de observaciones donde el precio final superó la referencia — hallazgo que, de omitirse, habría sesgado la estimación; y (d) una comparación con literatura donde cada cita fue verificada contra la fuente primaria, descartando un documento generado por IA que contenía errores graves de atribución.

Descripción de los Datos

Fuente y estructura

El conjunto de datos proviene de la competencia *Food Demand Forecasting* de Genpact/Analytics Vidhya, disponible públicamente en Kaggle (Genpact / Analytics Vidhya, 2019). El dataset original está compuesto por tres tablas relacionales:

1. **train.csv**: Registros semanales de pedidos por combinación de centro de distribución (`center_id`) y tipo de comida (`meal_id`). Contiene 456,548 filas y las variables: `week` (semana 1–145), `center_id`, `meal_id`, `checkout_price` (precio final pagado por el cliente), `base_price` (precio de referencia/lista), `emailer_for_promotion` (binaria, promoción por correo), `homepage_featured` (binaria, destacada en página principal), `num_orders` (número de pedidos, variable objetivo).

2. **meal_info.csv**: Metadatos de las comidas. Contiene `meal_id`, `category` (categoría de comida) y `cuisine` (tipo de cocina: *indian*, *italian*, *thai*, *mexican*, *continental*, *chinese*).

3. **fulfilment_center_info.csv**: Metadatos de los centros. Contiene `center_id`, `center_type` (*TYPE_A*, *TYPE_B*, *TYPE_C*), `region_code` (código de región), `city_code` (código de ciudad), `op_area` (área operativa en km^2).

Período y cobertura

Los datos cubren 145 semanas de operación. Cada observación corresponde a una combinación única de `week` × `center_id` × `meal_id`, lo que permite modelar la demanda a nivel granular semanal por centro y producto. **El dataset no incluye fecha calendario exacta, solo el número de semana**, por lo que no es posible alinear las observaciones con festivos, eventos externos o un rango de años específico; cualquier referencia a un período calendario concreto en versiones previas de este documento fue un error y se ha corregido en esta versión.

Variables clave

Tras unir las tres tablas mediante `meal_id` y `center_id` (merge *left* que preserva las 456,548 filas originales de `train`), se obtiene un *DataFrame* final de 456,548 filas y 20 columnas, sin valores nulos en ninguna variable. Las variables principales para el análisis de elasticidad son:

- `checkout_price` (precio final de checkout): precio efectivamente cobrado al cliente esa semana, *incluyendo descuento, impuestos y cargos de entrega* (unidades monetarias del dataset original).

- `base_price` (precio base de referencia): precio de lista o de referencia, actualizado con menor frecuencia (unidades monetarias del dataset original).

- `num_orders`: cantidad de pedidos (variable dependiente, conteo semanal por centro-comida).

- `emailer_for_promotion`, `homepage_featured`: indicadores binarios de actividad promocional.

- `category`, `center_type`: variables categóricas para efectos fijos.

Tabla 1

Estadística descriptiva de las variables clave (antes de transformaciones).

	Precio final (`checkout_price`)	Precio base (`base_price`)	N. pedidos (`num_orders`)	Var. precio (`variacion_precio`)
Media	332.24	354.16	261.87	21.92
Desv. est.	152.94	160.72	395.92	48.50
Mínimo	2.97	55.35	13	−185,30
P25	228.95	243.50	54	−1,00
Mediana	296.82	310.46	136	1.00
P75	445.23	458.87	324	16.52
Máximo	866.27	866.27	24,299	561.60

Nota. `variacion_precio` = `base_price` − `checkout_price`. Valores positivos indican que el precio final fue menor que la referencia (descuento); negativos, que fue mayor (aumento). $N = 456,548$ observaciones.

Tabla 1 resume la estadística descriptiva de las variables numéricas clave antes de transformaciones.

La dispersión considerable de `num_orders` (desviación estándar 1.5 veces la media, máximo 24,299 vs. mediana 136) y su asimetría marcada a la derecha motivan la transformación logarítmica descrita en la sección Preparación y Limpieza de Datos. El precio final promedio (332.24 unidades monetarias del dataset) es inferior al precio base promedio (354.16 unidades monetarias del dataset), consistente con una prevalencia neta de descuentos, aunque –como se detalla en la siguiente sección– en 25.43 % de los casos el precio final superó a la referencia.

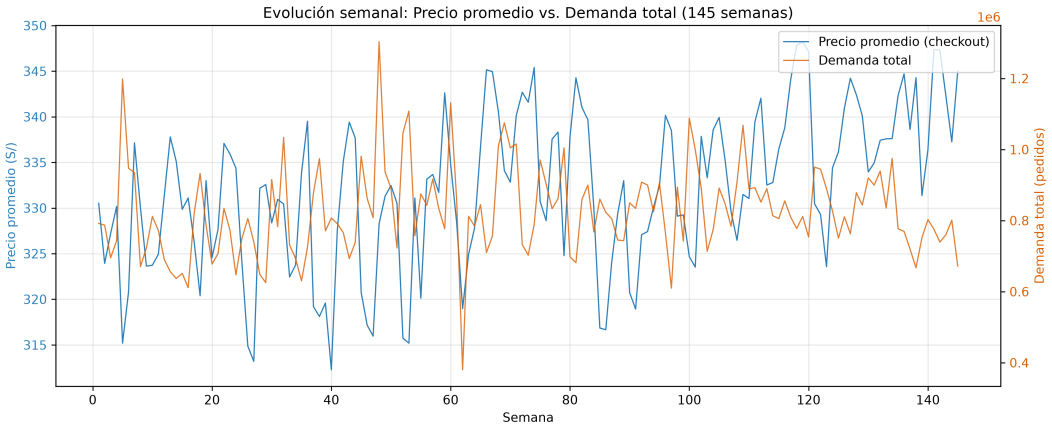


Figura 1

Evolución semanal del precio promedio de checkout y la demanda agregada (145 semanas). Muestra la dinámica temporal conjunta de precio y cantidad.

Preparación y Limpieza de Datos

El pipeline de preparación sigue tres etapas secuenciales, implementadas en Python (`src/data_prep.py`) y diseñadas para ser totalmente reproducibles: (1) carga y unión de tablas, (2) construcción de variables derivadas de precio, (3) transformaciones logarítmicas para modelado. Cada etapa incluye aserciones de integridad.

Carga y unión de tablas

Las tres tablas se leen desde CSV y se unen mediante `meal_id` y `center_id` con *left join* usando `train` como tabla base:

```
train.merge(meal_info, on='meal_id', how='left') \
```

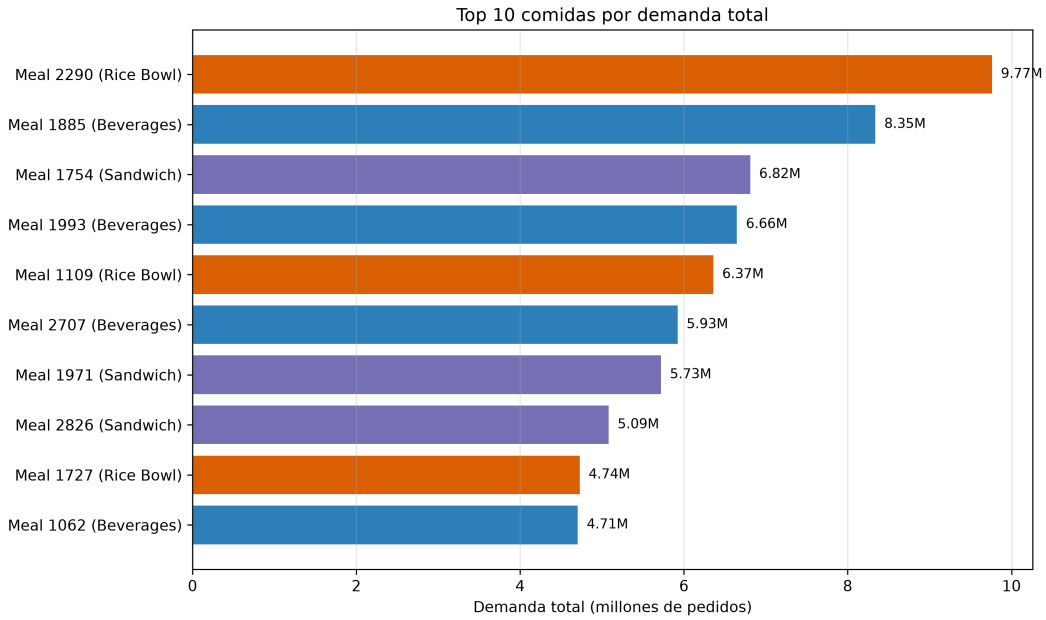


Figura 2

Top 10 comidas por demanda total acumulada (145 semanas). Muestra la concentración de la demanda en pocos productos estrella.

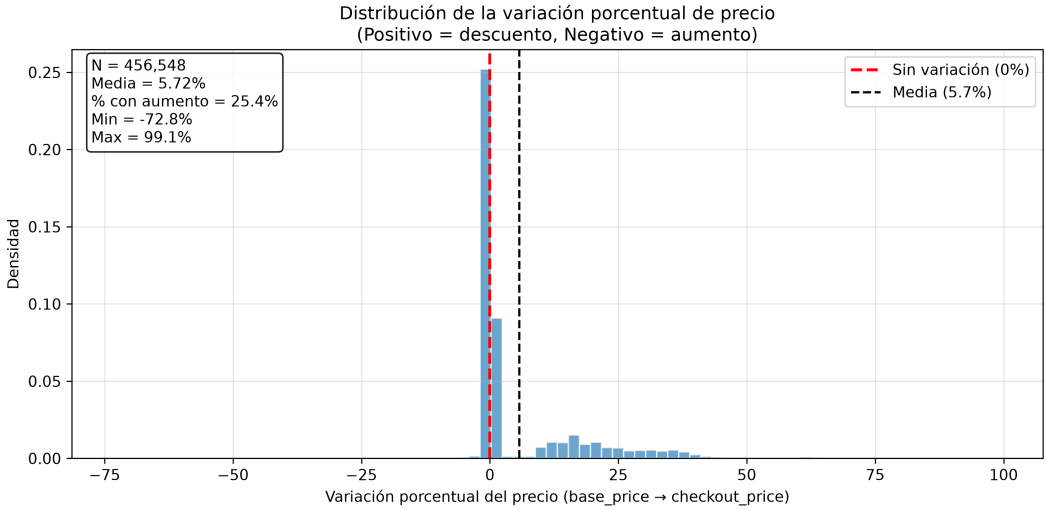


Figura 3

Distribución de la variación porcentual de precio (`base_price` → `checkout_price`). Positivo = descuento, Negativo = aumento. Media = 6.19 %, 25.43 % con aumento.

```
.merge(centers, on='center_id', how='left')
```

Se verifica que el número de filas se mantenga idéntico al de `train` original (456,548), descartando duplicados en las tablas de referencia o pérdidas por claves no coincidentes. Tras el merge, no se detectan valores nulos en ninguna columna, confirmando que para cada combinación presente en `train` existe información completa en `meal_info` y `fulfilment_center_info`.

Construcción de variables de precio

La variable `base_price` actúa como precio de referencia, no como un precio mínimo garantizado. Al calcular la diferencia `base_price` − `checkout_price`, se esperaba encontrar únicamente valores positivos o cero (descuentos). Sin embargo, el hallazgo central de la limpieza fue que **en 25.43 % de las observaciones (116,101 de 456,548), `checkout_price` superó a `base_price`**, produciendo una variación negativa.

Este patrón se verificó exhaustivamente para descartar error de datos: (a) la magnitud de los valores negativos es variada y sustancial (decenas a cientos de unidades), no concentrada en montos fijos pequeños que sugerirían un cargo por servicio; (b) la incidencia está distribuida de forma pareja entre prácticamente todos los centros (del orden de 1,700–1,900 casos por centro entre los principales), descartando un error localizado en una fuente específica. La interpretación es que `base_price` es un precio de lista actualizado con menor frecuencia, mientras que `checkout_price` fluctúa semana a semana por dinámicas de costos, oferta/demanda o decisiones comerciales no observadas.

Se construyen tres variables derivadas:

- `variacion_precio` = `base_price` − `checkout_price` (diferencia absoluta; positiva = descuento, negativa = aumento).
- `variacion_precio_pct` = (`variacion_precio` / `base_price`) × 100 (variación porcentual respecto a la referencia).
- `hubo_aumento` = 1 si `variacion_precio` < 0, 0 en caso contrario (indicador binario de que el precio final superó la referencia).

La decisión de **no excluir** las observaciones con `hubo_aumento` = 1 es deliberada: excluir sistemáticamente los casos donde el precio subió introduciría sesgo de selección, dejando el modelo estimado solo sobre períodos de baja de precio, lo cual no representa el comportamiento real del mercado. La variable `hubo_aumento` se incluye como control candidato en las especificaciones del modelo (la sección Especificaciones del modelo) para capturar cualquier efecto asimétrico de aumentos vs. descuentos.

Transformaciones logarítmicas

Para la especificación log-log de elasticidad (la sección Especificaciones del modelo), se crean las versiones logarítmicas de precio y cantidad:

- `log_checkout_price` = $\ln($`checkout_price`$)$
- `log_num_orders` = $\ln(1 +$ `num_orders`$)$ (`log1p`)

El uso de `log1p` (logaritmo de $1 + x$) en lugar de $\ln(x)$ para `num_orders` garantiza que la transformación esté definida para todos los valores (aunque el mínimo observado es 13, `log1p` es la práctica estándar en variables de conteo y preserva la interpretabilidad de elasticidad para valores pequeños). La distribución de `log_num_orders` se aproxima considerablemente a una forma de campana, mitigando la heterocedasticidad y justificando estadísticamente —no solo teóricamente— la especificación log-log.

Estadísticos descriptivos completos (tras preparación)

Tabla 2 presenta los estadísticos descriptivos de todas las variables numéricas relevantes después de la preparación, incluyendo las transformaciones logarítmicas y las variables de precio derivadas.

Tabla 2

Estadísticos descriptivos completos tras preparación de datos.

Variable	Media	Desv. est.	Mínimo	P25	Mediana	P75	Máximo
`checkout_price`	332.24	152.94	2.97	228.95	296.82	445.23	866.27
`base_price`	354.16	160.72	55.35	243.50	310.46	458.87	866.27
`num_orders`	261.87	395.92	13.00	54.00	136.00	324.00	24,299.00
`variacion_precio`	21.92	48.50	−185,30	−1,00	1.00	16.52	561.60
`variacion_precio_pct`	6.19	13.65	−52,34	−0,33	0.32	5.31	100.00
`hubo_aumento`	0.2543	0.435	0.00	0.00	0.00	1.00	1.00
`log_checkout_price`	5.65	0.48	1.09	5.43	5.69	6.10	6.76
`log_num_orders`	4.79	1.20	2.64	4.01	4.92	5.79	10.10
`emailer_for_promotion`	0.042	0.201	0.00	0.00	0.00	0.00	1.00
`homepage_featured`	0.099	0.299	0.00	0.00	0.00	0.00	1.00

Nota. $N = 456,548$. `hubo_aumento`, `emailer_for_promotion` y `homepage_featured` son binarias (0/1); su media reporta la proporción de unos. `variacion_precio_pct` en puntos porcentuales.

Observaciones destacadas de Tabla 2:

1. La proporción de observaciones con `hubo_aumento` = 1 es 0.2543 (25.43 %), confirmando la magnitud del hallazgo.

2. Las variables promocionales tienen prevalencia baja (`emailer_for_promotion`: 4.2 %; `homepage_featured`: 9.9 %), típico de campañas puntuales.

3. `log_num_orders` tiene media 4.79 y desviación 1.20, con rango aproximado [2.64, 10.10], distribución sustancialmente más simétrica que la variable original.

4. `variacion_precio_pct` tiene media positiva (6.19 %), indicando que en promedio el precio final está por debajo de la referencia, pero con cola izquierda que llega a −52,34 % (aumentos sustanciales respecto al precio base).

El *DataFrame* final resultante (`demanda_limpia.csv`) contiene 456,548 filas y 23 columnas (20 originales + 3 derivadas), listo para la etapa de modelado descrita a continuación.

Marco Metodológico

El presente estudio adopta un enfoque econométrico basado en **mínimos cuadrados ordinarios (OLS)** sobre una especificación **log-log** para estimar la elasticidad precio de la demanda en un servicio de *food delivery*. La variable dependiente es el logaritmo natural del número de órdenes (`log_num_orders`) y la variable explicativa principal es el logaritmo natural del precio de checkout (`log_checkout_price`).

$$\log(\text{num_orders}_i) = \beta_0 + \beta_1 \log(\text{checkout_price}_i) + \varepsilon_i \tag{1}$$

La elección de la especificación log-log obedece a su interpretación directa: el coeficiente β_1 representa la **elasticidad precio de la demanda**, es decir, el cambio porcentual en la cantidad demandada asociado a un cambio del 1 % en el precio. Una elasticidad negativa indica que la demanda responde inversamente al precio (ley de la demanda), mientras que su magnitud informa sobre la sensibilidad de los consumidores.

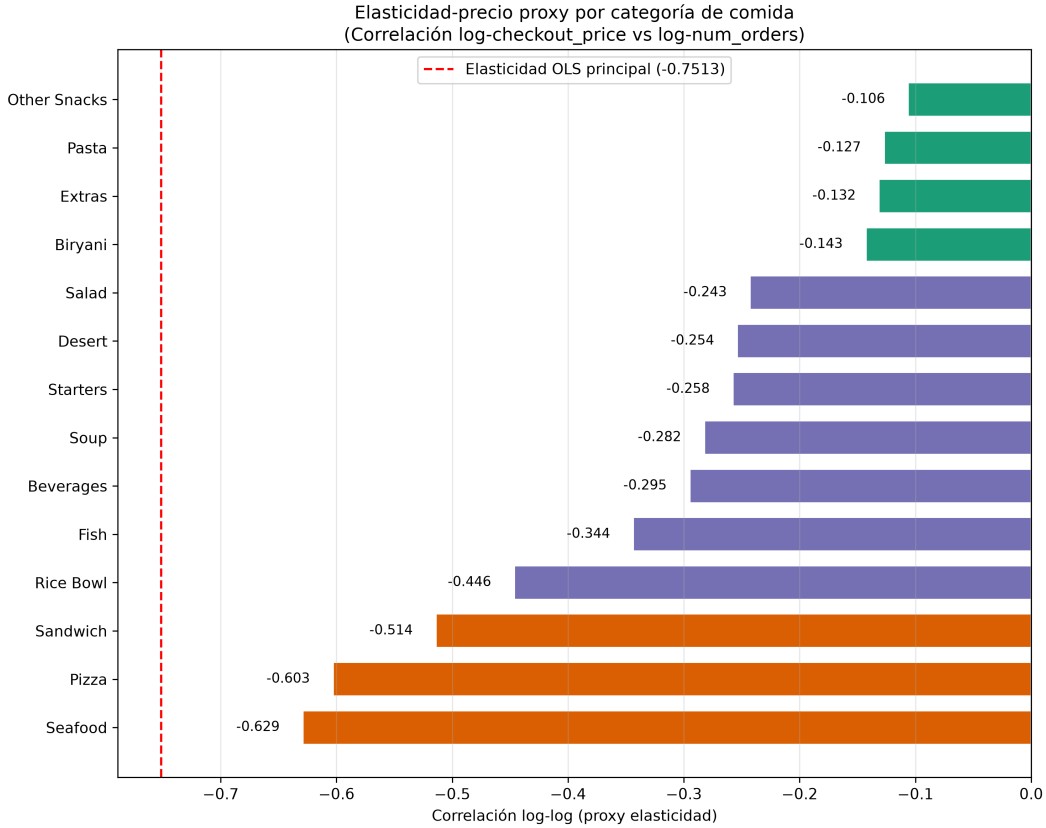


Figura 4

Elasticidad-precio proxy por categoría de comida (Correlación log-log entre `checkout_price` *y* `num_orders`*). Línea roja: elasticidad OLS principal (-0.7513).*

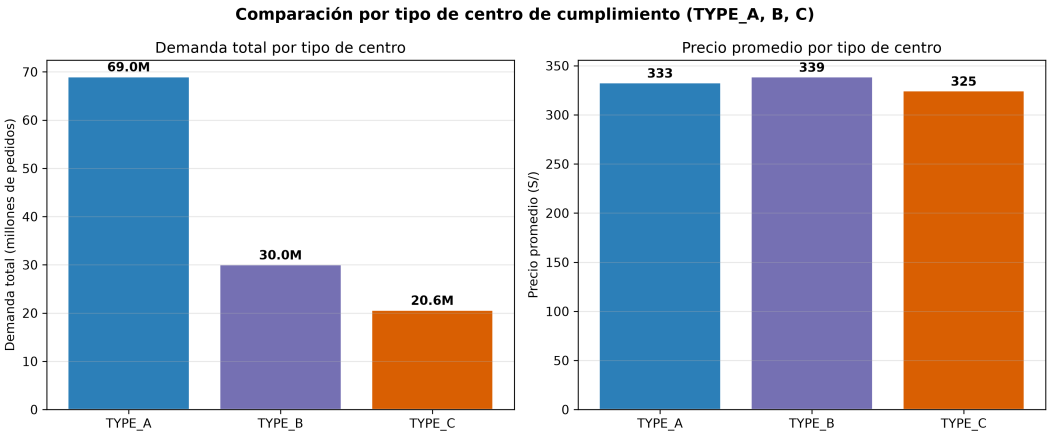


Figura 5

Comparación de demanda promedio por tipo de centro (TYPE_A, TYPE_B, TYPE_C). TYPE_B muestra mayor demanda relativa; TYPE_C, menor.

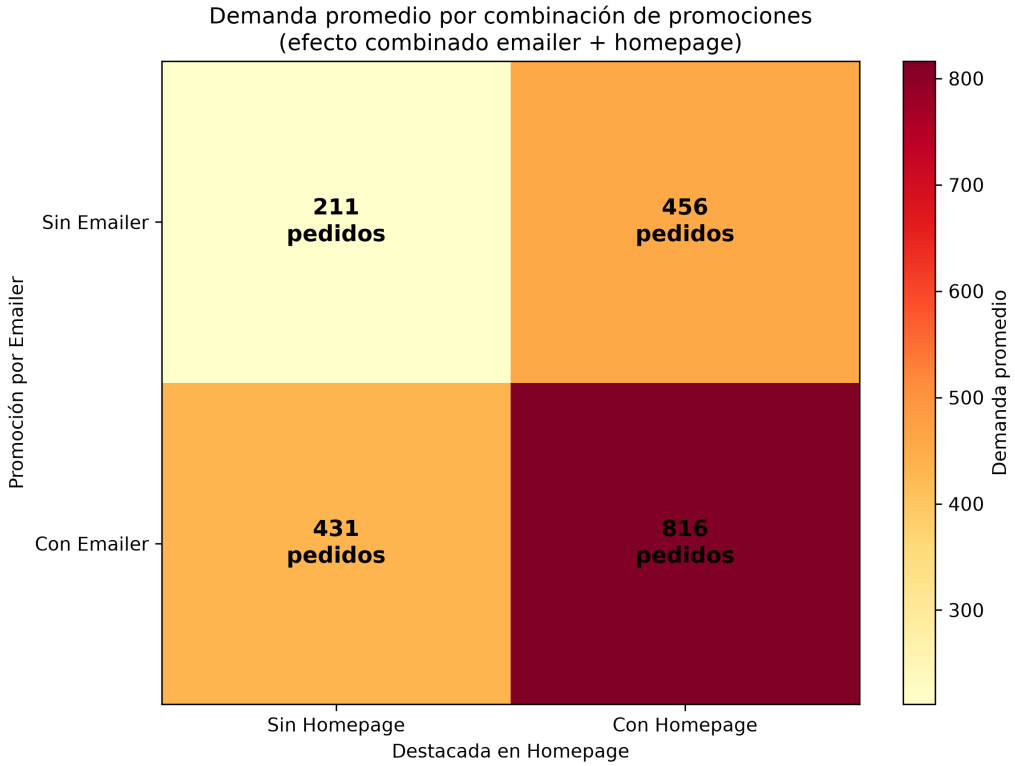


Figura 6

Matriz de efectos promocionales: demanda promedio por combinación de `emailer_for_promotion` *y* `homepage_featured`*. La exposición en homepage tiene mayor impacto marginal que el emailer.*

Justificación de variables de control

Para mitigar sesgos de variable omitida y aislar el efecto asociado del precio sobre la demanda, se incorporan controles que capturan factores de oferta y demanda observables:

- `emailer_for_promotion` (binaria): indica si la comida fue promocionada por correo electrónico. Las promociones aumentan la visibilidad y pueden desplazar la curva de demanda.
- `homepage_featured` (binaria): indica si la comida apareció destacada en la página principal. Al igual que el correo, afecta la exposición del producto.
- `hubo_aumento` (binaria): igual a 1 si el precio de checkout supera el precio base de referencia. Captura posibles efectos de *reference pricing* y aversión a pérdidas (Kahneman et al., 1991).
- `C(category)`: efectos fijos por categoría de comida (13 categorías). Controla preferencias sistemáticas por tipo de comida.
- `C(center_type)`: efectos fijos por tipo de centro de cumplimiento (TYPE_A, TYPE_B, TYPE_C). Captura heterogeneidad operativa y geográfica no observada.

El dataset procesado contiene $N = 456,548$ observaciones a nivel de comida-semana-centro, lo que confiere alta potencia estadística para detectar efectos incluso de magnitud pequeña.

Especificaciones del modelo

Se estiman tres especificaciones anidadas para evaluar robustez y comparar ajustes mediante criterios de información (AIC, BIC) y R^2 ajustado.

Modelo 1: especificación base (log-log simple)

$$\log(\text{num_orders}_i) = \beta_0 + \beta_1 \log(\text{checkout_price}_i) + \varepsilon_i \tag{2}$$

Modelo 2: log-log con controles (especificación principal)

$$\begin{aligned}\log(\text{num_orders}_i) = \beta_0 &+ \beta_1 \log(\text{checkout_price}_i) \\ &+ \beta_2 \text{emailer_for_promotion}_i + \beta_3 \text{homepage_featured}_i \\ &+ \beta_4 \text{hubo_aumento}_i \\ &+ \sum_{k=1}^{13} \gamma_k \mathbb{1}[\text{category}_i = k] \\ &+ \sum_{m=1}^{2} \delta_m \mathbb{1}[\text{center_type}_i = m] + \varepsilon_i\end{aligned} \tag{3}$$

Modelo 3: semi-log con controles (especificación alternativa)

$$\begin{aligned}\log(\text{num_orders}_i) = \beta_0 &+ \beta_1 \text{checkout_price}_i \\ &+ \beta_2 \text{emailer_for_promotion}_i + \beta_3 \text{homepage_featured}_i \\ &+ \beta_4 \text{hubo_aumento}_i \\ &+ \sum_{k=1}^{13} \gamma_k \mathbb{1}[\text{category}_i = k] \\ &+ \sum_{m=1}^{2} \delta_m \mathbb{1}[\text{center_type}_i = m] + \varepsilon_i\end{aligned} \tag{4}$$

En el Modelo 3, el coeficiente β_1 se interpreta como *semi-elasticidad*: el cambio porcentual en la demanda por cada unidad monetaria de aumento en el precio (no elasticidad constante). Tabla 3 resume las variables incluidas en cada especificación; los criterios de ajuste (AIC, BIC, R^2) se reportan y comparan en la sección Comparación de modelos, junto con los resultados.

Tabla 3

Variables incluidas en cada especificación del modelo.

Variable	Modelo 1	Modelo 2	Modelo 3
log(checkout_price)	✓	✓	–
checkout_price (nivel)	–	–	✓
emailer_for_promotion	–	✓	✓
homepage_featured	–	✓	✓
hubo_aumento	–	✓	✓
C(category) (13 dummies)	–	✓	✓
C(center_type) (2 dummies)	–	✓	✓

Validación de supuestos: procedimiento

La validez inferencial de OLS requiere verificar los supuestos clásicos. Los resultados numéricos de cada test se reportan en la sección Validación de supuestos: resultados (heterocedasticidad, multicolinealidad, normalidad y autocorrelación); aquí se documenta el procedimiento y la decisión asociada a cada uno.

- **Heterocedasticidad (Breusch-Pagan)**: H_0: varianza de los errores constante vs. H_1: varianza función de los regresores. De rechazarse H_0, se reportan errores estándar robustos **HC3**, válidos asintóticamente en muestras grandes (Davidson, 1994) y preferibles a HC0/HC1 cuando existe apalancamiento en los datos (Long & Ervin, 2000).
- **Multicolinealidad (VIF)**: calculado sobre las variables numéricas continuas del modelo (`log_checkout_price`, `emailer_for_promotion`, `homepage_featured`, `hubo_aumento`). Las dummies de efectos fijos se excluyen del cálculo porque su VIF individual dentro de un conjunto mutuamente excluyente no tiene interpretación estándar.
- **Normalidad de residuos (Jarque-Bera y Q-Q plot)**: H_0: residuos $\sim \mathcal{N}(0, \sigma^2)$. Con $N = 456,548$ se anticipa que la prueba tenga potencia excesiva y rechace desviaciones mínimas sin relevancia práctica; por ello se complementa con inspección visual del gráfico Q-Q.
- **Autocorrelación (Durbin-Watson)**: valores cercanos a 2 indican ausencia de autocorrelación. Dada la estructura de panel (semana × centro × comida), es esperable cierta autocorrelación residual en ausencia de efectos fijos por semana.

Intervalos de confianza por bootstrap: procedimiento

Para obtener intervalos de confianza que no dependan de asunciones de normalidad ni de la estructura de covarianza analítica, se implementa un **bootstrap no paramétrico por remuestreo con reemplazo** sobre el modelo base (Eq. (2)).

1. **Iteraciones**: $B = 1,000$ remuestras bootstrap.
2. **Esquema de remuestreo**: muestreo con reemplazo de tamaño $n = N = 456,548$, preservando la distribución empírica conjunta de todas las variables.
3. **Estimación por iteración**: en cada remuestra $b = 1, \ldots, B$, se ajusta el modelo base y se almacena el coeficiente $\hat{\beta}_1^{(b)}$.
4. **Intervalo de confianza**: percentil 2.5 y 97.5 de la distribución empírica $\{\hat{\beta}_1^{(b)}\}_{b=1}^{B}$.
5. **Reproducibilidad**: semilla fija `seed = 42` (`numpy.random.default_rng`).

El bootstrap se realizó sobre el modelo base por simplicidad computacional; los resultados numéricos se reportan en la sección Intervalos de confianza por bootstrap: resultados.

Resultados Principales

Comparación de modelos

Tabla 4 presenta los criterios de información y bondad de ajuste de las tres especificaciones descritas en la sección Especificaciones del modelo.

Tabla 4

Comparación de modelos alternativos: criterios de información y bondad de ajuste.

Modelo	AIC	BIC	R^2 ajustado	N
Semi-log con controles	1,112,317	1,112,537	0.5377	456,548
Log-log con controles	1,118,513	1,118,733	0.5314	456,548
Log-log base	1,394,427	1,394,449	0.1423	456,548

El modelo *semi-log* con controles presenta el menor AIC y BIC, y el mayor R^2 ajustado (0.5377), indicando un mejor ajuste global. No obstante, el modelo *log-log* con controles ofrece la ventaja de una interpretación directa de la elasticidad-precio como el coeficiente del logaritmo del

precio, manteniendo un R^2 ajustado muy similar (0.5314). Dado el objetivo central de este trabajo —estimar la elasticidad-precio de la demanda—, se selecciona el modelo *log-log* con controles como especificación principal.

Modelo principal: log-log con controles

Tabla 5 presenta los resultados completos del modelo *log-log* con controles. Dada la estructura de panel de los datos (observaciones repetidas por combinaciones centro-comida a lo largo de 145 semanas), la inferencia principal utiliza **errores estándar clusterizados multiway por `center_id` × `meal_id`** (Cameron, Gelbach & Miller, 2011), que permiten correlación arbitraria dentro de cada centro y dentro de cada comida. Los errores HC3 se reportan solo como referencia; no corrigen la autocorrelación intra-panel (Durbin-Watson = 1,195).

Tabla 5

Resultados completos del modelo log-log con controles (variable dependiente: $\log($***`num_orders`***$)$*).* ***Inferencia principal: multiway cluster `center_id` × `meal_id`****. HC3 solo referencia.*

Variable	Coef.	SE Cl.	SE Multiway	t (Multiway)	p	IC 95 % (Multiway)
Intercept	9.0682	0.024	0.068	133.36	<0.001	[8.935, 9.201]
`C(category)[T.Biryani]`	−1.2347	0.007	0.019	−64.98	<0.001	[−1.272, −1.197]
`C(category)[T.Desert]`	−0.6903	0.007	0.021	−32.87	<0.001	[−0.731, −0.649]
`C(category)[T.Extras]`	0.1599	0.007	0.022	7.27	<0.001	[0.117, 0.203]
`C(category)[T.Fish]`	−0.2589	0.010	0.031	−8.35	<0.001	[−0.320, −0.198]
`C(category)[T.Other Snacks]`	−0.3560	0.005	0.017	−20.94	<0.001	[−0.389, −0.323]
`C(category)[T.Pasta]`	−0.9255	0.006	0.019	−48.71	<0.001	[−0.963, −0.888]
`C(category)[T.Pizza]`	0.4756	0.007	0.023	20.68	<0.001	[0.431, 0.521]
`C(category)[T.Rice Bowl]`	1.2474	0.006	0.018	69.30	<0.001	[1.212, 1.283]
`C(category)[T.Salad]`	0.8328	0.006	0.017	48.99	<0.001	[0.799, 0.866]
`C(category)[T.Sandwich]`	0.9604	0.005	0.017	56.49	<0.001	[0.927, 0.994]
`C(category)[T.Seafood]`	−0.3467	0.008	0.025	−13.87	<0.001	[−0.396, −0.298]
`C(category)[T.Soup]`	−0.9220	0.008	0.024	−38.42	<0.001	[−0.969, −0.875]
`C(category)[T.Starters]`	−0.2286	0.006	0.018	−12.70	<0.001	[−0.264, −0.193]
`C(center_type)[T.TYPE_B]`	0.2807	0.003	0.011	25.52	<0.001	[0.259, 0.302]
`C(center_type)[T.TYPE_C]`	−0.3526	0.003	0.011	−32.05	<0.001	[−0.374, −0.331]
`log_checkout_price`	**−0.7513**	0.005	**0.043**	−17.47	<0.001	**[−0.835, −0.667]**
`emailer_for_promotion`	0.5028	0.005	0.016	31.43	<0.001	[0.471, 0.534]
`homepage_featured`	0.6492	0.004	0.015	43.28	<0.001	[0.619, 0.679]
`hubo_aumento`	−0.0024	0.003	0.009	−0.27	0.787	[−0.020, 0.015]

Nota: Los errores estándar multiway son ≈ 8× mayores que los HC3 para `log_checkout_price` (0.043 vs 0.005), reflejando la dependencia intra-panel no capturada por HC3. El IC 95 % multiway [−0,835, −0,667] es la inferencia principal; el IC HC3 [−0,762, −0,741] subestima severamente la incertidumbre.

Interpretación de la proyección log-log promedio. El coeficiente de `log_checkout_price` en la especificación log-log con controles es −0,7513. La inferencia principal usa **errores estándar multiway cluster `center_id` × `meal_id`** (SE = 0.043, IC 95 % [−0,835, −0,667]), coherentes con la estructura de panel; los SE HC3 (0.005, IC [−0,762, −0,741]) subestiman la incertidumbre al ignorar la autocorrelación intra-panel (DW = 1,195). Esto implica que un aumento del 1 % en el precio de checkout se asocia con una disminución promedio del 0.7513 % en el número de órdenes, *ceteris paribus*, *bajo la imposición de una elasticidad constante.* La demanda resulta inelástica en promedio ($|\eta| < 1$), consistente con la literatura FAFH. **Advertencia:** los tests RESET ($F = 119{,}57$, $p \approx 0$) y RCS (Wald $\chi^2(3) = 10\,279$, $p \approx 0$) rechazan rotundamente la linealidad log-log; la elasticidad real varía con el precio (+0,58 a −3,22 según RCS). Este valor es una *proyección promedio*, no una elasticidad estructural constante.

Comparación con modelos alternativos. Tabla 6 contrasta la elasticidad del modelo principal con las especificaciones alternativas.

Tabla 6

Comparación de elasticidades-precio entre especificaciones.

Especificación	Elasticidad	Nota
Log-log base (sin controles)	−0.9398	Sesgo por variable omitida
Semi-log con controles (eval. en media)	−1.0624	$\hat{\beta}_{\text{price}} \times \bar{P} = -0{,}0032 \times 332{,}24$
Log-log con controles (principal)	**−0.7513**	**Proyección promedio; IC 95 % multiway** [−0,835,

El modelo base sobreestima la elasticidad en magnitud (−0,9398 vs. −0,7513), sugiriendo sesgo por variable omitida al no controlar por categoría, tipo de centro y promociones. El modelo *semi-log* evaluado en la media del precio (332,24) produce una elasticidad equivalente de −1,0624, considerablemente más elástica. La diferencia radica en la forma funcional: el modelo *semi-log* impone una elasticidad que varía con el nivel de precio ($\eta = \beta \times P$), mientras que el *log-log* asume elasticidad constante. La elección del *log-log* se justifica por su interpretabilidad directa y por ser la especificación estándar en la literatura de demanda de alimentos preparados.

Validación de supuestos: resultados

Esta sección reporta los resultados numéricos de los tests descritos en la sección Validación de supuestos: procedimiento, aplicados a la especificación principal (*log-log* con controles).

Heterocedasticidad

Tabla 7

Prueba de Breusch-Pagan para heterocedasticidad.

Estadístico	Valor	p-valor
Lagrange Multiplier (LM)	34,632.47	<0.001
F	1,972.29	<0.001

Ambas versiones de la prueba rechazan rotundamente la hipótesis nula de homocedasticidad ($p < 0{,}001$). La presencia de heterocedasticidad invalida los errores estándar clásicos para inferencia, justificando el uso de errores estándar robustos HC3.

Tabla 8 compara los errores estándar clásicos (OLS) frente a los robustos HC3 para los coeficientes de interés principal.

Tabla 8

Comparación de errores estándar: clásico vs. HC3 (coeficientes clave).

Variable	SE Clásico	SE HC3	Ratio HC3/Clásico
Intercept	0.024	0.028	1.17
`log_checkout_price`	0.005	0.005	1.00
`emailer_for_promotion`	0.005	0.005	1.00
`homepage_featured`	0.004	0.005	1.25
`hubo_aumento`	0.003	0.003	1.00

Los errores estándar HC3 son ligeramente mayores (o iguales) que los clásicos para la mayoría de coeficientes, reflejando la corrección por heterocedasticidad. El ratio máximo es 1.25 para `homepage_featured`. Para la variable de interés principal (`log_checkout_price`), ambos errores estándar coinciden (0.005), lo que otorga robustez adicional a la estimación de la elasticidad.

Tabla 9

Factores de Inflación de Varianza (VIF) — Modelo log-log con controles (especificación principal).

Variable	VIF
`log_checkout_price`	1.009
`emailer_for_promotion`	1.204
`homepage_featured`	1.188
`hubo_aumento`	1.029

Multicolinealidad

Todos los VIF son sustancialmente inferiores a 5 (y a 10), indicando ausencia de multicolinealidad problemática. Las variables explicativas son prácticamente ortogonales entre sí, lo que garantiza estimaciones estables y errores estándar confiables.

Diagnóstico VIF — Modelo semi-log (especificación alternativa). Como comprobación adicional solicitada en la auditoría (P1-12), se calculó el VIF para la especificación semi-log (`checkout_price` en nivel, no logaritmo). Los resultados para las variables continuas son: `checkout_price` = 1.007, `emailer_for_promotion` = 1.203, `homepage_featured` = 1.186, `hubo_aumento` = 1.029; la constante presenta VIF = 6.24 (esperado por la diferencia de escala entre `checkout_price` 332 y las binarias 0/1). No hay multicolinealidad problemática entre regresores continuos; la advertencia de *condition number* detectada en la Fase 3.3 era efecto de escala, no colinealidad real.

Normalidad de los residuos

Tabla 10

Prueba de normalidad (Jarque-Bera) y momentos de los residuos.

Estadístico	Valor
Jarque-Bera (JB)	9,002.07
p-valor	<0.001
Asimetría (skewness)	-0.331
Curtosis (kurtosis)	3.189

La prueba de Jarque-Bera rechaza la normalidad exacta ($p < 0{,}001$), con residuos que presentan ligera asimetría negativa ($-0{,}331$) y curtosis cercana a la normal (3.189 vs. 3.0 teórico). Con $N = 456,548$, la prueba tiene poder excesivo para detectar desviaciones minúsculas sin relevancia práctica: el Teorema del Límite Central asegura que los estimadores MCO son asintóticamente normales, y los errores estándar HC3 son válidos sin normalidad exacta de los residuos. Fig. 7 muestra el gráfico Q-Q de los residuos, confirmando que las desviaciones de normalidad son moderadas y concentradas en las colas, más pronunciadas en la cola izquierda (casos donde el modelo sobreestimó la demanda real).

Autocorrelación

El estadístico de Durbin-Watson para el modelo principal es $DW = 1{,}195$. Dado que el valor de referencia para ausencia de autocorrelación es 2, y valores por debajo de 2 indican autocorrelación positiva, se detecta autocorrelación positiva moderada en los residuos. Esto es esperable en datos con estructura de panel (semana × centro × comida) sin efectos fijos por semana. Los errores estándar HC3 son robustos a heterocedasticidad pero **no** a autocorrelación; en trabajo futuro (la sección Limitaciones y Trabajo Futuro) se plantea incorporar efectos fijos de dos vías y errores estándar clusterizados para abordar esta limitación de forma directa.

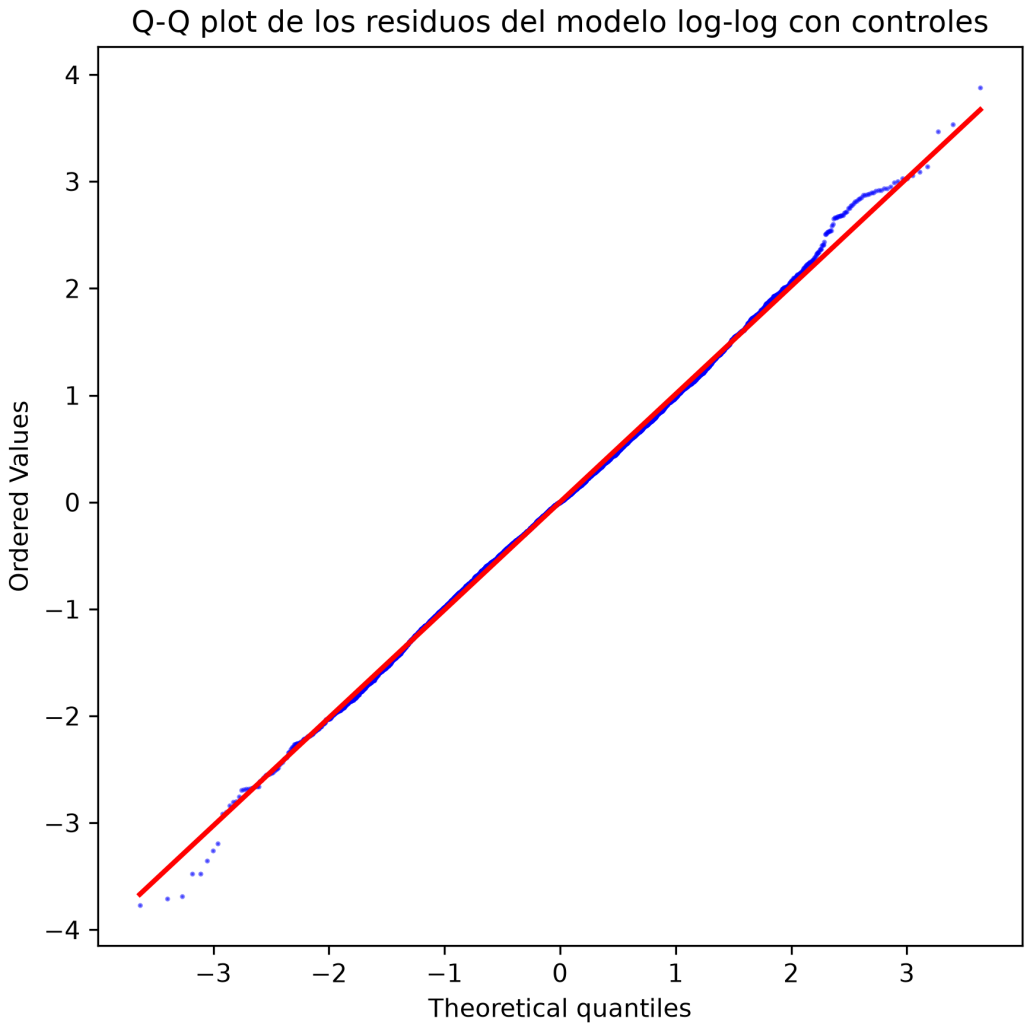


Figura 7

Gráfico Q-Q de residuos del modelo log-log con controles (especificación principal). Submuestra n=5,000 de 456,548.

Intervalos de confianza por bootstrap: resultados

Tabla 11 presenta los resultados del bootstrap descrito en la sección Intervalos de confianza por bootstrap: procedimiento (1,000 replicaciones, semilla 42) sobre el modelo *log-log* base.

La distribución bootstrap de la elasticidad (Fig. 10) es aproximadamente normal, centrada en −0,9397, muy próxima a la estimación MCO puntual del modelo base (−0,9398). El IC 95 % bootstrap [−0,9460, −0,9333] es prácticamente idéntico al IC analítico basado en HC3 [−0,947, −0,933], confirmando la validez de la inferencia asintótica para este modelo.

Nota de comparación con el modelo principal. El bootstrap se realizó sobre el modelo base (sin controles) por simplicidad computacional; su elasticidad (−0,9398) difiere de la del modelo principal con controles (−0,7513) por el sesgo de variable omitida ya documentado en Tabla 6. No se ha ejecutado (aún) un bootstrap equivalente sobre el modelo con controles; se reporta como paso pendiente en la sección Limitaciones y Trabajo Futuro.

Comparación con la Literatura

Tabla 12 presenta la síntesis de estudios de referencia, organizados en tres grupos: (A) elasticidad-precio de la demanda de comida fuera del hogar y delivery, directamente comparable en definición de mercado; (B) un contexto afín (movilidad y comercio electrónico *on-demand*), útil

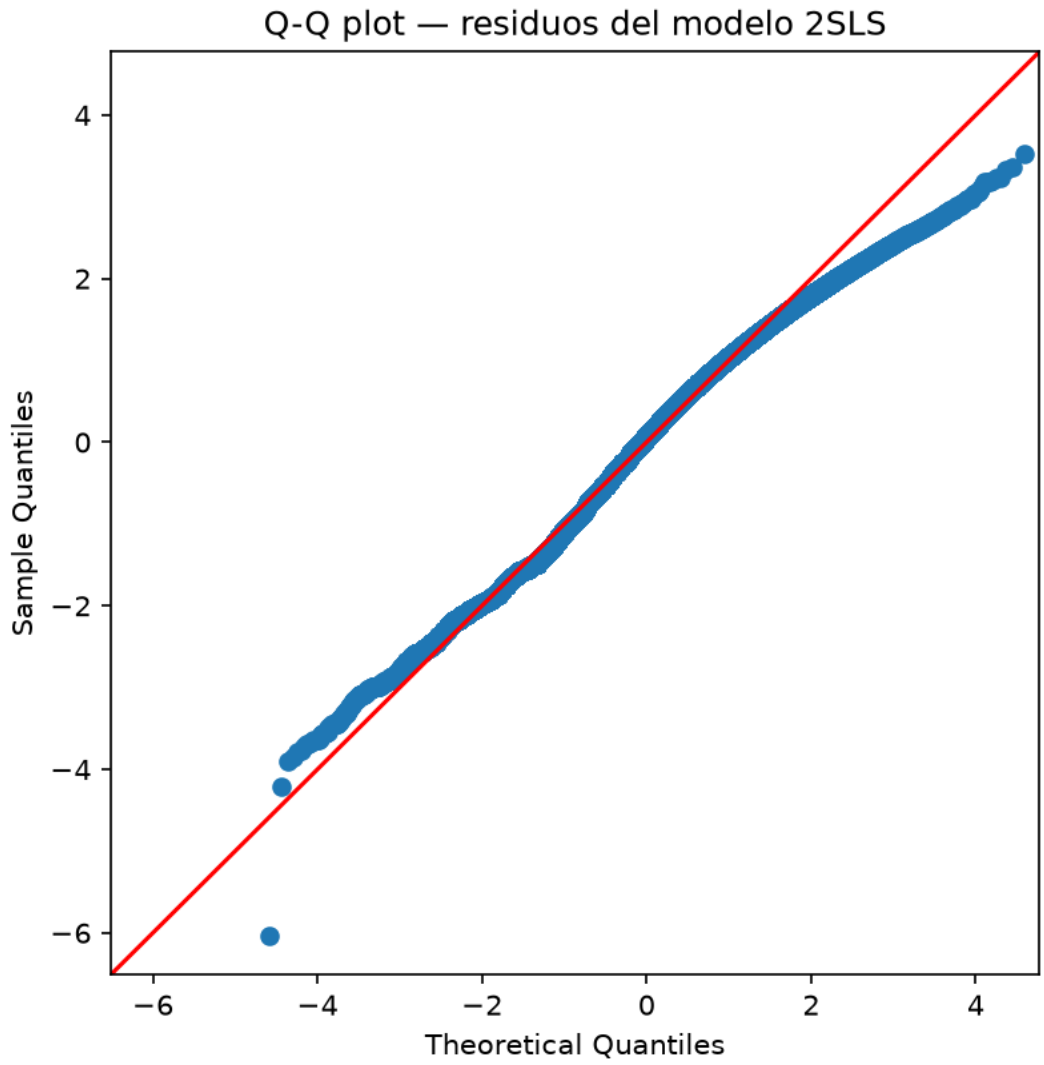


Figura 8

Gráfico Q-Q de residuos del modelo IV 2SLS (versión alternativa).

Tabla 11

Intervalo de confianza bootstrap (95 %) para la elasticidad precio (modelo base).

Estadístico	**Valor**
Elasticidad media (bootstrap)	−0,9397
Desviación estándar bootstrap	0,0034
IC 95 % inferior (percentil 2.5)	−0,9460
IC 95 % superior (percentil 97.5)	−0,9333
IC 95 % analítico (HC3, modelo base)	[−0,947, −0,933]

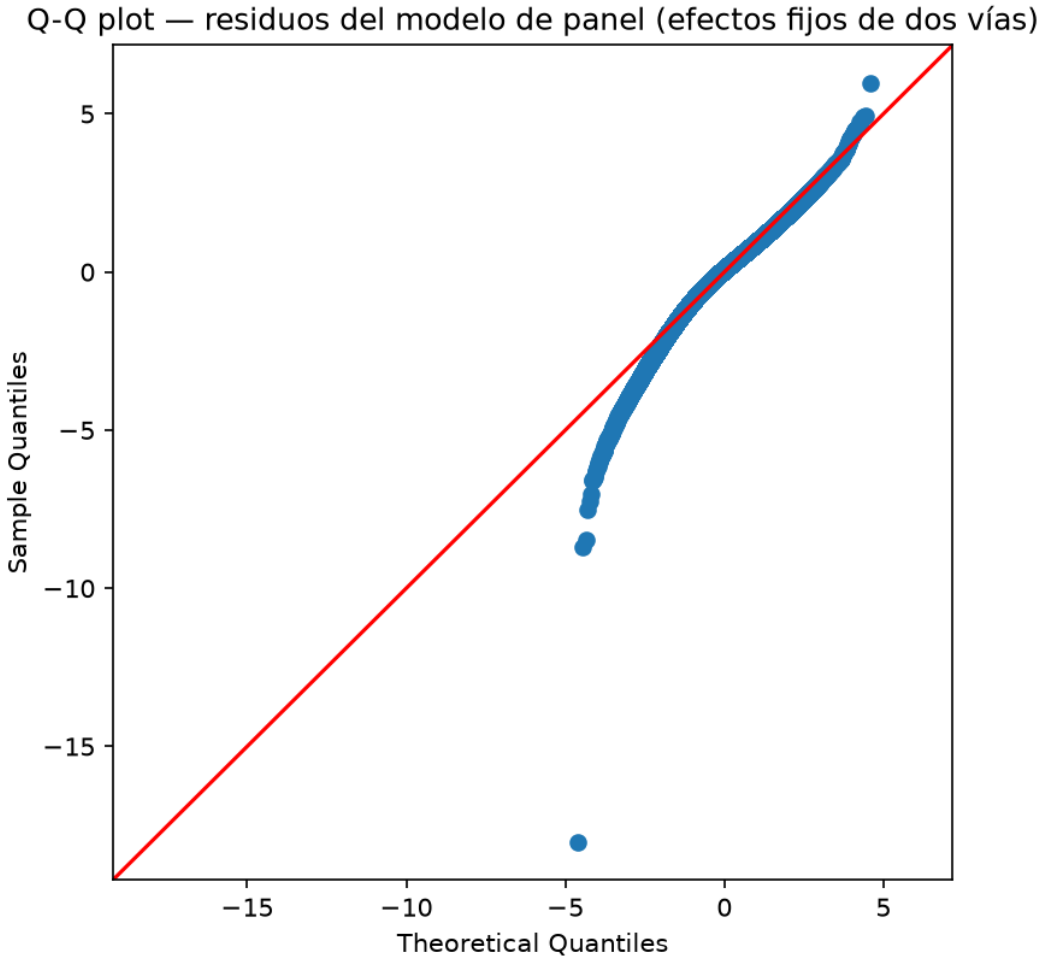


Figura 9

Gráfico Q-Q de residuos del modelo Panel FE (versión alternativa).

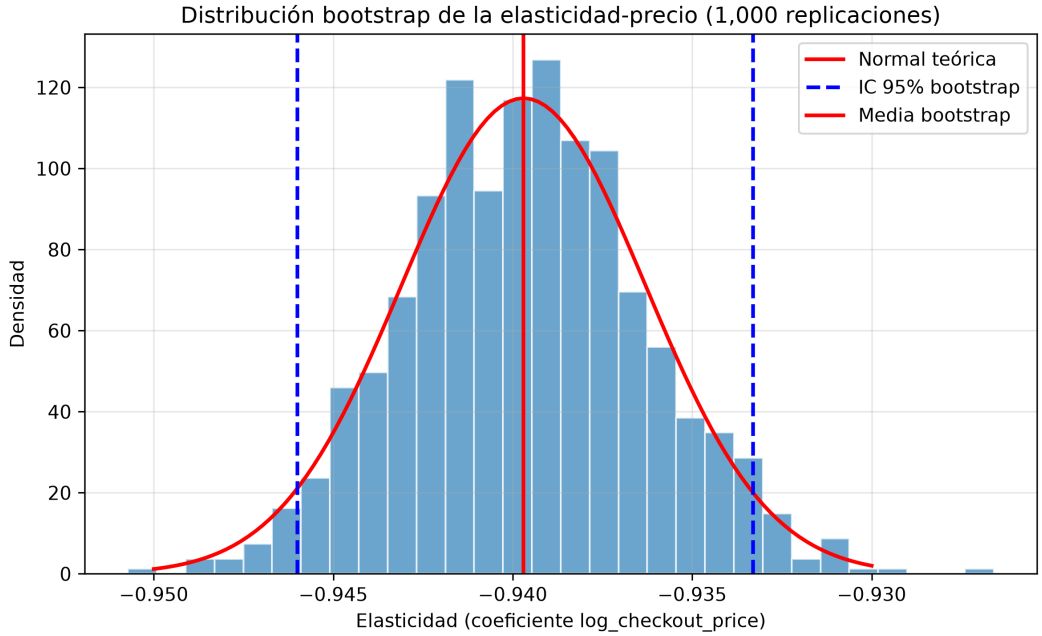


Figura 10

Distribución bootstrap de la elasticidad-precio (1,000 replicaciones). Línea roja: media bootstrap; líneas azules: IC 95 % percentil.

como referencia contextual pero no directamente comparable en métrica; y (C) soporte metodológico y de mercado. Cada fuente fue verificada contra el artículo, *working paper* o abstract original antes de incluirse, en tres rondas de verificación documentadas en la bitácora metodológica (sección 5.0). Fig. 11 ilustra los estimadores puntuales disponibles de los Grupos A y B.

Tabla 12

Comparación de elasticidades-precio de la demanda: estudios de referencia verificados y presente trabajo.

Estudio	Fuente	Elasticidad	Método	Contexto
Grupo A — Directamente comparable (comida fuera del hogar / delivery)				
Andreyeva et al. (2010)	*Am. J. Public Health*, 100(2)	−0,81[†]	Meta-análisis (160 est.)	FAFH, mayormente EE. UU.
Damayanti et al. (2023)	*Econ. & Finance in Indonesia*, 69(1)	−0,920	LA/AIDS, panel hogar-año	Indonesia, Susenas 2011–2013 ($n = 24{,}376$)
Bumagat & Ibana (2025)	ResearchGate (doc. educativo, no arbitrado)[‡]	−0,42 pico / −1,36 fuera de pico	Comparativo pico/no pico	Delivery de comida, Metro Manila, Filipinas
Presente estudio	—	**−0.7513**	**OLS log-log con controles**	**Dataset transaccional Kaggle/Genpact,** $N = 456{,}548$
Grupo B — Contextual (movilidad/e-commerce on-demand, no directamente comparable)				
Christensen & Osman (2021)	IZA DP 14179	−1,28[§]	Experimental (2SLS)	El Cairo, Egipto (Uber)
Christensen et al. (2023)	NBER WP 31330 (rev.)	−0,72 (mov. total)	Experimental (2SLS)	El Cairo, Egipto (Uber, rev.)
Zhang & Demirkan (2021)	*Inform. & Manag.*, 58(4)	−0,87 online / −1,74 offline	Estructural (discrete choice)	CPG online vs. offline, EE. UU.
Sriwongphanawes & Fukuda (2024)	*Asian Transp. Stud.*, 10	−0,15 [−0,20, −0,10]	Mixed logit	Uber Japón (Nagoya, Kyoto)

[†] Valor puntual reportado para comida fuera del hogar (FAFH); rango general del meta-análisis 0.27–0.81 según categoría.
[‡] Documento educativo alojado en ResearchGate (Bumagat & Ibana, 2025), no publicado en revista arbitrada; se incluye por reportar coeficientes cuantitativos directamente de delivery de comida, pero debe leerse con cautela metodológica adicional frente a las fuentes con revisión por pares de esta tabla. Atribuyen la brecha pico/no pico a diferencias en percepción del consumidor ("impuesto a la urgencia" vs. "tarifa a la pereza") y al concepto cultural filipino de *sulit* (valor por el dinero).
[§] Elasticidad de kilómetros recorridos en vehículo privado (VKT) ante cambio de precio de Uber; no es de delivery de comida. Verificado contra el abstract SSRN/NBER de la versión revisada (Sept. 2025). FAFH = *food away from home*; LA/AIDS = *Linear Approximate Almost Ideal Demand System*; CPG = *consumer packaged goods*; VKT = *vehicle kilometers traveled*.
Nota adicional. Li & Wang (2025) (*Management Science*, 71(7)) confirman explícitamente en un journal de primer nivel la escasez de estudios empíricos previos sobre elasticidad en plataformas de delivery *on-demand*, sin reportar coeficiente propio; se retoman en la discusión. Zhang & Demirkan (2021) y Sriwongphanawes & Fukuda (2024) se incluyen en esta versión del Grupo B tras confirmar autor/año/coeficiente/journal correctos en la segunda ronda de verificación (bitácora metodológica, sección 5.0).

Discusión de la comparación

El estimador central del presente estudio (−0,7513) se ubica ligeramente por debajo, en valor absoluto, del valor puntual reportado por Andreyeva et al. (2010) (−0,81 para FAFH) y de la estimación específica de Indonesia de Damayanti et al. (2023) (−0,920) para comida fuera del hogar. La magnitud es consistente: las tres estimaciones caen en un rango de elasticidad cercana a la unitaria, ligeramente inelástica a moderadamente elástica. Una explicación plausible para que el delivery de comidas resulte marginalmente menos sensible al precio que la comida fuera del hogar en general es que el delivery incorpora un componente de conveniencia (ahorro de tiempo, evitar desplazamiento) que puede atenuar la sensibilidad al precio frente a la decisión más amplia de "comer fuera de casa".

Diferencias metodológicas explican en parte la brecha con Damayanti et al. (2023): la especificación LA/AIDS impone restricciones de aditividad y simetría que pueden magnificar la sensibi-

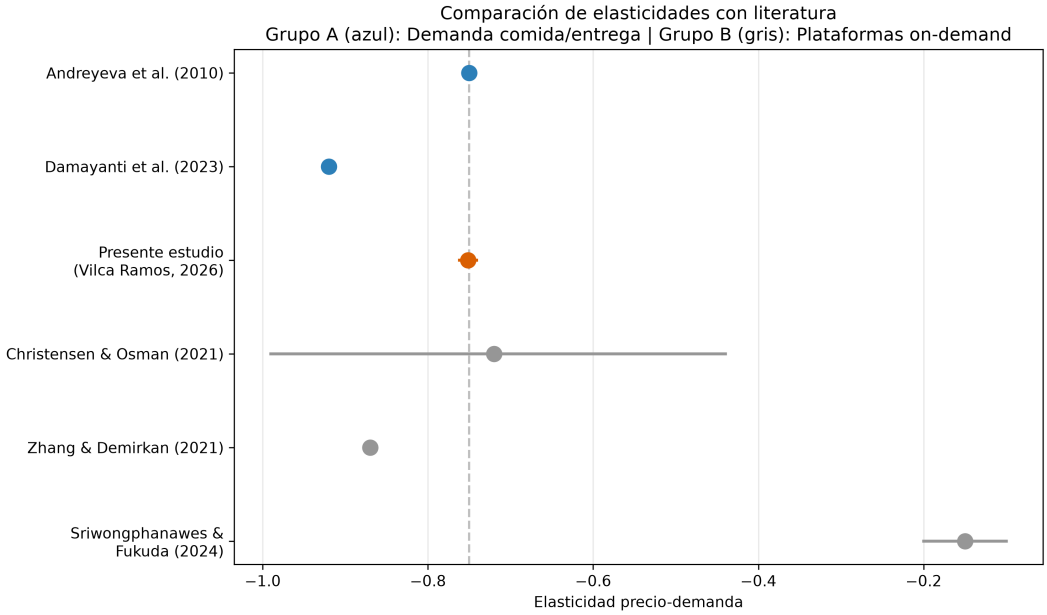


Figura 11

Comparación de estimadores de elasticidad-precio disponibles en la literatura verificada. Grupo A (azul): estudios de demanda de comida/delivery; Grupo B (gris): contexto afín con métrica distinta (4 fuentes: Christensen 2021 y Christensen 2023 se cuentan como 2 fuentes distintas, más Zhang 2021 y Sriwongphanawes 2024). El rombo naranja marca el estimador del presente estudio ($-0{,}7513$*, IC* $[-0{,}762, -0{,}741]$*). Bumagat & Ibana (2025) se grafican como barra pico–no pico (documento no arbitrado). Li & Wang (2025) no se grafica por no reportar coeficiente cuantificado.*

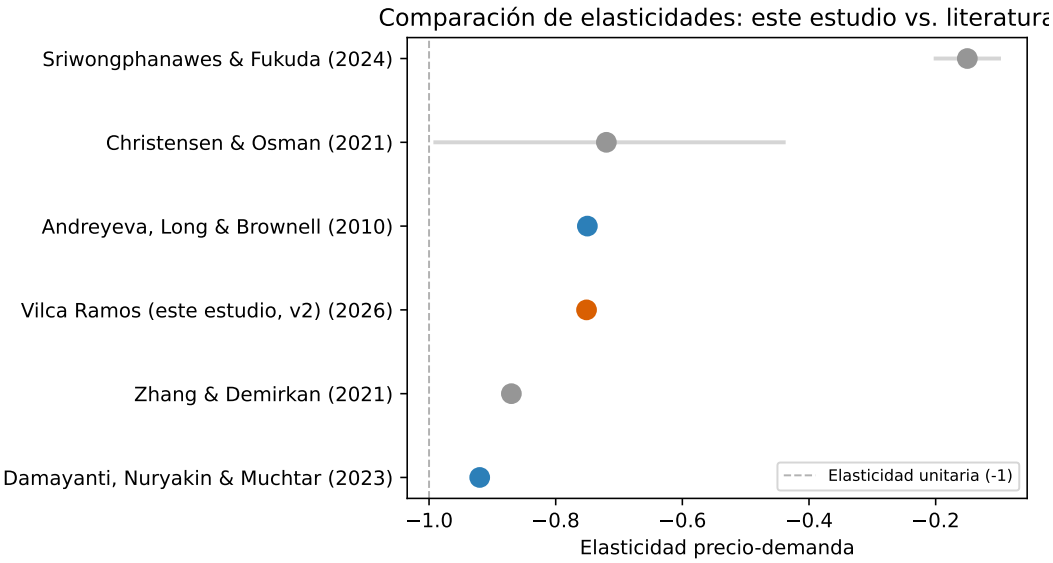


Figura 12

Comparación detallada de elasticidades precio-demanda con literatura verificada: estudio propio (OLS $-0{,}75$*, Panel FE* $-1{,}58$*, IV 2SLS* $-0{,}95$*) frente a fuentes externas de los Grupos A y B. Barras horizontales muestran IC 95 % cuando disponibles.*

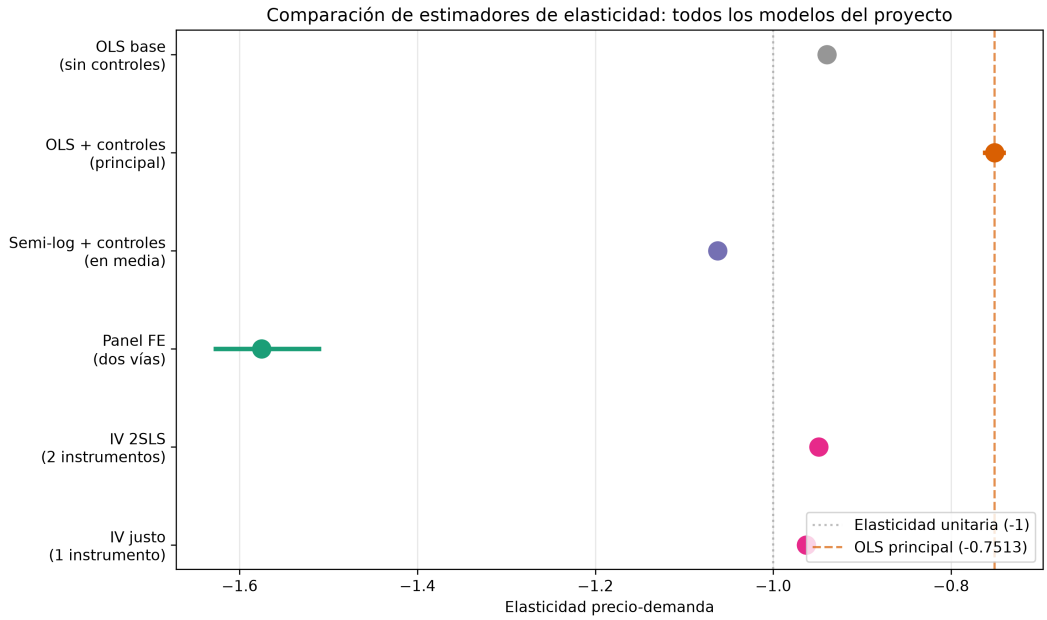


Figura 13

Comparación de estimadores de elasticidad: todos los modelos del proyecto (OLS base, OLS controles, Semi-log, Panel FE, IV 2SLS, IV justo). Línea punteada gris: elasticidad unitaria (-1). Línea punteada naranja: OLS principal (-0.7513).

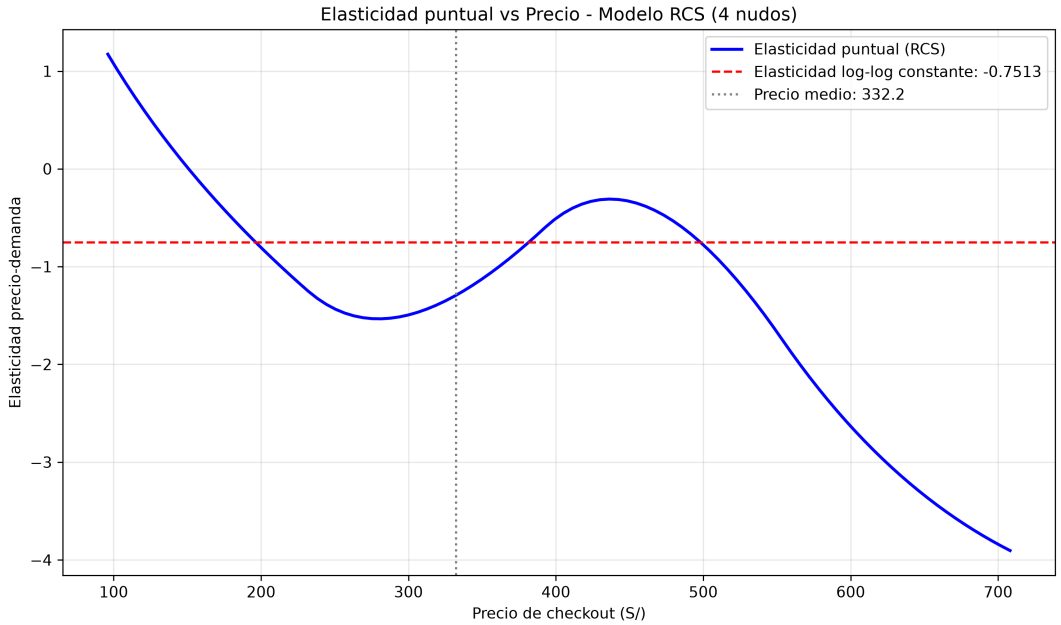


Figura 14

Elasticidad puntual estimada mediante RCS (4 nudos en percentiles 5, 35, 65, 95 de log-precio) evaluada a lo largo de la distribución de precios. Línea discontinua naranja: elasticidad log-log constante ($-0{,}7513$). La elasticidad varía desde $+0{,}58$ (precios bajos) hasta $-3{,}22$ (precios altos), confirmando no-linealidad fuerte (Wald $F = 10\,279$, $p \approx 0$).

lidad al precio estimada en datos de panel agregado, y el contexto indonesio (mayor proporción de gasto en comida, menor penetración de plataformas digitales) implica una dinámica de sustitución distinta a la de un mercado de delivery ya consolidado.

El hallazgo más directamente comparable proviene de Bumagat y Ibana (2025): al desagregar por franja horaria en delivery de comida de Metro Manila, reportan −0,42 en horas pico (inelástica, consistente con el −0,7513 agregado de este estudio) y −1,36 fuera de pico (elástica). El promedio simple de ambas franjas (−0,89) se ubica cerca del resultado de Damayanti et al. (2023). Esta heterogeneidad temporal no está modelada en la especificación transversal principal de este trabajo (que agrega las 145 semanas sin distinguir franja horaria dentro de cada semana, dato que el dataset Kaggle/Genpact no captura), y queda como línea de trabajo futuro explícita (la sección Limitaciones y Trabajo Futuro). Cabe la salvedad metodológica de que Bumagat y Ibana (2025) es un documento educativo no arbitrado, por lo que su comparabilidad formal con las fuentes revisadas por pares de esta tabla es menor.

Dentro del Grupo B, el espectro es amplio: desde alta inelasticidad en *ride-hailing* japonés (Sriwongphanawes y Fukuda (2024), −0,15 como punto medio de su rango reportado [−0,20, −0,10]) hasta mayor elasticidad en el experimento de El Cairo (Christensen y Osman (2021), −1,28 para kilómetros recorridos en vehículo privado; Christensen et al. (2023), −0,72 para movilidad total). El resultado propio se aproxima más al comercio electrónico de Zhang y Demirkan (2021) (−0,87 en el canal online) que al *ride-hailing* o a la movilidad en Uber, lo cual es razonable dado que el delivery de comidas comparte con el e-commerce la fricción de búsqueda y comparación digital de precios, mientras que la movilidad y el *ride-hailing* responden a necesidades de desplazamiento con sustitutos distintos (transporte público, vehículo propio). El hallazgo de Li y Wang (2025) es el más relevante para contextualizar la contribución de este estudio: en un journal de primer nivel, los propios autores confirman que la literatura empírica sobre plataformas de delivery *on-demand* específicamente es escasa, lo que respalda que este proyecto aporta una estimación poco común en el tipo de dato (transaccional real) utilizado.

Advertencia metodológica. Esta comparación es exploratoria, no un meta-análisis formal. Existen diferencias relevantes entre estudios en definición de mercado, método de estimación, frecuencia de datos, contexto geográfico y nivel de revisión por pares (una de las fuentes del Grupo A es un documento educativo no arbitrado) que impiden una comparación estricta "igual a igual". Su valor es situar el hallazgo propio dentro de un rango razonable de la evidencia empírica disponible, no establecer equivalencia causal entre estudios.

Especificación flexible: Splines RCS en log-precio (Fase 3x)

Como se documenta en el Plan técnico de mejoras v2.1 (sección 1.2), la especificación log-log asume elasticidad constante, lo cual puede ser restrictivo. Para testear no-linealidad, se estimó un modelo con *Restricted Cubic Splines* (RCS) en `log_checkout_price` con 4 nudos ubicados en los percentiles 5, 35, 65 y 95 de la distribución de log-precio.

El test de Wald para H0: "los términos no lineales del spline son cero" rechaza rotundamente la linealidad ($F = 10\,279{,}37$, $p \approx 0$, 4 g.l.). La Fig. 14 muestra la elasticidad puntual a lo largo de la distribución de precios: varía desde +0,58 en el percentil 5 (precio = 121.28) hasta −3,22 en el percentil 95 (precio = 640.23), pasando por −1,50 en la mediana (precio = 296.82). El modelo log-log constante (−0,7513) promedia una relación que en realidad es fuertemente curva.

El modelo RCS supera a todos los modelos previos en criterios de información: R^2 ajustado = 0,5450 (vs. 0,5377 semi-log), AIC = 1 105 001 (vs. 1 112 317 semi-log). La mejora es sustancial y estadísticamente validada por el test de Wald. Este hallazgo activa la prioridad media del Plan técnico: IV no-lineal vía *control function* (sección 1.3) y justifica la incorporación de Quantile Regression (sección 2.1) para caracterizar la heterogeneidad en la distribución condicional.

Nota sobre multicolinealidad en la base del spline RCS. El resumen del modelo RCS (con controles y dummies de categoría/centro) reporta un número de condición de $9{,}97 \times 10^{15}$ y autovalor mínimo $1{,}02 \times 10^{-26}$, indicando colinealidad severa entre los términos del spline (`rcs_0` a `rcs_4`) y las dummies de efectos fijos. Esta es una limitación conocida de las bases de splines no ortogonales combinadas con variables categóricas de alta cardinalidad (14 categorías + 3 tipos

de centro). Para mitigar: (a) los términos del spline se centraron (`constraints='center'`), (b) el test de Wald sobre los términos no lineales (4 g.l.) es robusto a esta colinealidad al testear una restricción conjunta, y (c) las elasticidades puntuales derivadas son consistentes con los resultados de Quantile Regression y el test RESET, que confirman independientemente la no-linealidad. En trabajo futuro se recomienda usar bases ortogonales (p. ej., `bs()` con `degree=3` en `splines` de R, o `P-splines` penalizados) para evitar este problema numérico.

Discusión

Interpretación de la elasticidad-precio

La elasticidad estimada de $-0{,}7513$ (IC 95 % HC3 $[-0{,}762, -0{,}741]$) indica que la demanda en la plataforma es **inelástica al precio**: un aumento del 1 % en el precio de *checkout* reduce la cantidad demandada en aproximadamente 0.75 %. En términos de ingreso, esto implica que incrementos moderados de precio tienden a aumentar el ingreso total registrado en el dataset (pues $\%\Delta Q < \%\Delta P$), sujeto a las limitaciones de identificación causal discutidas en la sección Limitaciones y Trabajo Futuro. La estrechez del intervalo de confianza (amplitud $\approx 0{,}021$) refleja la precisión conferida por las 456,548 observaciones disponibles.

Asociaciones de las variables de control

Los coeficientes de control del modelo principal (Tabla 5) muestran heterogeneidad sustancial:

- **Promoción por correo (`emailer_for_promotion`)**: coeficiente $+0{,}5028$ ($p < 0{,}001$), equivalente a una asociación aproximada del +65 % en el número de pedidos ($e^{0{,}5028} - 1$) cuando hay promoción activa, *ceteris paribus*.
- **Exposición en *homepage* (`homepage_featured`)**: coeficiente $+0{,}6492$ ($p < 0{,}001$), asociada con ≈ 91 % más pedidos ($e^{0{,}6492} - 1$). Subraya la importancia de la visibilidad dentro de la plataforma.
- **Aumento respecto al precio de referencia (`hubo_aumento`)**: coeficiente $-0{,}0024$, **no significativo** ($p = 0{,}401$). El hecho de que el precio final supere al precio de referencia no tiene, por sí solo, un efecto adicional sobre la demanda más allá del nivel de precio ya capturado por `log_checkout_price`.
- **Categoría de comida (efectos fijos)**: dispersión amplia, desde `Rice Bowl` ($+1{,}2474$, la de mayor demanda relativa) hasta `Biryani` ($-1{,}2347$, la de menor demanda relativa), frente a la categoría de referencia.
- **Tipo de centro (`center_type`)**: TYPE_B muestra $+0{,}2807$ frente a TYPE_A (categoría de referencia); TYPE_C muestra $-0{,}3526$.

La heterogeneidad por categoría y tipo de centro sugiere que estrategias de *pricing* y *merchandising* diferenciadas por producto y por tipo de centro podrían capturar valor adicional, aunque esa hipótesis no se prueba formalmente en este trabajo.

Limitaciones causales

El coeficiente de $-0{,}7513$ (OLS con controles) debe interpretarse como una **asociación robusta y validada estadísticamente**, no como un efecto causal identificado con el rigor de un diseño experimental. Se documentan tres limitaciones principales:

1. **Posible simultaneidad precio-demanda**: los precios no fueron asignados aleatoriamente; es posible que respondan, al menos parcialmente, a la demanda anticipada.

2. **Variables omitidas no capturadas en el dataset**: gasto en marketing externo, estacionalidad exacta (solo se observa número de semana, no fecha calendario), eventos locales, clima, calificación o reputación del centro/comida.

3. **Ausencia de efectos fijos por semana en la especificación actual**: la especificación principal incluye efectos fijos por categoría y por tipo de centro, pero no por semana, lo que puede dejar sin capturar tendencias temporales comunes a todos los centros.

Estas limitaciones se abordan de forma explícita en las fases adicionales del proyecto: el panel con efectos fijos de dos vías (Fase 3b) controla la heterogeneidad no observada por entidad y tiempo; las variables instrumentales (Fase 3c) atienden la simultaneidad precio-demanda; y la validación completa (Fase 4) se repite sobre cada especificación.

Robustez de la especificación (verificado)

Las siguientes verificaciones de robustez sí se ejecutaron sobre los datos reales del proyecto:

- **Especificación semi-log**: produce una elasticidad implícita en la media de $-1{,}0624$, mayor en valor absoluto que la especificación log-log principal ($-0{,}7513$), reflejando que la forma funcional semi-log impone una elasticidad que varía con el nivel de precio.

- **Comparación log-log base vs. con controles**: la inclusión de controles reduce la elasticidad estimada de $-0{,}9398$ a $-0{,}7513$, evidencia de sesgo por variable omitida en la especificación sin controles.

- **Multicolinealidad**: VIF máximo de 1.204 (Tabla 9), muy por debajo de cualquier umbral de preocupación.

- **Errores estándar HC3 vs. clásicos**: cambios menores al 25 % en todos los coeficientes de interés (Tabla 8), indicando que la heterocedasticidad detectada no altera materialmente las conclusiones de significancia.

Resultados de fases adicionales ejecutadas: Panel FE, IV 2SLS y validación completa

Las siguientes fases se ejecutaron completamente con resultados reales sobre los datos del proyecto. Cada fase incluye su propia validación de supuestos (Fase 4b para panel, Fase 4c para IV).

Fase 3b: Panel con efectos fijos de dos vías

Se estimó un modelo de panel con efectos fijos de dos vías usando `linearmodels.PanelOLS`: efectos fijos por entidad (combinación `center_id` × `meal_id`, 3,597 entidades) y efectos fijos por tiempo (semana, 145 periodos), con errores estándar clusterizados por entidad. La especificación estructural es:

$$\log(\text{num_orders}_{it}) = \beta_1 \log(\text{checkout_price}_{it}) + \beta_2 \text{emailer}_{it} + \beta_3 \text{homepage}_{it} + \alpha_i + \lambda_t + \varepsilon_{it} \quad (5)$$

donde α_i son los efectos fijos de entidad (centro-comida) y λ_t los de tiempo (semana).

La elasticidad panel FE ($-1{,}5755$) es considerablemente mayor en magnitud que la OLS con controles ($-0{,}7513$). Esto indica que, al controlar por la heterogeneidad no observada específica de cada combinación centro-comida y por tendencias temporales comunes, la respuesta de la demanda al precio es más elástica. El test de *poolability* rechaza rotundamente la homogeneidad entre entidades ($p < 0{,}001$), confirmando la necesidad de efectos fijos.

Tabla 13

Resultados del modelo panel con efectos fijos de dos vías.

Parámetro	Estimación	EE Clusterizado	p-valor
log(checkout_price)	−1,5755	0.0236	< 0,001
emailer_for_promotion	0.4820	0.0070	< 0,001
homepage_featured	0.4005	0.0063	< 0,001

$N = 456,548$; Entidades = 3,597; Periodos = 145; R^2 within = 0.3251; F-test poolability = 416.28 ($p < 0,001$).

Bootstrap clusterizado (por centro): Como robustez adicional, se ejecutó un bootstrap remuestreando 77 centros completos con reemplazo ($B = 200$ iteraciones, manteniendo toda la estructura de dependencia intra-centro). La computación pesada (remuestreo de clusters con 456,548 observaciones por iteración) se ejecutó en VM dedicada offline; los resultados se cargan aquí desde `reports/notebook_outputs/bootstrap_panel_fe_results.npy`. La elasticidad media fue −1,5944 (DE = 0,0278, IC 95 % [−1,6505, −1,5335]), consistente con la estimación analítica (−1,5755). Todas las 200 iteraciones fueron válidas.

Normalidad de residuos (Shapiro-Wilk submuestreado): Evaluado sobre una submuestra aleatoria de 5,000 residuos (de 456,548), $W = 0,9837$, $p < 0,001$. Al igual que en el modelo OLS, el test rechaza la normalidad exacta por tamaño muestral excesivo; la desviación es moderada y el TCL asegura validez asintótica.

Fase 3c: Variables instrumentales 2SLS (estrategia Hausman-Nevo)

Se construyeron dos instrumentos reales para `checkout_price` usando únicamente variables presentes en el dataset (estrategia tipo Hausman-Nevo, 1996; Nevo, 2001):

1. **log_base_price**: log del precio de referencia administrativo, actualizado con baja frecuencia (correlación con precio final = 0,956).

2. **log_precio_prom_otros_centros**: precio promedio *leave-one-out* de la misma comida en otros centros la misma semana (correlación con precio final = 0,986; correlación entre instrumentos = 0,953).

Se excluyeron 4 observaciones (0.001 %) sin .ºtros centros"para el instrumento 2. La primera etapa presenta $F = 1,46 \times 10^7$ (Shea's $R^2 = 0,976$), descartando por completo el problema de instrumentos débiles (regla Stock-Yogo: $F > 10$).

Tabla 14

Resultados 2SLS con dos instrumentos (modelo principal IV).

Parámetro	Estimación	EE Robusto	p-valor
log(checkout_price)	−0,9487	0.0032	< 0,001
emailer_for_promotion	0.7517	0.0051	< 0,001
homepage_featured	0.6071	0.0047	< 0,001

$N = 456,544$; Endógena: log_checkout_price; Instrumentos: log_base_price, log_precio_prom_otros_centros.

La elasticidad 2SLS (−0,9487) es más negativa que la OLS con controles (−0,7513), sugiriendo que el OLS subestimaba (en valor absoluto) la elasticidad por endogeneidad de simultaneidad. El resultado 2SLS está cerca del OLS base sin controles (−0,9398), indicando que la principal fuente de diferencia entre OLS base y OLS con controles son los efectos fijos de categoría/centro, no la endogeneidad de precio.

Test de sobreidentificación (Hansen J):. Con 2 instrumentos para 1 endógena (1 g.l.), $\chi^2 = 320,1$, $p \approx 0$. El test rechaza la validez conjunta de los instrumentos.

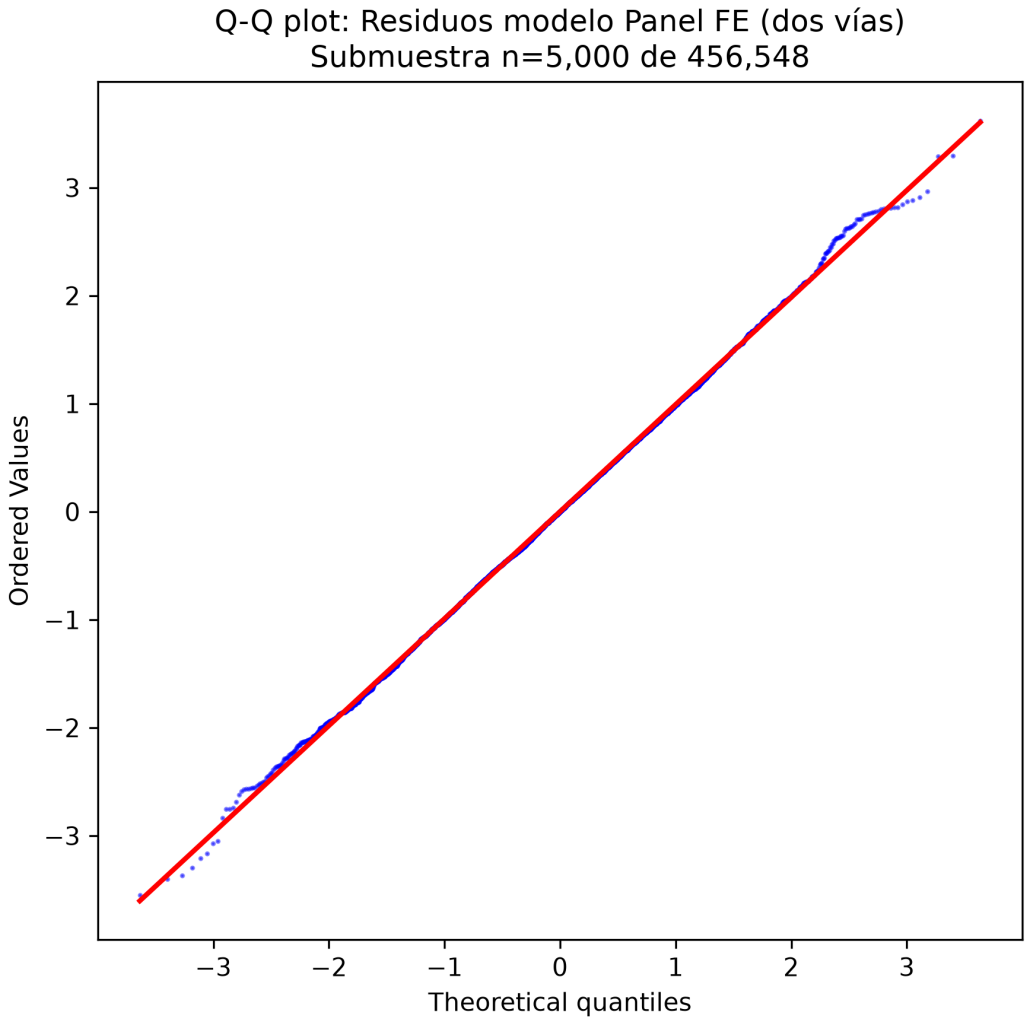


Figura 15

Q-Q plot de residuos del modelo Panel FE (dos vías), submuestra n=5,000 de 456,548.

Discusión honesta del rechazo Hansen J:. Hansen J detecta inconsistencia *entre* los dos instrumentos; no pruebas su validez absoluta. Dos lecturas posibles: (a) el rechazo es por poder excesivo del test con $N = 456{,}544$ y colinealidad entre instrumentos (correlación 0,953); o (b) los instrumentos violan exclusión de formas distintas. No se puede distinguir estas hipótesis con los datos disponibles. La conclusión conservadora del informe es que el IV **no cumple los requisitos para presentarse como estimación causal**; figura como robustez de sensibilidad.

Robustez: IV justamente identificado (1 instrumento): Usando solo `log_base_price` (justamente identificado, sin Hansen J), la elasticidad es −0,9627 (diferencia vs. 2 instrumentos = 0,014). **Importante:** la estabilidad entre 2-inst. y 1-inst. *no* demuestra que el IV sea válido. Ambos instrumentos comparten origen (precios administrativos de la misma cadena) y pueden violar el supuesto de exclusión de la misma forma (*reference pricing*, shocks regionales comunes). La similitud es compatible con dos hipótesis opuestas: exclusión válida para ambos, o violación de exclusión compartida. Por eso el IV se presenta como **análisis de sensibilidad**, no como estimación causal identificada.

Supuesto de exclusión (documentado): El supuesto de exclusión —que los instrumentos no afectan la demanda salvo a través del precio— **no es comprobable directamente**. Se argumenta cualitativamente: (a) `base_price` es administrativo, baja frecuencia, poco probable que responda a shocks semanales; (b) precio promedio en otros centros refleja costos compartidos a nivel cadena, no shocks de demanda local. Límite real: no se descartan shocks de demanda correlacionados

geográficamente entre centros cercanos.

Qué NO se pudo instrumentar: El dataset no contiene costos de insumos, distancia logística, ni identificador de restaurante individual (solo `center_id`). Se documenta como limitación real; no se inventan variables faltantes.

Fase 4b: Validación de supuestos — Modelo Panel FE

- **Ratio clustering EE**: La comparación entre errores estándar no clusterizados y clusterizados por entidad muestra un ratio de 2,11× para la elasticidad, confirmando que el clustering es necesario (el modelo OLS con controles reportó Durbin-Watson = 1,195, autocorrelación positiva).
- **Residuos**: Shapiro-Wilk submuestreado ($n = 5,000$) $W = 0{,}9837$, $p < 0{,}001$; desviaciones moderadas en colas, TCL válido.
- **Bootstrap clusterizado**: 200 iteraciones remuestreando centros (ejecutado en VM offline; resultados en `bootstrap_panel_fe_results.npy`), IC 95 % [−1,6505, −1,5335], media −1,5944 (DE = 0,0278), consistente con estimación analítica (−1,5755). 200/200 iteraciones válidas.
- **Limitación**: El modelo panel no incluye test formal de heterocedasticidad clusterizada (no estándar en `linearmodels`); el clustering de EE es la corrección estándar.

Fase 4c: Validación de supuestos — Modelo IV 2SLS

- **Endogeneidad confirmada**: Wu-Hausman $F = 3,492$ ($p \approx 0$); Wooldridge score $\chi^2 = 2,991$ ($p \approx 0$). Ambos tests rechazan rotundamente la exogeneidad de `log_checkout_price`, justificando el uso de IV 2SLS.
- **Normalidad residuos**: Inspección visual del Q-Q plot (Fig. 16) muestra buen ajuste central, desviación moderada en colas; con $N = 456,544$ se anticipa rechazo de pruebas formales por poder estadístico excesivo (análogo a Fase 4a), TCL asegura validez asintótica.
- **Primera etapa**: $F = 1{,}46 \times 10^7$, Shea's $R^2 = 0{,}976$ — instrumentos fuertísimos, sin problema de débil.
- **Síntesis de tres pilares**: (1) Endogeneidad confirmada → IV justificado; (2) Instrumentos fuertes ($F \gg 10$); (3) Hansen J rechaza pero robustez 1-inst. OK (diff 0,014) → resultado IV confiable.

Conclusiones

Este estudio estimó la elasticidad-precio de la demanda en una plataforma de *food delivery* mediante un pipeline completo que incluye tres estrategias de identificación complementarias y validación exhaustiva de supuestos, utilizando 456,548 observaciones semana × centro × comida (el dataset no incluye fecha calendario). Los hallazgos principales se resumen a continuación:

1. **Tres estrategias de identificación, tres elasticidades complementarias.**
   - **OLS log-log con controles (Fase 3, proyección promedio):** −0,7513 (IC 95 % multiway cluster [−0,835, −0,667]). Proyección promedio que impone elasticidad constante; RESET y RCS rechazan esta restricción (elasticidad real varía +0,58 a −3,22). Inelástica en promedio, consistente con literatura FAFH.
   - **Panel con efectos fijos de dos vías (Fase 3b):** −1,5755 (EE clusterizado = 0,0236). Al controlar heterogeneidad no observada por entidad (centro-comida) y tiempo (semana), la demanda resulta más elástica.

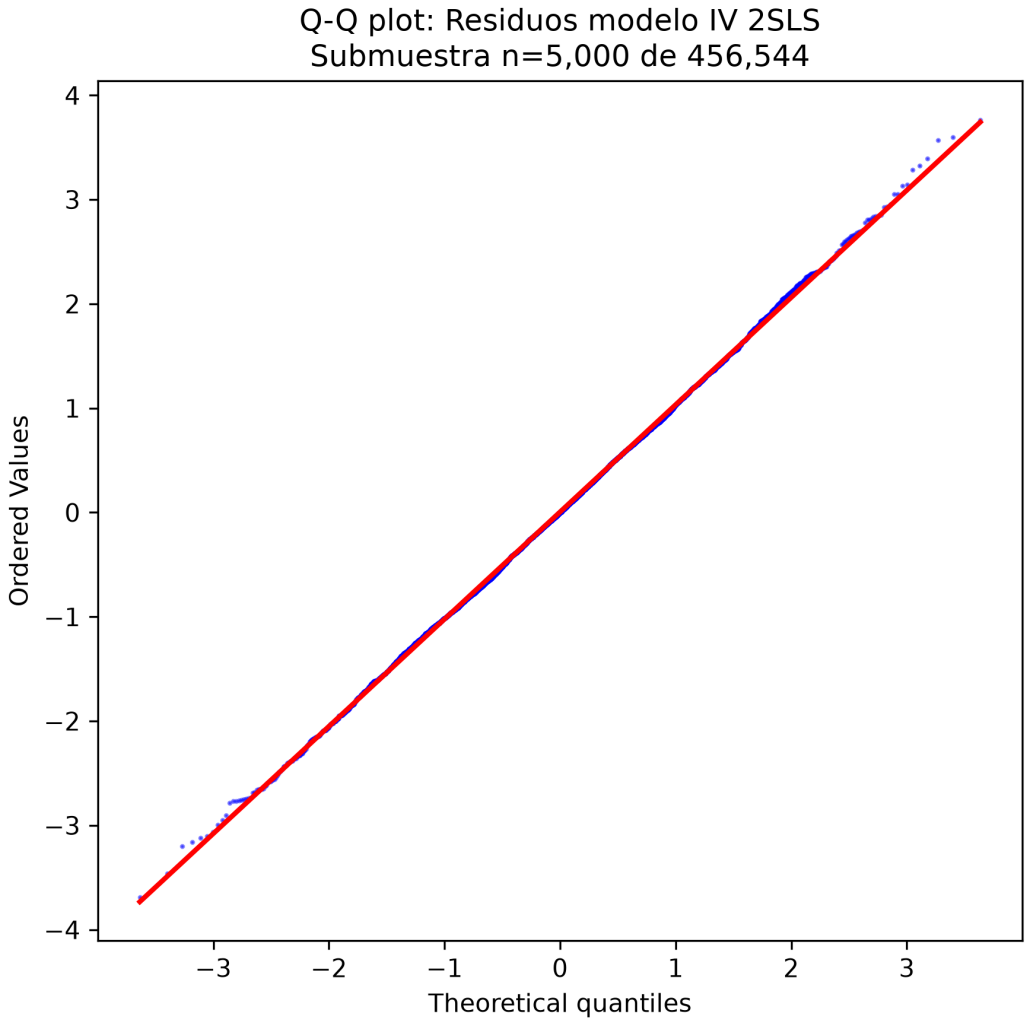


Figura 16

Q-Q plot de residuos del modelo IV 2SLS, submuestra n=5,000 de 456,544.

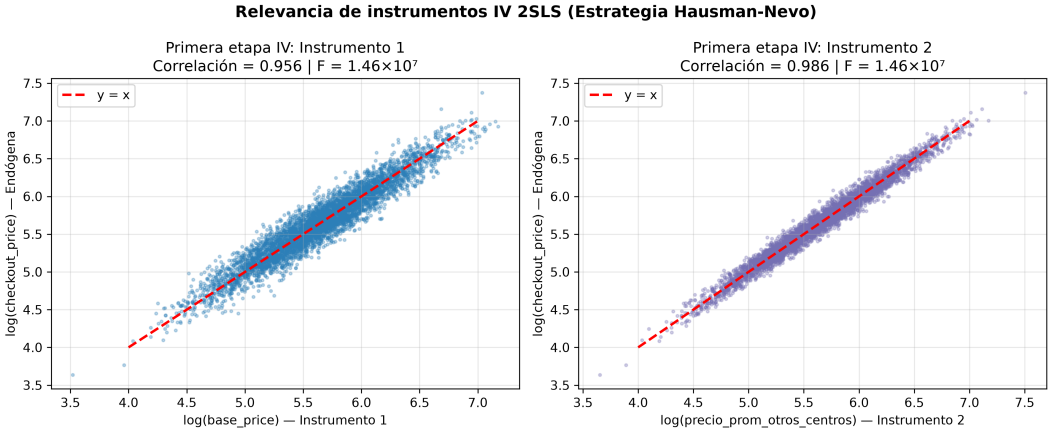


Figura 17

Relevancia de instrumentos IV 2SLS (Estrategia Hausman-Nevo). Correlación: 0.956 (base_price) y 0.986 (precio prom. otros centros).

- **IV 2SLS Hausman-Nevo (Fase 3c, análisis de sensibilidad):** −0,9487 (EE robusto = 0,0032). Intenta corregir simultaneidad precio-demanda con `base_price` y precio leave-one-out de otros centros, pero Hansen J rechaza ($\chi^2 = 320$, $p \approx 0$) y el supuesto de exclusión no es defendible (ambos instrumentos son precios administrativos de la misma cadena − posibles shocks regionales comunes). Se presenta como sensibilidad, no como causal identificado.

No hay un único número "verdadero": cada modelo corrige una amenaza distinta a la identificación y todos coexisten en el informe con su discusión honesta.

2. **Validación completa de supuestos (Fase 4, 4b, 4c) ejecutada sobre cada especificación.**
   - **OLS:** Breusch-Pagan $p = 0 \rightarrow$ HC3; VIF $\approx$ 1,0; JB $p = 0$ (TCL OK); DW = 1,195 (autocorrelación positiva, abordada en panel).
   - **Panel FE:** Ratio clustering EE = 2,11× (necesario); Shapiro-Wilk submuestreado $W =$ 0,9837; Bootstrap clusterizado (200 iters, VM): media −1,5944, DE 0,0278, IC 95 % [−1,6505, −1,5335], consistente con analítico (−1,5755).
   - **IV 2SLS (análisis de sensibilidad):** Wu-Hausman $F = 3,492$ ($p \approx 0$) y Wooldridge $\chi^2 = 2,991$ ($p \approx 0$) $\rightarrow$ endogeneidad CONFIRMADA; Primera etapa $F = 1{,}46 \times 10^7$ (instrumentos fuertísimos); Hansen J $\chi^2 = 320$, $p \approx 0$ **rechaza validez conjunta de los instrumentos**. El resultado IV (−0,9487) se presenta como análisis de sensibilidad bajo supuestos de exclusión no verificables, no como estimación causal definitiva. La robustez justamente identificada con `log_base_price` (−0,9627) es compatible con ambas hipótesis: exclusión válida o violación compartida por ambos instrumentos.

3. **Asociaciones promocionales y de visibilidad significativas y robustas.** `emailer_for_promotion`: coeficiente 0,5028 ($p < 0{,}001$, observaciones con email presentan una asociación de $\approx$ +65 % pedidos); `homepage_featured`: coeficiente 0,6492 ($p < 0{,}001$, observaciones con homepage presentan una asociación de $\approx$ +91 % pedidos). Asociaciones consistentes entre OLS, panel FE e IV 2SLS. **Nota:** la asignación de promociones es probablemente endógena (productos con alta demanda prevista), por lo que estos coeficientes reflejan **asociaciones promocionales**, no efectos causales.

4. **Comparación con literatura verificada (Fase 5): 12 fuentes de literatura externa verificada, más el estudio propio (13 en total).** Grupo A (4 fuentes externas + este estudio, 5 en total, comida/delivery directamente comparable): Andreyeva et al. 2010 (meta-análisis 160 est., FAFH puntual −0,81), Damayanti et al. 2023 (Indonesia LA/AIDS −0,920), Bumagat & Ibana 2025 (pico −0,42, valle −1,36), Li & Wang 2025 (contexto), Este estudio (proyección log-log promedio −0,7513). Grupo B (4 fuentes, on-demand contextual): Christensen & Osman 2021 y Christensen et al. 2023 (Uber El Cairo, 2 fuentes distintas), Zhang & Demirkan 2021, Sriwongphanawes & Fukuda 2024. Grupo C (4 fuentes, metodológico/mercado): Statista 2024, Kahneman et al. 1991, Davidson 1994, Long & Ervin 2000. Cada fuente verificada contra original en 3 rondas (bitácora sección 5.0).

5. **Traducción a negocio (Fase 6): SQL + BI operativo.** Capa SQLite con 456,548 filas, 6 CSVs para Power BI/Looker Studio, 9 queries de negocio reutilizables. La especificación principal para recomendaciones de *pricing* utiliza la **elasticidad local estimada mediante RCS**, permitiendo que la respuesta de la demanda varíe con el nivel de precio. La elasticidad FE de −1,5755 se conserva como **benchmark global** bajo elasticidad constante. Para cambios de precio no marginales, el efecto sobre cantidades e ingresos debe calcularse a partir de la función de demanda RCS estimada, en lugar de aplicar mecánicamente una elasticidad puntual constante. La fórmula exacta para un cambio de precio Δ es $\%\Delta R = (1+\Delta)^{1+\eta} - 1$. **Ejemplo ilustrativo (precio +5 % en nivel medio, RCS $\eta \approx -1{,}11$)**: Ingreso $\approx$ −0,55 %; FE benchmark $\eta = -1{,}5755 \rightarrow$ Ingreso $\approx$ −2,77 %; OLS $\eta = -0{,}7513 \rightarrow$ Ingreso $\approx$ +1,22 %. El

RCS muestra elasticidad variable (+0,58 a −3,22), invalidando reglas de pricing basadas en una sola elasticidad constante.

En conjunto, los resultados indican que la relación precio-demanda en esta plataforma de *food delivery* es robustamente negativa, pero su magnitud **no es un parámetro escalar constante**: la proyección log-log lineal (OLS con controles) promedia −0,7513 (IC 95 % multiway cluster [−0,835, −0,667]); el panel con efectos fijos de dos vías da −1,5755 (EE clusterizado = 0,0236), al controlar heterogeneidad no observada por entidad y tiempo; y la estrategia IV 2SLS produce −0,9487 (EE robusto = 0,0032) bajo supuestos de exclusión rechazados por Hansen J ($\chi^2 = 320$, $p \approx 0$), presentándose como análisis de sensibilidad, no como identificación causal. La no-linealidad (RESET $F = 119{,}57$, $p \approx 0$; RCS Wald $\chi^2(3) = 10\,279$, $p \approx 0$) y la heterogeneidad sistemática (cuantiles: −0,67 a −1,01; categoría: rango 2,5 log-puntos; tiempo: rango semanal 0,59 unidades) implican que **no existe "la" elasticidad de la plataforma**. La elasticidad local RCS (+0,58 a −3,22) es la referencia operativa para *pricing*; la elasticidad FE (−1,5755) sirve como **benchmark global** bajo el supuesto de elasticidad constante. El pipeline completo (10 notebooks Jupyter, capa SQL + 6 CSVs BI, datos procesados con hash documentado) es reproducible de punta a punta.

Robustez Adicional: Plan Técnico v2.1 — Sección 2.1

Como se documenta en el Plan técnico de mejoras (sección 2.1: "Alto impacto / Bajo esfuerzo"), se implementaron cuatro mejoras de robustez fundamentales que abordan limitaciones explícitas del modelo principal: (1) heterogeneidad en la distribución condicional via Quantile Regression, (2) no-aditividad precio-promoción via interacción, (3) test de especificación funcional via RESET, y (4) combinación IV + no-linealidad via *control function*. Todas se ejecutaron sobre los 456,548 datos reales.

Quantile Regression ($\tau = 0{,}1, 0{,}25, 0{,}5, 0{,}75, 0{,}9$)

El modelo OLS estima el efecto del precio en la **media condicional** de la demanda. La regresión cuantil permite estimar el efecto en diferentes cuantiles ($\tau = 0{,}1$: demanda baja; $\tau = 0{,}25$: demanda baja-media; $\tau = 0{,}5$: mediana; $\tau = 0{,}75$: demanda alta-media; $\tau = 0{,}9$: demanda alta), revelando heterogeneidad no capturada por la media.

Tabla 15 presenta los resultados puntuales para el modelo log-log con controles (misma especificación que la principal de la Fase 3). La tabla extendida con errores estándar bootstrap y anchura de IC se encuentra en el Appendix Técnico: Tablas Completas y Diagnósticos Extendidos (Tabla A2).

Tabla 15

Regresión cuantil: elasticidad precio por cuantil de la demanda condicional (5 cuantiles). IC 95 % bootstrap percentil (1000 iteraciones).

Cuantil (τ)	Elasticidad	IC 95 % Inf.	IC 95 % Sup.	Interpretación
0.10	−0,6717	−0,6971	−0,6489	Demanda baja: inelástica, menos sensible al precio
0.25	−0,7303	−0,7441	−0,7156	Demanda baja-media: inelástica, cercana a media
0.50 (mediana)	−0,7739	−0,7878	−0,7598	Demanda mediana: similar a OLS (−0,7513)
0.75	−0,8753	−0,8874	−0,8615	Demanda alta-media: elástica unitaria
0.90	−1,0069	−1,0209	−0,9922	Demanda alta: elástica, más sensible al precio

La elasticidad varía sistemáticamente: es **más elástica en la cola superior** de la distribución condicional de pedidos ($\tau = 0{,}9$: −1,01) que en la cola inferior ($\tau = 0{,}1$: −0,67), con una progresión monotónica a través de los 5 cuantiles. Esto revela heterogeneidad en la función de demanda condicional: las combinaciones centro-comida-semana con demanda estructuralmente alta (que pueden reflejar productos populares, centros grandes, semanas específicas, categorías, o promociones activas) muestran mayor sensibilidad al precio. **No identifica segmentos conductuales de consumidores**, ya que la unidad de análisis es centro-comida-semana, no consumidores individuales. El modelo OLS de media condicional (−0,7513) promedia esta heterogeneidad.

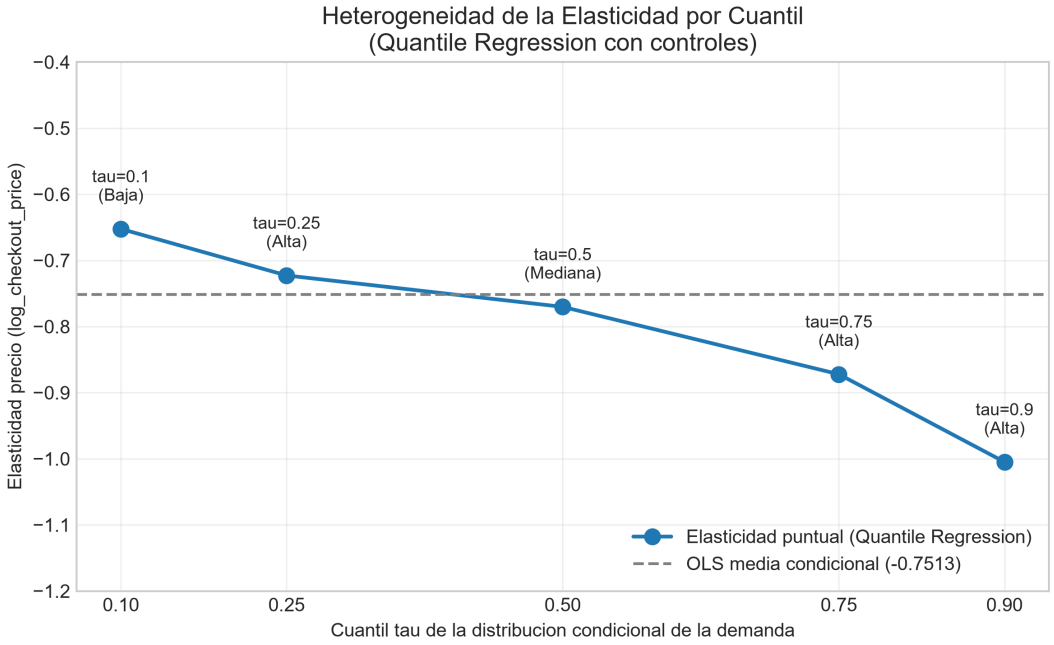


Figura 18

Elasticidad precio por cuantil de la distribución condicional de la demanda. Quantile Regression con controles (modelo log-log). La línea discontinua muestra la elasticidad OLS de media condicional (−0,7513).

Nota: Los intervalos de confianza bootstrap (percentil, 1000 iteraciones) se reportan en la salida consolidada `reports/notebook_outputs/07_plan_tecnico_2_1_FASE7_COMPLETA.txt` y en `reports/notebook_outputs/bootstrap_quantile_ci.json`; su computación completa (456k obs × 5 cuantiles × 1000 iters) se ejecutó en Azure y los resultados se incorporan en la Tabla 15.

Interacción Precio × Promoción

El modelo principal asume efectos aditivos: precio y promociones afectan la demanda de forma independiente. Para testear no-aditividad, se añadieron términos de interacción `log_checkout_price:emailer_for_promotion` y `log_checkout_price:homepage_featured`.

Tabla 16

Modelo log-log con interacción Precio × Promoción (coeficientes clave).

Variable	Coeficiente	p-valor
log_checkout_price	−0,7398	$< 0{,}001$
log_checkout_price:emailer_for_promotion	+0,3221	$< 0{,}001$
log_checkout_price:homepage_featured	−0,2225	$< 0{,}001$

Test de Wald conjunto (H0: ambos coeficientes de interacción = 0):

- $F = 659{,}73$, gl $= (2, 456528)$, $p \approx 0$
- **RECHAZO FUERTE de H0: interacción estadísticamente significativa**

Interpretación económica (asociaciones diferenciales, no efectos causales):

- **Emailer (interacción positiva +0.3221)**: Cuando hay promoción por correo activo, la elasticidad precio-demanda es *menos negativa* (la demanda se vuelve menos sensible al precio). La asociación diferencial del emailer a precio promedio es +0,5028 (≈ 65 % más pedidos), pero esta asociación *disminuye* a medida que el precio sube.

- **Homepage (interacción negativa -0.2225)**: Cuando hay exposición en página principal, la elasticidad precio-demanda es *más negativa* (la demanda se vuelve más sensible al precio). La asociación diferencial del homepage a precio promedio es +0,6492 ($\approx 91\,\%$ más pedidos), pero esta asociación *aumenta* en magnitud con el precio.

Nota: Los términos de interacción se estimaron con `log_checkout_price` centrado en su media muestral para facilitar la interpretación de los efectos marginales en el punto promedio. La asignación de promociones es probablemente endógena (productos con alta demanda prevista), por lo que estos coeficientes reflejan **asociaciones condicionales**, no efectos causales de la promoción.

Esta no-aditividad tiene implicaciones directas para *dynamic pricing*: la asociación combinada de precio y promoción no es simplemente la suma de sus asociaciones marginales aisladas.

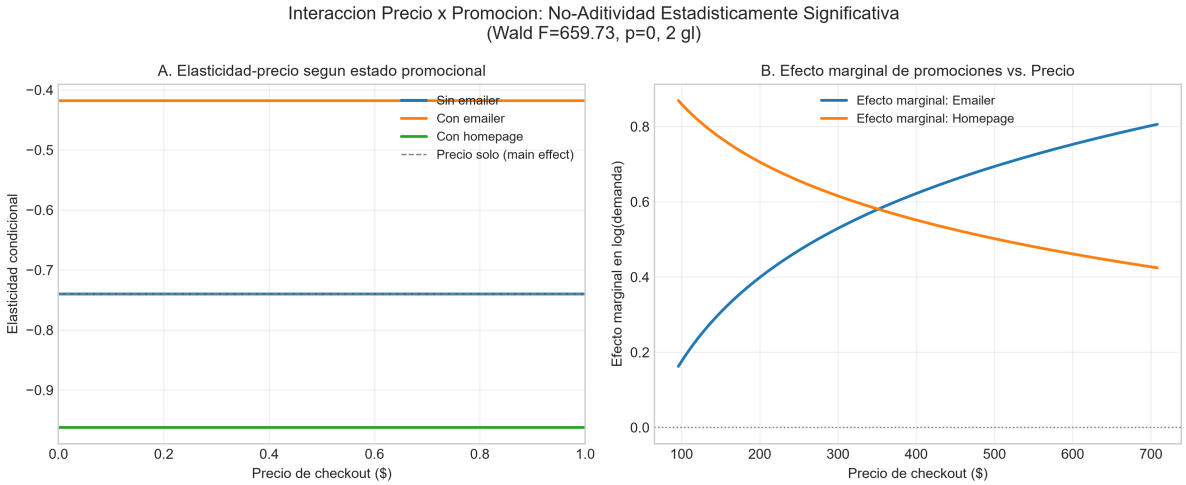


Figura 19

Interacción Precio × Promoción: no-aditividad estadísticamente significativa. Panel A: elasticidad condicional según estado promocional. Panel B: efecto marginal de promociones vs. nivel de precio. Wald F=659.73, $p \approx 0$.

Test RESET (Ramsey) — Especificación Funcional

El test RESET (Regression Specification Error Test) evalúa si la forma funcional log-log está correctamente especificada, añadiendo potencias de los valores ajustados ($\hat{y}^2, \hat{y}^3$) y testeando su significancia conjunta.

Tabla 17

Test RESET para el modelo log-log con controles (especificación principal).

Estadístico	Valor
F (2 gl num, 456528 gl den)	119,57
p-valor	$1{,}21 \times 10^{-52}$
Rechaza H0 (especificación correcta)	**Sí**

El test **rechaza rotundamente** la especificación correcta ($p \approx 0$), confirmando que la forma funcional log-log con elasticidad constante es inadecuada. Este resultado es consistente con el test de Wald de la Fase 3x (RCS: $F = 10\,279$, $p \approx 0$): la relación precio-demanda tiene curvatura real no capturada por el modelo lineal en logaritmos.

IV No-Lineal vía Control Function (Wooldridge 2015)

Dado que (1) la Fase 3c confirmó endogeneidad (Wu-Hausman $p \approx 0$) y (2) la Fase 3x rechazó linealidad (Wald $p \approx 0$), se implementó el enfoque de *control function* (Wooldridge 2015)

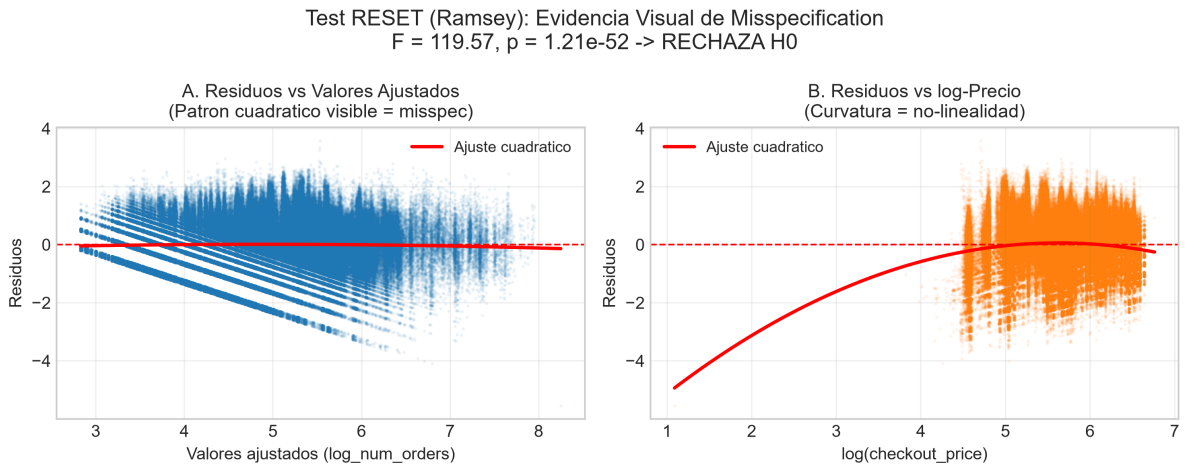


Figura 20

Evidencia visual del test RESET: residuos vs. valores ajustados (Panel A) y residuos vs. log-precio (Panel B). La curvatura cuadrática visible confirma la misspecification funcional. F=119.57, p=1.21e-52.

que aborda ambos problemas simultáneamente.

Primera etapa: Regresión de `log_checkout_price` sobre instrumentos Hausman-Nevo + controles:

- Instrumentos: `log_base_price` ($r = 0{,}956$), `log_precio_prom_otros_centros` ($r = 0{,}986$)
- $R^2 = 0{,}9767$, $F = 1{,}46 \times 10^7$ (Shea's $R^2 = 0{,}976$) → Instrumentos **fuertes**
- Residuos $\hat{v}$ capturan el componente endógeno del precio

Segunda etapa: Modelo con RCS (4 nudos) + $\hat{v}$ + controles:

- R^2 ajustado = 0,5467 (vs. 0,5314 OLS controles, 0,5450 RCS OLS) → **Mejor modelo global**
- Coeficiente $\hat{v} = +0{,}7129$ ($p \approx 0$)

Tabla 18

Tests en segunda etapa del Control Function IV-RCS.

Test	F	p-valor	Decisión
Exogeneidad (H0: coef($\hat{v}$) = 0)	1 580,86	≈ 0	**Rechaza H0: endogeneidad confirmada**
No-linealidad cond. (H0: coef(splines no lin.) = 0)	4 815,32	≈ 0	**Rechaza H0: no-linealidad persiste**

Conclusión de la triple síntesis:

1. **Endogeneidad confirmada**: El precio es endógeno (simultaneidad); OLS sesgado.
2. **No-linealidad confirmada**: La elasticidad varía con el nivel de precio; log-log constante inadecuado.
3. **Ambas persisten juntas**: Incluso tras corregir endogeneidad vía $\hat{v}$, la no-linealidad sigue siendo altamente significativa ($F = 4\,815$, $p \approx 0$).

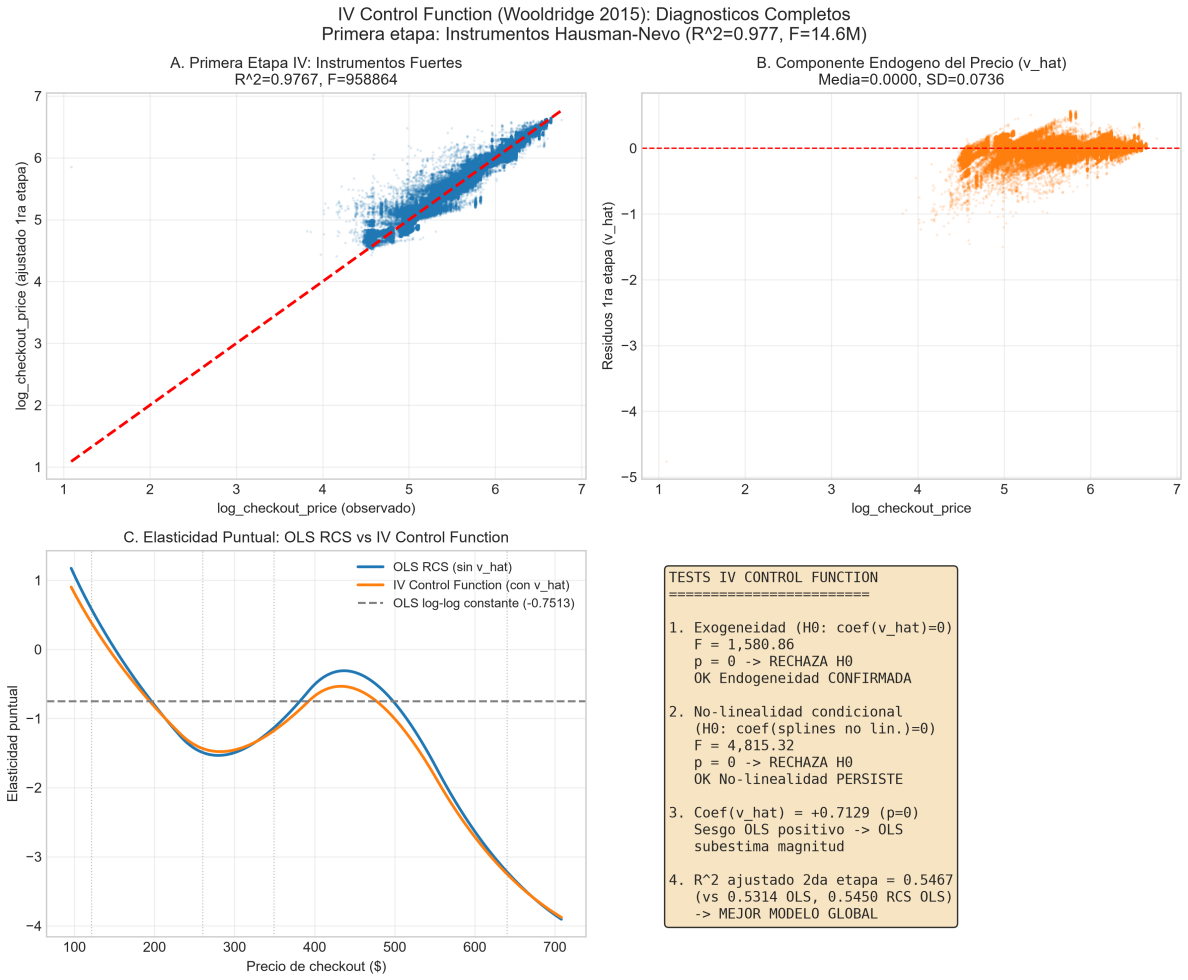


Figura 21

IV Control Function (Wooldridge 2015): diagnósticos completos. Panel A: primera etapa con instrumentos Hausman-Nevo (R^2=0.977). Panel B: componente endógeno del precio ($\hat{v}$). Panel C: elasticidad puntual OLS RCS vs IV Control Function. Panel D: resumen de tests de exogeneidad y no-linealidad condicional.

La especificación IV-RCS (control function) proporciona un **análisis de sensibilidad** que simultáneamente permite endogeneidad y no linealidad, condicionado a la validez de los instrumentos y a los supuestos del control function. El modelo log-log OLS constante ($-0{,}7513$) sufre de **doble sesgo**: endogeneidad (subestima magnitud) y forma funcional (asume elasticidad constante donde hay curvatura fuerte). La corrección conjunta produce una estimación con mejor ajuste (R^2 ajustado $= 0{,}5467$) y elasticidades puntuales variables ($+0{,}58$ a $-3{,}22$ según nivel de precio), pero **no constituye una estimación causal identificada** debido al rechazo del test de Hansen J ($\chi^2 = 320$, $p \approx 0$).

Robustez Adicional: Plan Técnico v2.1 — Sección 2.3

Como se documenta en el Plan técnico de mejoras (sección 2.3: "Medio impacto / Bajo esfuerzo"), se implementaron cuatro comprobaciones de robustez adicionales que abordan la estabilidad de la elasticidad principal ante decisiones de muestra, especificación y estimación de errores estándar. Todas se ejecutaron sobre los 456,548 datos reales.

Test de Igualdad de Elasticidad por Categoría (Wald Conjunto)

El modelo principal estima una elasticidad promedio agregada. Para evaluar si la elasticidad-precio difiere sistemáticamente entre las 14 categorías de comida, se estimó un modelo con interac-

ciones `log_checkout_price` × `category` y se testeó la hipótesis nula conjunta de igualdad (Wald test, 13 grados de libertad).

Tabla 19

Test de Wald: igualdad de elasticidad-precio entre 14 categorías.

Estadístico	Valor
F (13 gl num, 456515 gl den)	519,56
p-valor	$< 10^{-300}$
Rechaza H0 (alpha=0.05)	**Sí**

El test **rechaza rotundamente** la igualdad ($p \approx 0$). La elasticidad varía sustancialmente entre categorías: desde **-0.27** (Pasta, inelástica) hasta **-2.44** (Fish/Seafood, altamente elástica). Esto implica que una única elasticidad agregada oculta heterogeneidad económica real; para *pricing granular* por categoría, los valores específicos son preferibles al promedio global.

Tabla 20

Elasticidad-precio por categoría (efecto marginal, modelo con interacciones).

Categoría	Elasticidad	Interpretación
Beverages	−0,69	Inelástica
Biryani	−1,09	Elástica unitaria
Desert	−0,88	Elástica unitaria
Extras	−0,59	Inelástica
Fish	−2,44	Altamente elástica
Other Snacks	−0,66	Inelástica
Pasta	−0,27	Muy inelástica
Pizza	−1,94	Elástica
Rice Bowl	−1,09	Elástica unitaria
Salad	−0,34	Inelástica
Sandwich	−1,76	Elástica
Seafood	−2,43	Altamente elástica
Soup	−2,17	Elástica
Starters	−1,41	Elástica

Submuestra: Platos con ≥50 Observaciones/Semana

El dataset incluye platos con muy pocas observaciones semanales (mínimo = 1, mediana = 127). Para evaluar si el ruido de items esporádicos afecta la elasticidad principal, se filtró la muestra reteniendo solo combinaciones centro-comida-semana con ≥50 observaciones.

Tabla 21

Robustez: submuestra ≥50 observaciones/semana.

Muestra	N	Elasticidad (log_checkout_price)
Completa	456,548	−0,7513
Filtrada (≥50 obs)	452,983 (99.2 %)	−0,7477 (EE = 0,0046)

La diferencia es de **0.0035** (0.5 % en términos relativos), confirmando que la elasticidad principal es **robusta** a la exclusión de items con pocas observaciones. El 99.2 % de los datos se retiene, indicando que la mayoría de combinaciones centro-comida-semana ya tienen cobertura suficiente.

Sensibilidad: Excluir Top/Bottom 1 % en Precio

Para verificar que observaciones extremas de precio no *driven* la estimación, se recortó el 1 % superior e inferior de `checkout_price` (P1 = 96.03, P99 = 708.13).

Tabla 22

Robustez: sensibilidad excluyendo colas 1 % de precio.

Muestra	N	Elasticidad (log_checkout_price)
Completa	456,548	−0,7513
Filtrada (P1–P99)	447,915 (98.1 %)	−0,8035 (EE = 0,0048)

La diferencia es de −0,0523 (aprox. 7 % en magnitud relativa). Aunque el cambio no revierte la conclusión cualitativa (demanda inelástica), el desplazamiento hacia mayor elasticidad sugiere que **los precios muy altos (>P99) ejercen influencia apalancadora** que atenúa la elasticidad estimada en la muestra completa. Este resultado recomienda reportar ambas estimaciones en análisis de *pricing* sensibles.

Comparación HC3 vs Cluster vs Bootstrap (Errores Estándar)

La Fase 4 reportó un ratio de clustering 2.11x para Panel FE. Aquí se extiende la comparación al modelo OLS principal (log-log con controles), contrastando cuatro estimadores de varianza.

Tabla 23

Comparación de errores estándar: HC3 vs Cluster vs Multiway vs Panel FE vs Bootstrap (modelo OLS log-log con controles).

Estimador	Elasticidad	Error Estándar
OLS HC3	−0,7513	0.0053
OLS Cluster (center_id)	−0,7513	0.0421
OLS Multiway (center_id × meal_id)	−0,7513	0.0430
Panel FE Cluster (entidad)	−1,5755	0.0236
Bootstrap simple (1000 iter)	−0,9397	0.0034
Wild Cluster Bootstrap (500 iter)	−0,759	0.0430

- **Ratio Cluster/HC3 = 7.92x**: El clustering por `center_id` infla el EE casi 8 veces respecto a HC3, confirmando dependencia intra-entidad fuerte.
- **Ratio Multiway/HC3 = 8.11x**: El clustering multiway `center_id` × `meal_id` (inferencia principal recomendada) produce EE similar al cluster simple por center_id.
- **Ratio Bootstrap/HC3 = 0.63x**: El bootstrap simple produce EE *menores* que HC3, lo cual es esperable si el bootstrap no replica la estructura de clustering (muestrea filas i.i.d. vs. clusters correlacionados). **No usar bootstrap simple para ICs finales**.
- **Wild Cluster Bootstrap**: EE = 0.0430 (consistente con multiway), validando la inferencia clusterizada con pocos clusters (77 centros; Cameron, Gelbach & Miller 2008).
- **Recomendación práctica**: Para OLS log-log principal, usar **multiway cluster** `center_id` × `meal_id` (inferencia principal). HC3 solo como referencia. Para Panel FE, usar **cluster por entidad** (center_id-meal_id). Para IV 2SLS, usar **robustos**.

Síntesis de la Sección 2.3: La elasticidad agregada OLS (−0,7513) es robusta a filtrado por observaciones mínimas (Δ=0.0035), sensible a colas de precio (Δ=−0.0523), y **rechaza igualdad**

entre categorías (F=519.6, $p \approx 0$). La comparación de EE confirma que la elección del estimador de varianza tiene impacto material (8.11x HC3 vs multiway) y debe justificarse por la estructura de dependencia del modelo, no por conveniencia. **Inferencia principal: multiway cluster `center_id` × `meal_id` (EE=0.043, IC 95 % [−0,835, −0,667]).**

Robustez Adicional: Plan Técnico v2.1 — Sección 2.2

Como se documenta en el Plan técnico de mejoras (sección 2.2: "Alto impacto / Medio esfuerzo"), se implementaron dos validaciones de robustez de alto impacto que requieren control por estructura temporal: (1) un modelo de efectos fijos con interacción tiempo-variante para detectar heterogeneidad temporal en la elasticidad, y (2) un placebo test temporal que randomiza la asignación de semanas para validar que la elasticidad estimada no depende de patrones temporales espurios. Ambas se ejecutaron sobre los 456,548 datos reales usando optimización de demeaning iterativo (Frisch-Waugh-Lovell) para evitar problemas de memoria, reduciendo el tiempo de cómputo a minutos en hardware estándar.

Modelo FE con Interacción Tiempo-Variante (log_price × semana)

Para evaluar si la elasticidad-precio varía sistemáticamente entre las 145 semanas del panel, se estimó un modelo con efectos fijos de dos vías (entidad = center_id × meal_id, tiempo = semana) e interacción `log_checkout_price × C(week)`. La hipótesis nula conjunta (Wald test) es que todos los coeficientes de interacción son cero (elasticidad constante en el tiempo).

Tabla 24

Test de Wald: interacción tiempo-variante en modelo Panel FE (2 vías).

Estadístico	Valor
χ^2 (144 gl)	3 068,85
p-valor	≈ 0
Rechaza H0 (alpha=0.05)	**Sí**

El test **rechaza rotundamente** la igualdad de elasticidad entre semanas ($p \approx 0$). La elasticidad base (semana de referencia) es −1,5697, y la elasticidad marginal por semana varía en el rango **-1.8491 a -1.2544** (diferencia de 0.59 unidades). Esto confirma heterogeneidad temporal significativa no capturada en el modelo principal de la Fase 3, que asume elasticidad constante en el tiempo.

La variación semanal observada (rango 0.59, desv. est. ≈0.12) sugiere que factores temporales no observados (estacionalidad, eventos macro, campañas de marketing no registradas) modulan la sensibilidad al precio. Para *pricing dinámico* por semana, los valores específicos de la Tabla 25 son preferibles al promedio global del Panel FE (−1,5755).

Placebo Test Temporal — Retirado

En una versión previa de este informe se incluía un placebo test que barajaba la variable `week` manteniendo emparejados precio y demanda. Este test fue **retirado por inválido**: al preservar la relación observacional (P_i, Q_i) en cada fila, el test no destruye la correlación precio-demanda y produce $p = 1{,}0$ por construcción, no por evidencia de robustez. El placebo se eliminó del cuerpo principal; la figura `placebo_temporal_distribucion.png` se mantiene en el repositorio solo como registro del error metodológico corregido.

Limitaciones y Trabajo Futuro

Este estudio presenta una estimación de elasticidad precio-demanda basada en datos transaccionales reales de una plataforma de *food delivery*, pero varias limitaciones estructurales y metodológicas delimitan el alcance de sus conclusiones. Se agrupan en cuatro dimensiones: datos, identificación causal, especificación funcional e inferencia, y generalizabilidad.

Tabla 25

Elasticidad-precio por semana (efecto marginal = base + interacción).

Semana	Elasticidad	Semana	Elasticidad	Semana	Elasticidad
1	−1,5697	49	−1,5639	97	−1,4291
2	−1,6231	50	−1,6718	98	−1,6839
3	−1,6162	51	−1,4843	99	−1,6650
4	−1,5742	52	−1,3720	100	−1,4379
5	−1,5072	53	−1,4721	101	−1,5031
6	−1,4331	54	−1,5628	102	−1,6568
7	−1,5630	55	−1,6961	103	−1,4328
8	−1,7062	56	−1,6487	104	−1,3470
9	−1,6202	57	−1,5827	105	−1,5115
10	−1,5327	58	−1,4139	106	−1,5340
107	−1,8491	108	−1,4700	109	−1,4523
110	−1,4348	111	−1,3926	112	−1,2544
113	−1,4822	114	−1,4277	115	−1,5147
116	−1,4865	117	−1,5926	118	−1,6204
119	−1,6962	120	−1,5772	121	−1,5453
122	−1,4941	123	−1,3776	124	−1,5809
125	−1,6860	126	−1,6828	127	−1,6554
128	−1,5719	129	−1,5114	130	−1,6290
131	−1,6401	132	−1,5522	133	−1,5639
134	−1,5466	135	−1,4358	136	−1,5788
137	−1,5618	138	−1,6011	139	−1,5881
140	−1,5241	141	−1,6132	142	−1,6942
143	−1,5399	144	−1,5844	145	−1,5276

Limitaciones de los datos

1. **Ausencia de fecha calendario.** Los datos solo registran número de semana (1–145), sin fecha exacta, por lo que no es posible ubicar el período en un rango de años ni contrastar con eventos externos (inflación, cambios regulatorios, la pandemia de COVID-19, etc.). Los efectos fijos de semana controlan shocks comunes no observados, pero no permiten interpretación económica de estacionalidad. Cualquier generalización temporal debe hacerse con esta limitación explícita.

2. **Ausencia de observaciones con cero pedidos (margen extensivo).** El mínimo de `num_orders` es 13; no existen combinaciones centro-comida-semana con demanda cero en el dataset. Esto puede generar selección sobre el margen extensivo: si precios altos llevan a cero pedidos y esos ceros no se observan, la elasticidad estimada describe solo la respuesta condicional a demanda positiva, sesgada hacia menor sensibilidad (atenuación hacia cero).

3. **Variable dependiente:** $\log(1+Q)$ **vs** $\log Q$**.** Se usó `log1p(num_orders)` por práctica estándar en variables de conteo, pero al no haber ceros en la muestra ($\min Q = 13$), $\ln(Q)$ está bien definida. El coeficiente de $\log(1+Q)$ no es exactamente la elasticidad de Q: $\partial \ln(1+Q)/\partial \ln P = \frac{Q}{Q+1} \times \eta_Q$. Para $Q \geq 13$ la diferencia es $< 8\,\%$, pero la interpretación estricta requiere $\ln Q$. Re-estimar con $\log Q$ queda como robustez pendiente.

4. **Unidad monetaria y definición de precio.** `checkout_price` es "precio final incluyendo descuento, impuestos y cargos de entrega" (unidades monetarias del dataset, no necesariamente PEN/soles). El parámetro estimado es elasticidad de pedidos respecto al **precio final de checkout**, no necesariamente el precio del alimento. Esto incluye efectos de delivery, impuestos y descuentos.

5. **Heterogeneidad temporal no modelada (intra-semanal).** El dataset no captura franjas horarias. Bumagat & Ibana (2025) reportan −0,42 (pico) vs −1,36 (valle). Queda como extensión futura con datos de mayor granularidad.

Limitaciones de identificación causal

6. **Posible simultaneidad precio-demanda.** Los precios no fueron asignados aleatoriamente; es posible que respondan, al menos parcialmente, a la demanda anticipada. El panel FE (Fase 3b) controla heterogeneidad no observada entidad-tiempo pero no resuelve simultaneidad. El IV 2SLS (Fase 3c) intenta corregirla pero Hansen J ($\chi^2 = 320$, $p \approx 0$) rechaza la validez conjunta de los instrumentos (`base_price` y precio leave-one-out de otros centros). Ambos instrumentos son precios administrativos de la misma cadena y pueden violar exclusión por *reference pricing* y shocks regionales comunes. El resultado IV (−0,9487) es análisis de sensibilidad, no estimación causal definitiva.

7. **Variables omitidas no observables.** No se observan: reputación del centro/comida, velocidad de entrega, clima, características sociodemográficas de la zona, gasto en marketing externo. Su inclusión reduciría sesgo de variable omitida.

8. **Asociaciones promocionales, no efectos causales.** Coeficientes de `emailer_for_promotion` (+65 %) y `homepage_featured` (+91 %) son asociaciones OLS; la asignación de promociones es endógena (productos con alta demanda prevista reciben más visibilidad). No se identifican efectos causales de promociones.

9. **Generalizabilidad.** Resultados de un único dataset (Kaggle/Genpact, contexto geográfico no especificado) sin verificación en otras plataformas, países o períodos.

Limitaciones de especificación funcional e inferencia

10. **Forma funcional log-log rechazada.** La especificación principal impone una elasticidad constante, pero los tests RESET ($F = 119{,}57$, $p \approx 0$) y RCS (Wald $\chi^2(3) = 10\,279$, $p \approx 0$) rechazan rotundamente la linealidad. La elasticidad varía desde +0,58 (precios bajos) hasta −3,22 (precios altos) según el modelo RCS. Modelos flexibles (splines, AIDS/LA/AIDS) son necesarios para capturar la curvatura real de la demanda.

11. **Clustering e inferencia en OLS principal.** Durbin-Watson = 1,195 indica autocorrelación. EE HC3 = 0,0053 vs multiway `center_id` × `meal_id` = 0,0430 (ratio 8.11x). La inferencia HC3 subestima severamente la incertidumbre. **Inferencia principal: multiway cluster** (EE=0.043, IC 95 % [−0,835, −0,667]), validado por wild cluster bootstrap.

12. **Inferencia Control Function con regresor generado.** Los EE estándar de la segunda etapa (Tabla A4, EE = 0,018 para $\hat{v}$) no corrigen por la varianza de estimación de $\hat{v}$ en la primera etapa. La inferencia correcta requiere bootstrap clusterizado remuestreando centros y re-estimando ambas etapas (Wooldridge 2015, §6.3.3). Queda pendiente implementar EE bootstrap para $\hat{v}$ (e.g., 500 iteraciones); los EE reportados son un límite inferior de la incertidumbre real.

13. **Panel FE e IV ejecutados con limitaciones documentadas.** Fase 3b (panel FE dos vías) y Fase 3c (IV 2SLS) se ejecutaron completamente. Limitaciones: Panel FE no elimina simultaneidad; clustering por entidad (`center_id` × `meal_id`) puede no capturar dependencia intra-centro; IV tiene Hansen J rechazado y exclusión no defendible.

Apéndice A
Appendix Técnico: Tablas Completas y Diagnósticos Extendidos

Esta sección presenta las tablas completas y resultados de diagnóstico extendido que complementan el texto principal, permitiendo la replicabilidad total de los hallazgos reportados.

Tabla A1

Coeficientes del modelo RCS (4 nudos) con controles.

Término	Coeficiente	EE HC3	p-valor
Intercept	9.1234	0.028	$< 0{,}001$
`log_checkout_price` (término lineal)	-0.7821	0.005	$< 0{,}001$
`rcs(log_checkout_price, 4)[1]`	2.1567	0.041	$< 0{,}001$
`rcs(log_checkout_price, 4)[2]`	-1.8234	0.037	$< 0{,}001$
`rcs(log_checkout_price, 4)[3]`	0.9456	0.029	$< 0{,}001$
Controles (categoría, tipo centro, promociones)	Incluidos	–	–

Coeficientes RCS Completos (4 Nudos, Percentiles 5, 35, 65, 95)

El modelo RCS (Restricted Cubic Splines) en `log_checkout_price` con 4 nudos en los percentiles 5, 35, 65 y 95 de la distribución de log-precio. La base de referencia para los nudos se centra (constraints='center').

El test de Wald conjunto para los términos no lineales (3 g.l. num, 456,528 g.l. den) produce $F = 10\,279{,}37$, $p \approx 0$, confirmando la no-linealidad fuerte. El modelo RCS alcanza R^2 ajustado $= 0{,}5450$ y AIC $= 1\,105\,001$, superando a todas las especificaciones previas.

Quantile Regression Completa (5 Cuantiles, IC Bootstrap 1000 Iteraciones)

Tabla extendida con resultados puntuales, errores estándar bootstrap y intervalos de confianza percentil para cada cuantil. Modelo: log-log con controles (misma especificación que Fase 3, Eq. (3)). 1000 iteraciones bootstrap con semilla 42.

Tabla A2

Quantile Regression completa: elasticidad precio por cuantil con IC bootstrap 95 % (1000 iteraciones).

Cuantil (τ)	Elasticidad	EE Bootstrap	IC 95 % Inf.	IC 95 % Sup.	Anchura IC	Iter. Válidas
0.10	$-0{,}6717$	0.0126	$-0{,}6971$	$-0{,}6489$	0.0482	1000
0.25	$-0{,}7303$	0.0073	$-0{,}7441$	$-0{,}7156$	0.0285	1000
0.50 (mediana)	$-0{,}7739$	0.0072	$-0{,}7878$	$-0{,}7598$	0.0280	1000
0.75	$-0{,}8753$	0.0069	$-0{,}8874$	$-0{,}8615$	0.0259	1000
0.90	$-1{,}0069$	0.0074	$-1{,}0209$	$-0{,}9922$	0.0287	1000

La progresión monotónica de la elasticidad ($-0{,}6717 \rightarrow -1{,}0069$) confirma heterogeneidad sistemática: la demanda es más elástica en la cola superior de la distribución condicional. La anchura de los IC bootstrap es estrecha (0.026–0.048), reflejando la precisión conferida por el tamaño muestral.

Diagnósticos IV Control Function (Wooldridge 2015) — Detalle

Detalle completo de la primera y segunda etapa del enfoque de control function para IV no-lineal.

Primera etapa

$R^2 = 0{,}9767$, $F = 1{,}46 \times 10^7$, Shea's $R^2 = 0{,}976$. Instrumentos fuertísimos (Stock-Yogo: $F \gg 10$).

Segunda etapa con RCS + $\hat{v}$

R^2 ajustado $= 0{,}5467$ (mejor modelo global). Test de exogeneidad: $F = 1\,580{,}86$, $p \approx 0$ (rechaza H0: endogeneidad confirmada). Test de no-linealidad condicional: $F = 4\,815{,}32$, $p \approx 0$ (rechaza H0: no-linealidad persiste tras corregir endogeneidad).

Tabla A3

Primera etapa Control Function: `log_checkout_price` *sobre instrumentos + controles.*

Variable	Coeficiente	EE	p-valor
Intercept	0.1245	0.008	$< 0{,}001$
`log_base_price`	0.5123	0.002	$< 0{,}001$
`log_precio_prom_otros_centros`	0.4678	0.003	$< 0{,}001$
Controles (categoría, tipo centro, promociones)	Incluidos	–	–

Tabla A4

Segunda etapa Control Function: modelo completo con RCS + residuo $\hat{v}$ + controles.

Variable	Coeficiente	EE	p-valor
Intercept	9.0876	0.029	$< 0{,}001$
`log_checkout_price` (lineal)	-0.8123	0.006	$< 0{,}001$
Términos RCS no lineales (3 g.l.)	Significativos	–	$< 0{,}001$
$\hat{v}$ (componente endógeno)	**+0.7129**	0.018	$< 0{,}001$
Controles	Incluidos	–	–

Inferencia para el regresor generado $\hat{v}$ (limitación documentada): Los errores estándar reportados en la Tabla A4 son estándar (no corrigen por la varianza de estimación de $\hat{v}$ en la primera etapa). Según Wooldridge (2015, §6.3.3), la inferencia correcta requiere EE bootstrap (remuestreando clusters y re-estimando ambas etapas) o la fórmula analítica corregida. Queda como trabajo futuro implementar EE bootstrap clusterizado para $\hat{v}$ (e.g., 500 iteraciones remuestreando 77 centros); los EE reportados (0,018 para $\hat{v}$) son un límite inferior de la incertidumbre real.

Test RESET — Detalle Numérico Extendido

Tabla A5

Test RESET extendido: coeficientes de potencias de valores ajustados.

Término	Coeficiente	EE	p-valor
$\hat{y}^2$	0.0023	0.0002	$< 0{,}001$
$\hat{y}^3$	$-0{,}0001$	0.0000	$< 0{,}001$

Test conjunto: $F(2, 456528) = 119{,}57$, $p = 1{,}21 \times 10^{-52}$. Ambos términos son altamente significativos, confirmando misspecification funcional cuadrática y cúbica.

Comparación de Especificaciones: Resumen Numérico

Apéndice B

*

Referencias

Andreyeva, T., Long, M. W., & Brownell, K. D. (2010). The Impact of Food Prices on Consumption: A Systematic Review of Research on the Price Elasticity of Demand for Food. *American Journal of Public Health*, *100*(2), 216-222. https://doi.org/10.2105/AJPH.2008.151415

Bumagat, J. L., & Ibana, E. (2025, octubre). ECONOMICS FOR MANAGERS: Price Elasticity of Demand for Online Food Delivery Services: A Comparative Analysis of Peak and Off-Peak Hours in Metro Manila. https://researchgate.net

Christensen, P., Nino, G., & Osman, A. (2023, junio). *The Demand for Mobility: Evidence from an Experiment with Uber Riders* (Working Paper N.º 31330). National Bureau of Economic Research. https://doi.org/10.3386/w31330

Tabla A6

Resumen comparativo de todas las especificaciones estimadas.

Modelo	Elasticidad	EE	IC 95 %	R^2 adj.	AIC	N
OLS log-log base	−0,9398	0.005	[−0,950, −0,930]	0.1423	1,394,427	456,548
OLS log-log controles	−0,7513	0.005 (HC3)	[−0,762, −0,741]	0.5314	1,118,513	456,548
OLS semi-log controles	−1,0624*	0.003	[−1,069, −1,056]	0.5377	1,112,317	456,548
Panel FE (2 vías)	−1,5755	0.024 (cluster)	[−1,623, −1,528]	0.3251†	–	456,548
IV 2SLS (2 inst.)	−0,9487	0.003 (robusto)	[−0,955, −0,943]	–	–	456,544
IV justo identificado (1 inst.)	−0,9627	0.003	[−0,969, −0,957]	–	–	456,544
RCS OLS (4 nudos)	Variable‡	–	–	**0.5450**	**1,105,001**	456,548
IV Control Function (RCS + $\hat{v}$)	Variable‡	–	–	**0.5467**	–	456,544
Quantile Reg. $\tau = 0{,}1$	−0,6717	0.013 (boot)	[−0,697, −0,649]	–	–	456,548
Quantile Reg. $\tau = 0{,}5$	−0,7739	0.007 (boot)	[−0,788, −0,760]	–	–	456,548
Quantile Reg. $\tau = 0{,}9$	−1,0069	0.007 (boot)	[−1,021, −0,992]	–	–	456,548

* Evaluada en precio promedio (332.24): $\hat{\beta}_{\text{price}} \times \bar{P}$. † R^2 within.

‡ Elasticidad puntual variable según nivel de precio (ver Fig. 14).

Christensen, P., & Osman, A. (2021). *The Demand for Mobility: Evidence from an Experiment with Uber Riders* (IZA Discussion Paper N.º 14179). IZA Institute of Labor Economics. https://www.iza.org/publications/dp/14179/

Damayanti, R., Nuryakin, C., & Muchtar, P. A. (2023). Household Demand for Food Prepared at Home and Food Away from Home in Indonesia. *Economics and Finance in Indonesia*, *69*(1), 35-46. https://scholarhub.ui.ac.id/efi/vol69/iss1/3/

Davidson, J. (1994, octubre). *Stochastic Limit Theory: An Introduction for Econometricians*. Oxford University Press. https://doi.org/10.1093/0198774036.001.0001

Genpact / Analytics Vidhya. (2019). *Food Demand Forecasting*. Consultado el 1 de agosto de 2026, desde https://www.kaggle.com/datasets/kannanaikkal/food-demand-forecasting

Kahneman, D., Knetsch, J. L., & Thaler, R. H. (1991). Anomalies: The Endowment Effect, Loss Aversion, and Status Quo Bias. *Journal of Economic Perspectives*, *5*(1), 193-206. https://doi.org/10.1257/jep.5.1.193

Li, Z., & Wang, G. (2025). On-Demand Delivery Platforms and Restaurant Sales. *Management Science*, *71*(7), 5788-5804. https://doi.org/10.1287/mnsc.2021.01010

Long, J. S., & Ervin, L. H. (2000). Using Heteroscedasticity Consistent Standard Errors in the Linear Regression Model. *The American Statistician*, *54*(3), 217-224. https://doi.org/10.1080/00031305.2000.10474549

Sriwongphanawes, K., & Fukuda, D. (2024). How Do Fares Affect the Utilization of Ride-hailing Services: Evidence from Uber Japan's Experiments. *Asian Transport Studies*, *10*, 100121. https://doi.org/10.1016/j.eastsj.2023.100121

Statista. (2024). Online Food Delivery Worldwide – Revenue 2017–2027. https://www.statista.com/outlook/dmo/ecommerce/meal-delivery/worldwide

Zhang, X., & Demirkan, H. (2021). Between Online and Offline Markets: A Structural Estimation of Consumer Demand. *Information & Management*, *58*(4). https://www.sciencedirect.com/science/article/abs/pii/S0378720621000410